

See discussions, stats, and author profiles for this publication at: <https://www.researchgate.net/publication/340310594>

ESTADO DEL ARTE DE LA INTELIGENCIA ARTIFICIAL APLICADA AL MANTENIMIENTO BASADO EN CONDICIÓN

Article · May 2015

CITATIONS

0

READS

1,396

4 authors, including:



Leonardo Pachano

IFP Energies nouvelles

8 PUBLICATIONS 18 CITATIONS

[SEE PROFILE](#)



Mary Vergara

University of the Andes (Venezuela)

58 PUBLICATIONS 41 CITATIONS

[SEE PROFILE](#)



Cristian Garcia

Universidad Politécnica Salesiana (UPS)

8 PUBLICATIONS 3 CITATIONS

[SEE PROFILE](#)

Some of the authors of this publication are also working on these related projects:



Project

Knee Prosthesis: theoretical foundations and computational techniques applied to its design [View project](#)



Project

In this thesis an h-adaptive strategy is developed based on a subdivision refinement technique for three-dimensional domain problems that allows to obtain more reliable results when the finite elements method is applied [View project](#)

ESTADO DEL ARTE DE LA INTELIGENCIA ARTIFICIAL APLICADA AL MANTENIMIENTO BASADO EN CONDICIÓN

Pachano Leonardo¹, Vergara Mary², Garcia Cristian³, Provenzano Sebastian⁴

Resumen

Con niveles de rentabilidad cada vez más altos y niveles de tolerancia al fallo cada vez más bajos, el sector industrial afronta día a día el reto de producir haciendo un mejor uso de sus recursos. El Mantenimiento Basado en Condición (MBC) y el uso de técnicas de Inteligencia Artificial (IA) se encuentran alineados con los requerimientos que actualmente exige la ISO 55000 en términos de una gestión óptima de activos. El desarrollo de este trabajo presenta el estado del arte de la IA aplicada al MBC, a través de: la revisión de la evolución de la gestión de mantenimiento, el esquema general de mantenimiento que en la actualidad se propone, el procedimiento para monitoreo de condición establecido en la norma ISO 17359, las arquitecturas para MBC, las metodologías para diagnóstico y pronóstico de fallas, casos de estudio de esquemas MBC-IA y finalmente la revisión del concepto de *e-maintenance*. La revisión muestra que se han realizado esfuerzos sistemáticos, de manera aislada, para crear bases con las que se establezca una visión holística de la condición del equipo, el cual es el núcleo fundamental de un mantenimiento óptimo. Por esa razón, se propone en una discusión final, un esquema que muestra cómo pueden orientarse las interconexiones de diferentes sistemas para alcanzar una gestión óptima de activos.

Abstract

Higher levels of profitability and lower levels of fault tolerance have faced the industry to confront the daily challenge of producing in a way that better uses the available resources. Condition Based Maintenance (CBM) and Artificial Intelligence (AI) techniques are aligned with the requirements for optimal asset management established in the ISO 55000 standards family. This paper presents the state of the art of AI techniques applied to CBM by: reviewing the evolution of maintenance management, presenting the general maintenance scheme currently proposed, the procedure for machines condition monitoring established in the standard ISO 17359, CBM architectures, methodologies for fault diagnosis and prognosis, case studies of CBM-IA schemes and the concept of *e-maintenance*. The review made shows how systematic isolated efforts have been made to ground basis for establishing a holistic vision of the equipment condition. All of it, keeping in mind that assets are the nucleus for optimal maintenance. For that reason, in the final discussion, a scheme is proposed to show how interconnections between different systems can be oriented to achieve optimal asset management.

Keywords: Artificial Intelligence, Asset management, Condition Based Maintenance.

Palabras Clave: Gestión de activos, Inteligencia Artificial, Mantenimiento Basado en Condición.

¹ Ingeniero Mecánico, Grupo de Investigación de Diseño y Modelado de Máquinas, Universidad de Los Andes, Venezuela. leonardopachano@ula.ve

² Doctor Ingeniero Industrial, Investigador invitado de la Universidad Politécnica Salesiana, Profesor titular de la Universidad de Los Andes, Venezuela. vmary@ula.ve

³ Máster en Mantenimiento, Ingeniero Mecánico, Estudiante de Doctorado en Ciencias Aplicadas - Universidad de Los Andes, Venezuela, Director de la Carrera Ingeniería Mecánica Automotriz - UPS - sede Cuenca. cgarcia@ups.edu.ec

⁴ Doctor Ingeniero Industrial, Coordinador de la Maestría de Ingeniería de Mantenimiento, Profesor titular de la Universidad de Los Andes, Venezuela. prse@ula.ve

Introducción

La dinámica del sector productivo a nivel mundial está marcada hoy en día por el creciente aumento en la complejidad de los sistemas mecánicos involucrados y la interacción que éstos mantienen con diferentes componentes electrónicos. El panorama actual exige políticas de mantenimiento que permitan garantizar una mayor precisión en la detección, diagnóstico y predicción de fallas, aunado a un aumento en las ganancias y mejoras en los niveles de fiabilidad y rendimiento de los activos, todo ello como parte de un esquema para la gestión óptima de activos enmarcada en la familia de normas ISO 55000. Parte de la solución a la problemática de obtener un óptimo desempeño, pasa por incorporar la Ingeniería de Mantenimiento como un factor que represente una ganancia en el sistema productivo, mediante la implementación de tecnologías provenientes de campos multidisciplinarios. En ese sentido, la intersección entre la Ingeniería de Mantenimiento y las Tecnologías de Información y Comunicación (TIC) ha resultado en el desarrollo de conceptos como el de *e-maintenance* [1] que apuntan a dar respuesta a las necesidades de las organizaciones productivas en términos de un mejor aprovechamiento de los recursos disponibles para la gestión de sus activos. Un número considerable de los desarrollos tecnológicos que se desprenden del concepto de *e-maintenance* se basan en la aplicación de técnicas de monitoreo de condición de los activos, piedra angular del concepto de Mantenimiento Basado en Condición (MBC). A su vez, muchos esquemas de MBC consideran el uso de técnicas de Inteligencia Artificial (IA) como vehículos para el procesamiento de las señales captadas por los sensores que monitorean la condición de los activos.

En la literatura pueden encontrarse algunas revisiones hechas en el campo del MBC y las técnicas usadas para diagnóstico y pronóstico de fallas. Así, en las referencias [2] y [3] se presentan revisiones de metodologías usadas

para diagnóstico y pronóstico de fallas y elementos de la arquitectura OSA-CBM. Por su parte, los trabajos [4]-[8] revisan el uso de técnicas de IA para diagnóstico de fallas, mientras que [9], [10] hacen lo propio en lo relativo al pronóstico de fallas. Sin embargo, en ninguna de las investigaciones realizadas se ha encontrado un esquema de MBC-IA que incorpore una visión global que permita visualizar el mantenimiento y la producción como un todo que asegure la ganancia en su implementación en cualquier sistema productivo.

Por consiguiente, en este trabajo se presenta el estado del arte del uso de la IA aplicada al MBC, como parte de un marco de referencia que muestre como el MBC se ha integrado a la Ingeniería de Mantenimiento y como también se ha desarrollado una nueva generación de Sistemas de Soporte de Decisiones (SSD) que involucran herramientas y métodos que apuntan a la formalización y utilización del diagnóstico y pronóstico con IA como objetivo fundamental de la Ingeniería de Mantenimiento predictivo. Para finalizar, se propone un esquema piramidal, cuya base muestra la visión holística necesaria para alcanzar una gestión óptima que considere la condición de los activos.

1. Mantenimiento

La gestión de mantenimiento sigue un gran crecimiento, especialmente en tiempos de crisis, impulsada por el aumento en las expectativas asociadas a los objetivos que el proceso de mantenimiento puede alcanzar y por los cambios en la comprensión de cómo ocurren las fallas [11]. Un esquema de los cambios más importantes ocurridos en las políticas de mantenimiento, se muestra en la figura 1, donde con el desarrollo de nuevas tecnologías, el mantenimiento ha pasado de ser un enfoque tecnológicamente básico a un campo de tecnología multidisciplinario que resulta de importancia estratégica para el sector productivo.

En la actualidad, el mantenimiento está asociado a destrezas que permiten conservar los equipos operando bajo condiciones necesarias, que aprovechan al máximo su vida útil, con altos

niveles de fiabilidad y eficiencia, sin que esto implique perturbaciones económicas [12]. A propósito de esto, en [11] se describen dos enfoques, como se observa en la figura 2. El primero, representa un enfoque correctivo donde el mantenimiento es efectuado luego de la ocurrencia de la falla y el segundo, un enfoque preventivo en el cual el mantenimiento es llevado a cabo en intervalos de tiempo predeterminados para reducir la probabilidad de falla y deterioro en los equipos.



Figura 1. Cambios en las políticas de mantenimiento en las últimas décadas [11]

Bajo este esquema, el MBC forma parte de una estrategia de mantenimiento que busca mitigar el alza en los costos relacionada con la creciente complejidad de los equipos usados en los sistemas de producción. De hecho, los gastos de mantenimiento pueden reducirse hasta en un 20% [11] considerando la implementación adecuada, no solo de esquemas de MBC sino de las técnicas de monitoreo de condición (ligadas al desarrollo de este concepto) apropiadas para cada tipo de activo.

En ese campo, los primeros intentos por monitorear la condición de una máquina apuntaban a relacionar el estado de ésta con los niveles de vibración propios de su funcionamiento. Así, el año 1939 representa el inicio de la medición de señales de vibración con

la publicación por parte de T.C Rathbone de su artículo titulado “*Vibration Tolerance*”, donde plasmó criterios basados en observación que constituyen el primer método conocido para relacionar niveles de amplitud de vibración con la condición del equipo. Luego, en la década de los 50s, inicia el análisis de vibraciones con la fundación de la *International Research & Development* (IRD), empresa líder en evaluación de condición, mientras que entre los años 60s-70s, se desarrolló el acelerómetro y se empezaron a ofertar dispositivos para la medición de vibración. Posteriormente en 1975, Jim Badders de *Dow Industrial Service* acuñó el termino Mantenimiento Predictivo, que para mediados de los 80s era ya una política de mantenimiento que aprovechaba el desarrollo de dispositivos portátiles para grabación de señales de vibración. Por último, en los años 90s y hasta hoy, se han hecho evidentes las ventajas que en conjunto puede ofrecer el análisis de vibraciones con otros tipos de técnicas de monitoreo de condición (ver [13], [14]). Así, algunos sistemas de software para monitoreo de condición ya incluyen técnicas de monitoreo de vibración como parte integral de su funcionamiento [15].

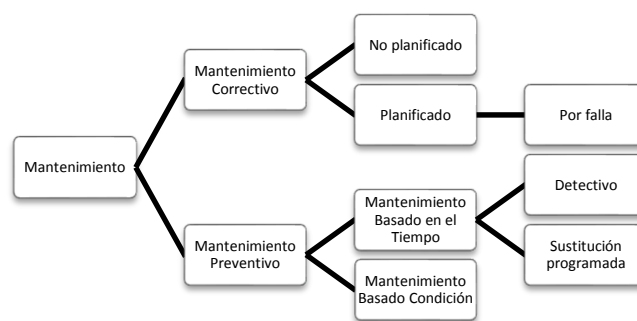


Figura 2. Esquema general de mantenimiento [11]

Los esquemas de MBC se encuentran enmarcados en una estructura general básica según se muestra en la figura 3 [16].

Estas etapas sirven de plataforma para la norma ISO 17359, donde la adquisición y procesamiento de datos son fundamentales para la toma de decisiones que directamente definen el éxito en la implementación del MBC.




Figura 3. Etapas en MBC [16]

2. Metodologías para el diagnóstico y pronóstico de fallas en sistemas de MBC

La parte fundamental para implementar un sistema de MBC es llevar a cabo tareas de detección, diagnóstico y pronóstico, primordialmente basada en datos, que permitan adelantarse a la aparición de fallas y evitar pérdidas debido a varios factores como tiempos de parada imprevistos. Por esto es importante detallar las metodologías usadas para tal fin, que se describen a continuación.

2.1. Metodologías basadas en modelos físicos

Emplean modelos matemáticos que están directamente conectados a fenómenos físicos que afectan la condición de un equipo o componente. Las metodologías bajo este enfoque utilizan residuos como características, estos residuos se obtienen mediante chequeos de consistencia entre los parámetros medidos en el sistema real a través de sensores y los parámetros obtenidos como salida del modelo matemático. La premisa es que los residuos se mantendrán bajo un umbral predeterminado bajo condiciones de operación normales y superará éste con la presencia de algún tipo de falla [2].

2.2. Metodologías basadas en conocimiento

Sustentadas en el conocimiento humano del proceso y sus fallos, surgen como respuesta a las limitaciones de los modelos físicos, asociadas a la difícil tarea de construir un modelo matemático exacto. Dos de las técnicas más usadas basadas en este tipo de metodología

incluyen Sistemas Expertos y Lógica Difusa. De forma generalizada, las metodologías bajo este enfoque buscan dar soluciones emulando el proceso de razonamiento humano [2].

2.3. Metodologías basadas en datos

Están basadas en técnicas estadísticas y de aprendizaje de máquina, cuya mayoría surgieron por el desarrollo de la teoría de reconocimiento de patrones. Básicamente, éstas pueden ser clasificadas bajo dos enfoques, uno estadístico y uno basado en la aplicación de IA. Las Redes Neuronales Artificiales son la técnica más comúnmente utilizada [2].

3. Monitoreo de condición. ISO 17359

La normativa ISO 17359:2011 [17], presenta un esquema genérico para el MBC de maquinaria como se muestra en la figura 4, que considera varios aspectos fundamentales.

3.1. Análisis beneficio/costo

Busca establecer indicadores de desempeño precisos y puntos de referencia para la medición de la efectividad de cualquier programa de monitoreo, considerando entre otros, costo del ciclo de vida, costo por pérdida de producción y daños colaterales.

3.2. Auditoria del equipo

Los equipos deben ser identificados considerando: componentes, procesos y su función de acuerdo a su actividad y condición de operación.

3.3. Auditoria de fiabilidad y criticidad

Se debe considerar el tipo de configuración (serie o paralelo). Seguidamente, se establece que máquinas deben o no ser incluidas en el programa para realizar un Análisis de Modos y Efectos de Fallos (AMEF) que permita identificar posibles fallas, síntomas y potenciales

parámetros de medición que sean útiles para identificar la presencia u ocurrencia de fallas.

3.4. Selección de las estrategias de mantenimiento

Se realiza en base al AMEF, en caso de que el modo de fallo no tenga un parámetro que pueda ser medido, se deben aplicar estrategias alternativas como mantenimiento correctivo, mantenimiento preventivo o rediseño de componentes.

3.5. Selección del método de monitoreo

Se deben considerar factores como: precisión de los parámetros medidos, viabilidad de la medición, condiciones de operación durante las mediciones, intervalos de medición y tasa de adquisición de datos. Esta información debe ser almacenada considerando la inclusión de información esencial para la descripción de la máquina, posición de la medición, unidades de medición e información de fecha y hora.

3.6. Adquisición y análisis de datos

La gestión del procedimiento de recolección de datos para monitoreo de condición supone que las mediciones sean tomadas de forma periódica y de manera más frecuente que el modo esperado de falla. El procedimiento descrito conlleva a la comparación entre las mediciones realizadas y el criterio de alarma, si las mediciones no cumplen con el criterio de alarma entonces se desencadena el proceso de diagnóstico y pronóstico.

3.7. Determinación de las acciones de mantenimiento

Al completar las acciones de mantenimiento, se recomienda registrar las actividades y cambios hechos sobre la máquina incluyendo los repuestos usados, habilidades necesarias para la identificación de la falla, entre otros, con la finalidad de construir un registro histórico que pueda resultar útil para futuros procesos de

diagnóstico/pronóstico y para la revisión del proceso general de monitoreo de condición.

3.8. Revisión

El proceso de monitoreo es iterativo, y como tal se recomienda la revisión periódica de las técnicas y criterios involucrados en su desarrollo, con la finalidad de mantenerse a la par con los más recientes desarrollos tecnológicos en el área.

4. Arquitecturas para MBC

Generalmente, los sistemas de MBC engloban diferentes tecnologías diseñadas para satisfacer alguna necesidad en particular. De ser posible, deben ser articulados sobre una estructura estándar que pueda unificar todos los elementos involucrados en un sistema de MBC, ya que de cierta manera, estos pueden definir las técnicas de Inteligencia Artificial a desarrollar, cumpliendo con la norma ISO 17359.

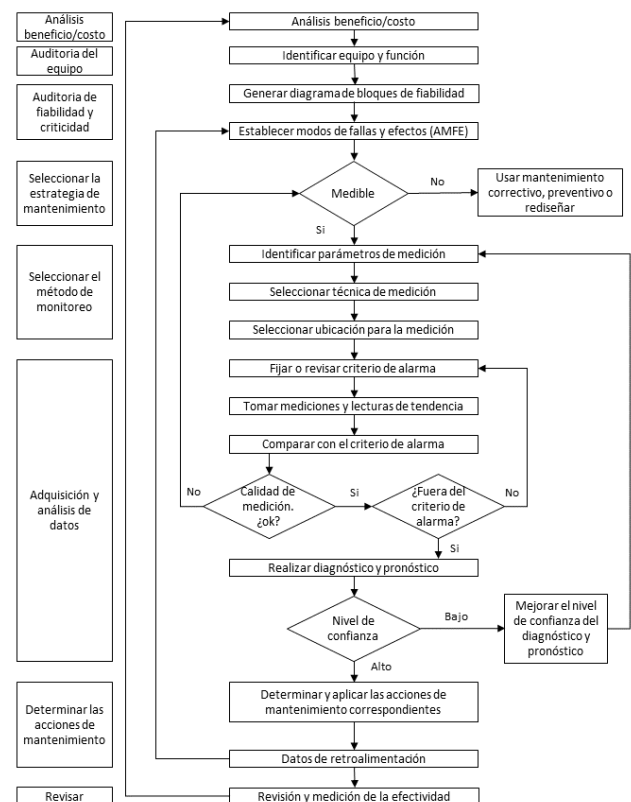


Figura 4. Procedimiento genérico para el monitoreo de condición según ISO 17359:2011 [17]

4.1. Arquitectura OSA-CBM

La Arquitectura de Sistema Abierto para Mantenimiento Basado en Condición, en inglés *Open Systems Architecture for Condition-Based Maintenance* (OSA-CBM) divide el proceso de mantenimiento en siete capas con la intención de integrar todos los componentes de software y hardware conformando una estructura común para éstos. Esta arquitectura fue parcialmente desarrollada en 2001 por la Marina de EEUU en colaboración con industrias líderes de varios sectores productivos como parte del programa *Dual Use Science and Technology* (DUST). La organización *Machine Information Management Open System Alliances* (MIMOSA) define OSA-CBM como “una arquitectura estándar para el flujo de información en un sistema de Mantenimiento Basado en Condición. Además de reducir costos, mejorar la interoperabilidad, aumentar la competencia, añade cambios de diseño y ofrece un mayor dominio en el campo del Mantenimiento Basado en Condición” [11]. Como se detalla en la figura 5, hay siete capas que conforman OSA-CBM, y algunas de ellas tienen normas asociadas a su desarrollo.

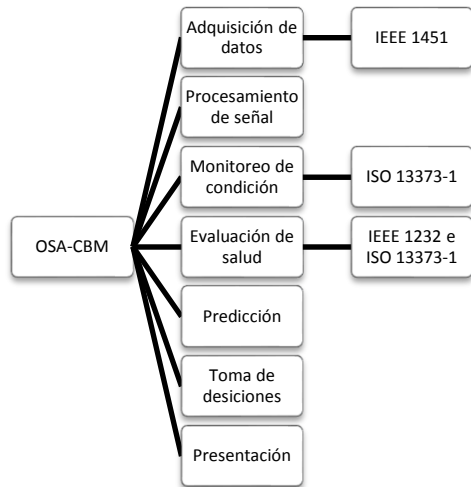


Figura 5. Capas de la arquitectura OSA-CBM

4.2. Arquitectura PROTEUS

El proyecto PROTEUS fue desarrollado con el patrocinio del Ministerio de Economía, Finanzas e Industria de Francia y el Ministerio Federal de

Educación e Investigación de Alemania. PROTEUS representa una plataforma de integración para los distintos componentes asociados a las actividades de mantenimiento en una organización, estos componentes están basados en distintos modelos que generalmente se complementan entre sí, pero que siempre están caracterizados por un alto grado de heterogeneidad. PROTEUS engloba todos los subsistemas que conforman un sistema de mantenimiento y los transforma en una descripción única del equipo a través de una arquitectura genérica que se basa en la tecnología de servicios web mediante el uso de tres componentes principales, *Central Service Application* (CSA), *Intelligent Core Adapter* (ICA) y *Functional Core Applications* (FCA) [18]. La figura 6, muestra el esquema general de la arquitectura PROTEUS.

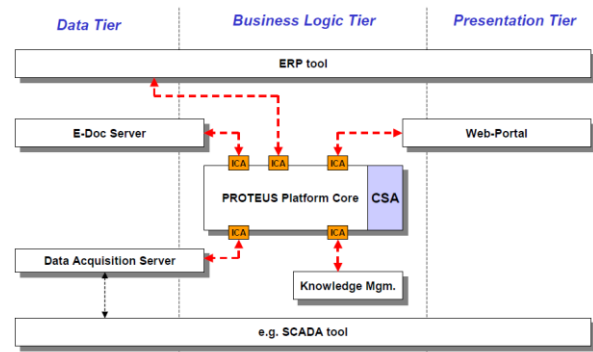


Figura 6. Arquitectura de la plataforma PROTEUS [17]

5. Casos de estudio de la IA aplicada al MBC

Los primeros usos de técnicas de IA aplicadas al MBC datan de mediados de los años 80s, fecha por la cual, IRD presentó un Sistema Experto para vibración de maquinaria llamado *Amethyst*. En esa misma década, otros desarrollos marcaron el inicio de la relación entre IA y MBC con propuestas como la de *DLI Engineering Corp.*, quien desarrolló un Sistema Experto para vibraciones en busca de mejorar la exactitud, calidad y consistencia del plan de MBC de los portaviones de la marina de los Estados Unidos. Para finales de esa década y principios de los 90s

dos nuevos Sistemas Expertos continuaron marcando la tendencia, por un lado *Design Maintenance Systems, Inc.* consiguió un contrato del gobierno canadiense para el desarrollo de un Sistema Experto para mantenimiento predictivo basado en vibración para embarcaciones rompehielos, mientras que CSI introdujo al mercado *Nspector*, un Sistema Experto para análisis de vibración de maquinaria [15].

En la actualidad, la tendencia en el uso de técnicas de IA en programas de mantenimiento sigue su curso. Como ejemplo, el trabajo realizado por [19] presenta los resultados de un estudio estadístico donde fueron analizadas 612 encuestas recibidas durante octubre de 2011, que buscaban aclarar el panorama en lo que se refiere al uso de IA en la industria de energía y petróleo. Cuando los participantes del estudio fueron interrogados respecto a los desafíos que se presentan en el manejo y análisis de información, 40% de ellos respondieron que la falta de modelos físicos que describan los problemas que se presentan es un desafío. Con base en ese porcentaje se puede inferir que hay un gran potencial asociado al uso de técnicas de IA (que aún no se aprovecha a cabalidad) dada la capacidad de estas técnicas para resolver problemas sin necesidad de contar con modelos físicos.

Como respuesta a la necesidad de contar con sistemas capaces de diagnosticar y predecir fallos en equipos basándose en la condición de éstos, el uso de técnicas de IA se perfila como una alternativa viable.

En función de la estructura del MBC a través de la ISO 17359 y las arquitecturas presentadas, se han dividido en diferentes casos de estudio las aplicaciones de IA en MBC. La revisión realizada, se extiende desde la aplicación de técnicas individuales en IA, hasta la aplicación híbrida de las mismas, donde esta última parece ser la más apropiada y robusta para sistemas complejos.

5.1. Sistemas Expertos

De forma generalizada, el uso de Sistemas Expertos, se basa en información proporcionada

por expertos y almacenada en forma de reglas. Al respecto, en [20] se presenta un Sistema Experto para la detección de fallas en equipos para fabricación de pantallas LCD. El sistema presenta en forma de reglas la relación entre síntomas y posibles diagnósticos, así como acciones que brinden soporte a las tareas de mantenimiento. Por su parte, en [21] se desarrolla un Sistema Experto para el diagnóstico y pronóstico de fallas en máquinas eléctricas. El software está sustentado en el uso de bases de datos y puede funcionar conectado a un servidor o de manera independiente. El trabajo de [22] describe un Sistema Experto para la detección y localización de fallas en el aislamiento de transformadores eléctricos. El sistema fue desarrollado bajo un esquema reconfirmativo que se sustenta en la capacidad para diagnosticar fallas desempeñando análisis de dominio de tiempo y frecuencia.

Finalmente, en cuanto al uso de Sistemas Expertos para pronóstico de fallas, se puede hacer referencia a [23] para el pronóstico de fallas en centrales hidroeléctricas y a [24] donde se presenta un Sistema Experto para mantenimiento predictivo con base en el análisis de señales de vibración aplicable a diferentes tipos de activos.

5.2. Sistemas Basados en Casos

En [25], [26] se presentan aplicaciones de Sistemas Basados en Casos para el diagnóstico de fallas. El primer trabajo describe un sistema para la detección de fallas en robots industriales mediante el estudio de señales acústicas. Las señales son captadas a través de micrófonos y son almacenadas en una biblioteca de casos junto con su respectivo diagnóstico. En el segundo trabajo, se describe un modelo para soporte de decisiones y diagnóstico de fallas en flotas de vehículos basado en una extensión del Razonamiento Basado en Casos, conocida como Razonamiento Dinámico Basado en Casos (*Dynamic Case - based Reasoning – DCBR*). El modelo considera el uso de información cuantitativa y cualitativa. Bajo el esquema propuesto, los operadores entregan información

en forma de descripciones textuales que son transformadas en redes semánticas, con esa información se realizan búsquedas dentro de la biblioteca de casos para generar hipótesis que son evaluadas y categorizadas en un ranking de prioridad como parte del proceso de diagnóstico.

5.3. Máquinas de Soporte Vectorial

Los modelos de diagnóstico de fallas basados en el uso de Máquinas de Soporte Vectorial, aprovechan la capacidad de generalización de esta técnica de IA para clasificar características de fallos extraídas de señales captadas por sensores que monitorean la condición de los activos. Así, en [27]-[29] se describe el uso de Máquinas de Soporte Vectorial para el diagnóstico de fallas en bandas transportadoras de carbón, máquinas de estampado metálico y Sistemas de Calefacción, Ventilación y Aire Acondicionado (*Heat Ventilation and Air Conditioning* – HVAC), respectivamente. Por otro lado, los trabajos de [30]-[32] hacen lo propio pero en el caso de máquinas rotativas.

Por su parte, en [33] se evalúa el desempeño de Árboles de Clasificación y Regresión (*Classification And Regression Tree* - CART), Análisis Multidiscriminante y Máquinas de Soporte Vectorial, para el diagnóstico de fallas en motores de inducción. Los autores consiguieron índices de precisión en la clasificación de fallas de 92.44%, 88.88% y 99.61%, respectivamente. De forma similar, el trabajo de [34] describe el diagnóstico de fallas en motores eléctricos mediante la clasificación de características extraídas con la Transformada Discreta de Fourier (TDF). Igualmente, [35] propone el diagnóstico de fallas en motores de inducción basado en señales de vibración. En ese mismo trabajo, para mitigar el efecto de señales de ruido, los autores proponen el procesamiento de las señales mediante la técnica de análisis de textura. Con ese fin, las señales son transformadas en imágenes bidimensionales en escala de grises y son analizadas mediante Patrones Binarios Locales (*Local Binary Patterns* – LBP) para la extracción de

características de fallas que son clasificadas por Máquinas de Soporte Vectorial.

Por último, [36] propone un esquema para la predicción de la intensidad y localización de daños en elementos del tipo viga en cantiléver. Como parte del trabajo, se realizó una simulación basada en el Método de Elementos Finitos donde se estudió el comportamiento de una viga bajo el efecto de vibración. El 90% de la data generada en la simulación fue utilizada para entrenar Máquinas de Soporte Vectorial, mientras que la data restante fue usada para validación.

5.4. Lógica Difusa

Las metodologías basadas en este tipo de técnica, utilizan motores de inferencia para el diagnóstico de posibles estados de fallas. En los trabajos [37]-[43] diferentes tipos de señales medidas sobre motores eléctricos son analizadas para la extracción de características que sirven como parámetros de entrada para el diagnóstico de fallas. Con aplicación en otro campo, [44] presenta un esquema para la detección de fallas en la planta compresora PIGAP I asociada a PDVSA. La detección de las fallas está basada en la metodología de Mantenimiento Centrado en Confiabilidad y la utilización de un sistema de Lógica Difusa desarrollado en Matlab. Por último, [45] plantea un modelo para la detección de fallas en transformadores eléctricos mediante el Análisis de Gases Disueltos en aceite. Las diferentes concentraciones de gases son usadas como indicadores de fallas que son analizadas en un esquema basado en Lógica Difusa.

5.5. Redes Neuronales Artificiales

El uso de Redes Neuronales Artificiales se encuentra documentado en la literatura en artículos que describen el uso de estos modelos para el diagnóstico y pronóstico de fallas basado en el análisis de señales captadas por sistemas para monitoreo de condición. En [46] proponen el uso de Redes Neuronales para la detección de fallas en turbinas eólicas con base en el estudio de señales de vibración y corriente eléctrica del estator registradas mediante sensores

inalámbricos del tipo piezoeléctrico y de efecto Hall, respectivamente. De manera similar, en [47] se presenta un modelo de Redes Neuronales para la detección de fallas incipientes en los rodamientos de turbinas eólicas, basado en la utilización de datos recolectados y almacenados por el sistema *Supervisory Control and Data Acquisition* (SCADA) instalado en la turbina.

En el campo automotriz, [48] propone el diagnóstico de fallas en motores diésel basado en el estudio de la curva de presión de los cilindros. El esquema propuesto utiliza un modelo que combina Redes Neuronales con funciones de base radial y Redes Neuronales de regresión generalizada, diseñado para reconstruir la señal de presión del pistón tomando como entrada señales de vibración. Estudios experimentales muestran un buen desempeño del esquema propuesto con valores de desviación estándar para la presión máxima promedio que varían entre 0.03 y 1.01%.

En la literatura también se pueden encontrar trabajos donde se propone el uso de Redes Neuronales para pronóstico de fallas. En [49] se propone la utilización de un modelo de Redes Neuronales para la estimación de la Vida Útil Restante considerando como parámetros de estudio el tiempo de suspensión (tiempo fuera de servicio del activo) y el nivel de degradación contemplado en el histórico de suspensión de los equipos. De manera similar, en [50] se describe un modelo generalizado para la estimación de la Vida Útil Restante en equipos que considera como parámetros de entrada los datos del histórico de fallas y de reemplazos. Los autores proponen además la estimación del grado de incertidumbre del modelo de Redes Neuronales tomando como base el conjunto de errores de predicción durante el entrenamiento y proceso de prueba, esto como parte de una estrategia para optimizar el Mantenimiento Basado en Condición. Así mismo, los autores también desarrollaron un método numérico para el cálculo del costo de las políticas del MBC.

La tabla 1 presenta un resumen de la literatura relacionada al uso de Redes Neuronales Artificiales en esquemas de MBC. Al respecto,

las aplicaciones más comunes corresponden al diagnóstico y/o pronóstico de fallas en motores eléctricos o rodamientos.

Tabla. 1: Resumen de referencias asociadas al uso de Redes Neuronales Artificiales aplicadas al MBC

Activo	Referencia
Engranajes	[51]
Generadores eléctricos	[52], [53]
Máquinas rectificadoras	[54]
Motores de avión	[55]
Motores eléctricos	[56]-[63]
Rodamientos	[64]-[72]
Sensores	[73], [74]
Sistemas neumáticos	[75]
Transformadores	[76]
Varios	[77]

5.6. Sistemas Híbridos

Varios Sistemas para Soporte de Decisiones (SSD) han sido desarrollados en base a modelos que integran el uso de distintas técnicas de IA. En relación a lo anterior, en [78] desarrollaron un sistema inteligente para predicción y soporte de decisiones (*Intelligent Predictive Decision Support System* – IPDSS) sustentado en el uso del Razonamiento Basado en Casos, modelos basados en reglas y Redes Neuronales Recurrentes. El monitoreo de la condición le permite al IPDSS brindar soporte de manera oportuna. Con ese objetivo, cuando los parámetros de operación alcanzan un nivel de alarma, el IPDSS le indica al personal de mantenimiento que una condición de advertencia ha ocurrido y activa el proceso de Razonamiento Basado en Casos para determinar si se trata de una falla reincidente, en cuyo caso el sistema ofrece consejos de forma automática, o si se está en presencia de una falla no documentada, en cuyo caso entra en funcionamiento el sistema de diagnóstico. Una vez que se diagnostica un componente como la fuente de la falla, se inicia el proceso para la predicción de la tendencia de deterioro que permite estimar la Vida Útil Restante del equipo.

Por su parte, en [79] se propone el uso de una metodología basada en el uso de información del monitoreo en tiempo real de la condición de equipos rotativos para determinar la Vida Útil Restante de éstos y determinar la mejor política

de reemplazo. El SSD presentado fue desarrollado en una estructura de tres módulos: el primer módulo, consiste en una base de datos alimentada con información del estado de deterioro proveniente del análisis de señales de vibración captadas por acelerómetros. El siguiente módulo está constituido por un modelo de Redes Neuronales entrenadas para predecir el percentil de vida y los tiempos de fallas en los rodamientos de los equipos. Por último, el tercer módulo genera una matriz de costos que permite estimar el punto óptimo de reemplazo que disminuya los costos esperados de mantenimiento.

En ese mismo orden de ideas, en [80] se presenta una herramienta conocida como *Intelligent System for Predictive Maintenance* (SIMAP), un software diseñado para el diagnóstico de fallas en tiempo real que toma en consideración información proveniente de diferentes sensores, así como de otras fuentes de información en busca de detectar anomalías en el comportamiento esperado de componentes industriales, que en el caso particular del trabajo presentado por los autores, corresponden a componentes de una turbina eólica. SIMAP presenta una estructura modular que entre otras técnicas utiliza Redes Neuronales para clasificación de patrones, Sistemas Expertos Difusos para diagnóstico de fallas y Algoritmos Genéticos Difusos para planificación de actividades de mantenimiento.

Por su parte, en [81] se describe el funcionamiento de la herramienta *Watchdog AgentTM*, desarrollada por el Centro para Sistemas Inteligentes de Mantenimiento (IMS). *Watchdog AgentTM* es una herramienta multisensor que puede ser usada para realizar Mantenimiento Predictivo Basado en Condición o para estimar la Vida Útil Restante de componentes claves de máquinas o procesos. Para facilitar el uso de la herramienta, ésta se encuentra estructurada bajo una arquitectura abierta lo que permite el uso de diferentes modelos y algoritmos usados para procesamiento de señales y extracción de características,

evaluación de la salud, diagnóstico y predicción de desempeño.

Finalmente, los modelos basados en Sistemas Híbridos, también han sido usados en pronóstico de fallas. En [82] se describe un esquema que combina el uso del Modelo Autoregresivo de Media Móvil (ARMA) y Máquinas de Soporte Vectorial de Mínimos Cuadrados para Regresión (LS-SVR) para el pronóstico de fallas en estructuras de aviones. Por otro lado, [83] presenta un modelo híbrido para la predicción de fallas basado en el Modelo Gaussiano Oculto de Markov (MG-HMM) y el modelo de regresión de soporte vectorial (FS-LSSVR). Los modelos propuestos en ambos trabajos utilizan conjuntos de datos conocidos para estimar el valor futuro de variables que permiten el cómputo de la Vida Útil Restante de los activos bajo estudio.

La tabla 2 presenta un resumen de los artículos disponibles en la literatura en lo referente al uso de Sistemas Híbridos en MBC. El uso de modelos basados en Redes Neuronales Artificiales (en conjunto con el uso de Lógica Difusa o algoritmos de optimización) predomina en la literatura, especialmente aplicado al diagnóstico y/o pronóstico de fallas en motores eléctricos.

Tabla 2: Resumen de referencias disponibles asociadas al uso de Sistemas Híbridos aplicados en MBC

Tipo de activo	Referencia
Actuadores hidráulicos	[84]
Bombas hidráulicas	[85], [86]
Centrales hidroeléctricas	[87]
Compresores	[88]
Engranajes	[89]-[92]
Fresadoras CNC	[93]
Motores Diésel	[94]
Motores eléctricos	[95]-[107]
Reactores nucleares	[108]
Rodamientos	[109], [110]
Trenes	[111]

6. E-maintenance

Los desarrollos presentados en los casos de estudio han impulsado la introducción de nuevos conceptos dentro de la función de mantenimiento. De esa manera, en la actualidad el concepto de *e-maintenance* ha ganado

relevancia. El término fue acuñado a principios de la década del 2000, y la idea detrás de éste fue desarrollada con el surgimiento de internet y el cómputo en la nube. El concepto se basa en un sistema de mantenimiento con capacidad para gestionar e intercambiar datos/información a través de internet. El desarrollo de este concepto ha forzado la integración del monitoreo y la supervisión en sistemas distribuidos complejos que operan sobre áreas de producción completas [1].

Además, el concepto es el pilar sobre el cual se han desarrollado conceptos adicionales como *e-manufacturing* y *e-business*. En relación a esto, el Centro de Sistemas de Mantenimiento Inteligentes (IMS) ha desarrollado una plataforma denominada *Device-to-Business* (D2B) TM que permite a los equipos conectados a través de una plataforma de *e-maintenance* estar en contacto con sistemas de *e-business* para solicitar acciones de mantenimiento de manera automática [112].

7. Discusión

Las mejoras en los niveles de confiabilidad y rentabilidad se alcanzan con la incorporación de tecnologías que permitan hacer un mejor uso de los activos de la organización, adelantándose a los posibles fallos y manteniendo los tiempos de operación correctos altos, mientras los tiempos de parada no planificados se mantienen lo más bajos posibles.

La figura 7 esquematiza el mayor desafío que enfrenta en la actualidad el sector productivo: *la integración de datos*. Por un lado, las empresas deben afrontar la problemática que se presenta al momento de integrar la información contenida en la base de datos de los sistemas de Gestión de Mantenimiento Asistida por Ordenador (GMAO), con la información obtenida mediante la inspección visual de los equipos. Por otro lado, las empresas deben poder manejar la interacción entre el proceso de operación propio de los equipos y el software de MBC, a través de una interfaz basada en el desarrollo de sensores inteligentes. La integración de todos estos

elementos es la base para la consolidación de una visión holística de la condición de los equipos que permita disminuir los niveles de tolerancia al fallo mediante la detección, diagnóstico y predicción de fallas de manera más efectiva y confiable. Los esfuerzos llevados a cabo en este sentido, buscan conseguir una mejor planificación que conlleve a mayores niveles de rentabilidad, que en la actualidad son exigidos como parte de una gestión de activos óptima que cumpla con los lineamientos de la normativa ISO 55000.

En definitiva, la correcta incorporación de técnicas de IA como parte de un esquema de MBC puede tomar provecho de los datos disponibles (históricos y captados por sistemas de monitoreo de condición) para diagnosticar y predecir la aparición de fallos de manera mucho más efectiva.

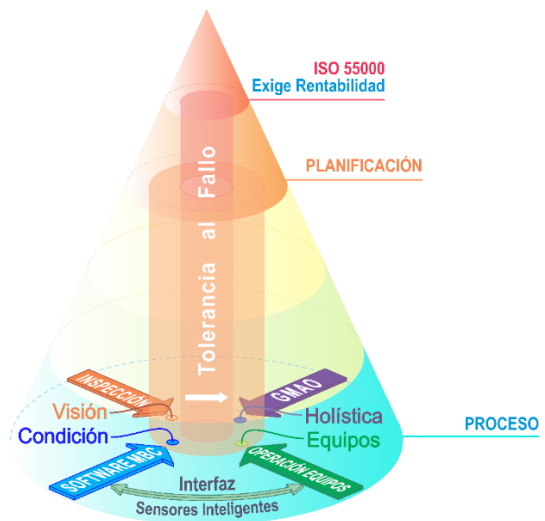


Figura 7. Rentabilidad para procesos productivos

8. Conclusiones

Con el desarrollo de este trabajo se presentó el estado del arte en el uso de la Inteligencia Artificial aplicada al Mantenimiento Basado en la Condición de la maquinaria, como un aporte que permita tener una visión más clara del panorama actual en términos de los conceptos y tecnologías que hoy en día se aplican para

mejorar los niveles de confiabilidad y rentabilidad de las organizaciones productivas.

Se mostró como se han creado las bases suficientes para establecer una visión holística de la condición de la maquinaria y con ello se propone un esquema que define las conexiones necesarias de diferentes sistemas en el proceso productivo para alcanzar una gestión óptima de activos.

Con base en el análisis realizado con los casos de estudio, puede hacerse notar el hecho de que la tendencia parece ser el uso de sistemas híbridos que tomen ventaja de las diferentes potencialidades asociadas a las diferentes técnicas de IA. Sin embargo, con base en ese mismo análisis también es importante resaltar que el uso de técnicas de IA como parte de esquemas de MBC aún no ha calado en la manera en que se esperaría dada las ventajas que conlleva el uso de estas técnicas. Por ese motivo, debe hacerse frente al reto de consolidar la evaluación económica de las políticas de mantenimiento como un factor clave que permita medir el impacto que éstas tienen sobre la organización, siempre con miras en trabajar de manera más efectiva a través del aumento de la ganancia.

Agradecimiento

La presente investigación agradece a la Secretaria Nacional de Educación Superior, Ciencia, Tecnología e Innovación SENESCYT Ecuador y su programa Prometeo por su aporte al desarrollo de la misma.

Referencias

[1] P. Oborski, “Developments in integration of advanced monitoring systems”, *Int. J. Advanced Manufacturing Technology*, vol. 75, pp. 1613–1632, 2014.

[2] Y. Peng, M. Dong, y M. J. Zuo, “Current status of machine prognostics in condition-based

maintenance: a review”, *Int. J. Advanced Manufacturing Tech.*, vol. 50, no. 1–4, pp. 297–313, 2010.

[3] R. Kothamasu, S. Huang, y W. VerDuin, “System health monitoring and prognostics — a review of current paradigms and practices”, *Int. J. Advanced Manufacturing Tech.*, vol. 28, no. 9–10, pp. 1012–1024, 2006.

[4] K. Kobbacy, S. Vadera, y M. Rasmy, “AI and OR in management of operations: history and trends”, *J. Operational Research Soc.*, vol. 58, no. 1, pp. 10–28, 2006.

[5] A. Patterson-Hine, G. Aaseng, G. Biswas, S. Narasimhan, y K. Pattipati, “A review of diagnostic techniques for ISHM applications” sin publicar.

[6] W. G. Fenton, T. M. McGinnity, y L. P. Maguire, “Fault diagnosis of electronic systems using intelligent techniques: a review”, *IEEE Trans. Syst. Man Cybern. C, Appl. Rev.*, vol. 31, no. 3, pp. 269–281, 2001.

[7] A. Siddique, G. Yadava, and B. Sin, “Applications of artificial intelligence techniques for induction machine stator fault diagnostics: review”, en *Symp. Diagnostics Electric Machines, Power Electronics and Drives*, Atlanta, 2003.

[8] I. Gondres, S. Lajes, y A. del Castillo, “Nuevo enfoque sobre la gestión del mantenimiento en subestaciones eléctricas”, *Energética*, vol. 28, no. 3, pp. 30–34, 2007.

[9] M. Schwabacher y K. Goebel, “A Survey of artificial intelligence for prognostics” sin publicar.

[10] C. S. Byington, M. J. Roemer, y Galie, “Prognostic enhancements to diagnostic systems for improved condition-based maintenance [military aircraft]”, *IEEE Proc. Aerospace Conference*, Big Sky, 2002.

[11] E. J. Amaya Simeón, “aplicação de técnicas de inteligência artificial no desenvolvimento de um sistema de manutenção baseada em condição” M.S. thesis, Dept. Engenharia Mecânica, Univ. Brasília, Brasília, 2008.

- [12] K. Holmberg, "Conclusions and future perspectives", en *E-maintenance*, Ed. Springer, 2010.
- [13] G. P. Sullivan, R. Pugh, A. P. Melendez, and W. D. Hunt, "Operations & Maintenance Best Practices. A Guide to Achieving Operational Efficiency", *Federal Energy Management Program*, vol. 3, 2010.
- [14] H. Czichos, *Handbook of Technical Diagnostics: Fundamentals and Application to Structures and Systems*. United States: Springer.
- [15] J. Mitchell, "From Vibration Measurements to Condition Based Maintenance Seventy Years of Continuous Progress", *Sound and Vibration*, 2007.
- [16] M. Romanò, "Analysis of the new technologies for industrial maintenance" M.S. thesis, Politecnico di Milano, Milano, 2011.
- [17] *Condition monitoring and diagnostics of machines - general guidelines*, ISO standard 17359, 2011.
- [18] T. Bangemann, X. Rebeuf, D. Reboul, A. Schulze, J. Szymanski, J.-P. Thomesse, M. Thron, y N. Zerhouni, "PROTEUS—creating distributed maintenance systems through an integration platform", *Comput. Industry*, vol. 57, no. 6, pp. 539–551, 2006.
- [19] C. Bravo, N. de Guzman, S. Mohaghegh, M. Nikolau, G. Nunez, A. G. Pérez F. Rivas, L. Saputelli y G. Zangl, "Satate of the art of artificial Intelligence and predictive analytics in the E&P industry: a technology survey", En SPE Western Regional Meeting, Bakersfield, 2012.
- [20] Y. Yao, G. Lin, y A. Trappey, "Using knowledge-based intelligent reasoning to support dynamic equipment diagnosis and maintenance", *Int. J. Enterprise Inform. Syst.*, vol. 2, no. 1, pp. 17–29, 2006.
- [21] V. Kontargyri, C. Tsirekis, S. Sakarellos, A. Moronis, N. Kolliopoulos, y S. Kaminaris, "An expert system for fault diagnosis, repairing and maintenance of electrical machines", en Proc. 6th WSEAS Int. Conf. Applict. Elect. Eng., Estambul, 2007.
- [22] P. Purkait y S. Chakravorti, "Time and frequency domain analyses based expert system for impulse fault diagnosis in transformers", *IEEE Trans. Dielectr. Electr. Insul.*, vol. 9, no. 3, pp. 433–445, 2002.
- [23] A. Benavides, S. Saludes, L. de Miguel, y J. Perán, "Sistema experto para el mantenimiento predictivo de una central hidroeléctrica" sin publicar.
- [24] J. Calvo Rolle, R. Ferreira García, A. Álvarez, y H. Alaiz Moretón, "sistema basado en conocimiento para análisis de vibraciones en mantenimiento predictivo", *DYNA*, vol. 83, no. 8, pp. 484–492, 2008.
- [25] E. Olsson, P. Funk, y M. Bengtsson, "Fault diagnosis of industrial robots using acoustic signals and case-based reasoning", en *7th European Conf. Case-Based Reasoning*, Madrid, 2004.
- [26] A. Saxena, B. Wu, y G. Vachtsevanos, "Integrated diagnosis and prognosis architecture for fleet vehicles using dynamic case-based reasoning", en *IEEE Autotestcon*, Orlando, 2005.
- [27] W. Li, Z. Wang, Z. Zhu, G. Zhou, y G. Chen, "Design of online monitoring and fault diagnosis system for belt conveyors based on wavelet packet decomposition and support vector machine", *Advances in Mech. Eng.*, vol. 13, pp. 6–10, 2013.
- [28] M. Ge, G. Zhang, R. Du, and Y. Xu, "Application of support vector machine based fault diagnosis", en *15th Triennial World Cong.*, Barcelona 2002.
- [29] D. Dehestani, F. Eftekhari, Y. Guo, S. Ling, S. Su, y H. Nguyen, "Online support vector machine application for model based fault detection and isolation of HVAC system", *Int. J. Machine Learning and Computing*, pp. 66–72, 2011.
- [30] C. Shen, D. Wang, F. Kong, y P. Tse, "Fault diagnosis of rotating machinery based on the statistical parameters of wavelet packet paving and a generic support vector regressive classifier", *Measurement*, vol. 46, no. 4, pp. 1551–1564, 2013.
- [31] J. Cheng, D. Yu, J. Tang, y Y. Yang, "Application of SVM and SVD technique based on EMD to the fault diagnosis of the rotating machinery", *Shock and Vibration*, vol. 16, no. 1, pp. 89–98, 2009.

- [32] Y. Yang, D. Yu, y J. Cheng, "A fault diagnosis approach for roller bearing based on IMF envelope spectrum and SVM", *Measurement*, vol. 40, no. 9–10, pp. 943–950, 2007.
- [33] Y. Ghate y S. Dudul, "Artificial neural network based fault classifier for three phase induction motor", *Int. J. Computational Intell. Research*, vol. 5, no. 1, pp. 25–36, 2009.
- [34] A. Jawadekar, G. Dhole, S. Paraskar, y M. Beg, "signal processing based svm classifier for mixed fault detection in induction motor" sin publicar.
- [35] M. R. Shahriar, T. Ahsan, y U. Chong, "Fault diagnosis of induction motors utilizing local binary pattern-based texture analysis", *EURASIP J. Image and Video Processing*, vol. 2013, no. 1, 2013.
- [36] S. Satpal, Y. Khandare, A. Guha, y S. Banerjee, "Structural health monitoring of a cantilever beam using support vector machine", *Int. J. Advanced Structural Eng. (IJASE)*, vol. 5, no. 1, 2013.
- [37] M. Akar y I. C. Ankaya, "Broken rotor bar fault detection in inverter-fed squirrel cage induction motors using stator current analysis and fuzzy logic", *Turk J. Elec. Eng. & Comp. Sci.*, vol. 20, no. 1, pp. 1077–1089, 2012.
- [38] F. Zidani, D. Diallo, M. Benbouzid, y R. Nait-Said, "A fuzzy-based approach for the diagnosis of fault modes in a voltage-fed PWM inverter induction motor drive", *IEEE Trans. Ind. Electron.*, vol. 55, no. 2, pp. 586–593, 2008.
- [39] V. Prakash Pandey y P. Kumar Choudhary, "Induction Motor Condition Monitoring Using Fuzzy Logic", *Advance in Electronic and Electric Engineering*, vol. 3, no. 6, pp. 755–764, 2013.
- [40] J. Quiroga, L. Liu, y D. Cartes, "Fuzzy logic based fault detection of PMSM stator winding short under load fluctuation using negative sequence analysis", en *American Control Conference*, Seattle, 2008.
- [41] R. Saravana Kumar, K. Vinoth Kumar, y K. Ray, "Fuzzy logic based fault detection in induction machines using lab view", *Int. J. Comput. Sci. Network Security*, vol. 9, no. 9, pp. 226–243, 2009.
- [42] P. V. Jover Rodríguez y A. Arkkio, "Detection of stator winding fault in induction motor using fuzzy logic", *Appl. Soft Computing*, vol. 8, no. 2, pp. 1112–1120, 2008.
- [43] O. Uyar y M. Çunkaş, "Design of fuzzy logic based motor protection system", en *6th Int. Advanced Technologies Symp.*, Elazig, 2011.
- [44] L. Escalona, C. Jiménez, A. Ferrera, y F. Arteaga, "Diseño de sistema para la detección de fallas en planta compresora con mantenimiento centrado en confiabilidad usando lógica difusa", *Revista ingeniería UC*, vol. 10, no. 1, pp. 21–28, 2003.
- [45] R. Hooshmand Y M. Banejad, "Application of fuzzy logic in fault diagnosis in transformers using dissolved gas based on different standards", *World Academy of Sci., Eng. Tech.*, vol. 17, 2006.
- [46] N. Kumawat, D. Nivea, y R. Chandralekha, "Mems based motor fault detection in windmill using neural networks", *Int. J. Research in Eng. Sci.*, vol. 2, no. 4, 2014.
- [47] Z. Zhang y K. Wang, "Wind turbine fault detection based on SCADA data analysis using ANN", *Advances in Manufacturing*, vol. 2, no. 1, pp. 70–78, 2014.
- [48] J. Peña y G. Zurita, "Vibration based reconstruction of the cylinder pressure in diesel engines by using neural networks", *Investigación & Desarrollo*, vol. 5, pp. 53–60, 2005.
- [49] Z. Tian y M. Zuo, "Health condition prediction of gears using a recurrent neural network approach", *IEEE Trans. Reliab.*, vol. 59, no. 4, pp. 700–705, 2010.
- [50] B. Wu, Z. Tian, y M. Chen, "Condition based maintenance optimization using neural network based health condition prediction" sin publicar.
- [51] Z. Tian, L. Wong, y N. Safaei, "A neural network approach for remaining useful life prediction utilizing both failure and suspension histories", *Mech. Syst. Signal Process.*, vol. 24, no. 5, pp. 1542–1555, 2010.
- [52] A. Ourici, "Fault classification of a doubly FED induction machine using neural

network”, *World Academy of Sci., Eng. Tech.*, vol. 30, pp. 1011–1014, 2009.

[53] J. Gómez, M. de Armas, J. Monteagudo, y F. Ramos, “Diagnóstico del mantenimiento centrado en la eficiencia de turbinas de contrapresión aplicando redes neuronales artificiales” sin publicar.

[54] Z. Wang, P. Willett, P. DeAguiar, y J. Webster, “Neural network detection of grinding burn from acoustic emission”, *Int. J. of Machine Tools and Manufacture*, vol. 41, no. 2, pp. 283–309, 2001.

[55] X. Hu, J. Vian, J. Slepiski, y D. Wunsch, “Vibration analysis via neural network inverse models to determine aircraft engine unbalance condition”, en *Proc. Int. Joint Conf. Neural Networks*, Portland, 2003.

[56] Y. L. Murphey, M. A. Masrur, Z. Chen, y B. Zhang, “Model-based fault diagnosis in electric drives using machine learning”, *IEEE Trans. Mechatron.*, vol. 11, no. 3, pp. 290–303, 2006.

[57] T. Aroui, Y. Koubaa, y A. Toumi, “Application of feedforward neural network for induction machine rotor faults diagnostics using stator current”, *J. Elect. Syst.*, vol. 3, pp. 213–226, 2007.

[58] B. Ayhan, M.-Y. Chow, y M.-H. Song, “Multiple discriminant analysis and neural-network-based monolith and partition fault-detection schemes for broken rotor bar in induction motors”, *IEEE Trans. Ind. Electron.*, vol. 53, no. 4, pp. 1298–1308, 2006.

[59] S. Kolla y S. Altman, “Artificial neural network based fault identification scheme implementation for a three-phase induction motor” sin publicar.

[60] Y. Mohamed, M. Tolba, A. El-Kafas, y A. Eisa, “artificial neural network for monitoring and diagnosis of external faults in three phase induction motor”, *Minia J. Eng. Tech.*, vol. 32, no. 2, pp. 130–148, 2012.

[61] S. Khomfoi y L. Tolbert, “Fault diagnostic system for a multilevel inverter using a neural network”, *IEEE Trans. Power Electron.*, vol. 22, no. 3, pp. 1062–1069, 2007.

[62] S. Guedidi, S. E. Zouzou, W. Laala, M. Sahraoui, y K. Yahia, “Broken bar fault diagnosis of induction motors using MCSA and neural network”, en *8th IEEE Symp. Diagnostics Elect. Machines, Power Electron. & Drives*, Bologna, 2011.

[63] A. Smith, D. Coit, y Y. Liang, “A neural network approach to condition based maintenance: case study of airport ground transportation vehicles” sin publicar.

[64] I. Onel, K. Dalci, y I. Senol, “Detection of bearing defects in three-phase induction motors using Park’s transform and radial basis function neural networks”, *Sadhana*, vol. 31, no. 3, pp. 235–244, 2006.

[65] Z. Wang, Z. Zhu, W. Li, G. Chen, y G. Zhou, “Total energy growth rate of rolling bearing due to faults during run-up”, *Advances in Mech. Eng.*, vol. 5, 2013.

[66] J. Morales, H. Noriega, R. Ríos, y C. Bastidas, “Diagnóstico de cinco condiciones de falla en rodamientos de bolas mediante una red neuronal” sin publicar.

[67] J. Zarei, “Induction motors bearing fault detection using pattern recognition techniques”, *Expert Syst. Applicat.*, vol. 39, no. 1, pp. 68–73, 2012.

[68] B. Sreejith, A. K. Verma, y A. Srividya, “Fault diagnosis of rolling element bearing using time-domain features and neural networks”, en *IEEE Region 10 and the 3rd Int. Conf. Industrial and Inform. Syst.*, Kharagpur, 2008.

[69] J. García-Prada, C. Castejón, y O. Lara, “Incipient bearing fault diagnosis using DWT for feature extraction”, en *12th IFToMM World Congr.*, Besançon, 2007.

[70] B. S. Yang, T. Han, y J. L. An, “ART-KOHONEN neural network for fault diagnosis of rotating machinery”, *Mech. Syst. Signal Process.*, vol. 18, no. 3, pp. 645–657, 2004.

[71] O. Lara, C. Castejón, y J. García, “Bearing Fault Diagnosis based on neural network classification and wavelet transform”, en *6th WSEAS Int. Conf. Wavelet Analysis & Multirate Syst.*, Bucharest, 2006.

[72] K. Al-Raheem y W. Abdul-Karem, “Rolling bearing fault diagnostics using artificial neural

- networks based on Laplace wavelet analysis”, *Int. J. of Eng., Sci. Tech.*, vol. 2, no. 6, pp. 278–290, 2010.
- [73] S. Singh y T. R. Murthy, “Neural network based sensor fault detection for flight control systems”, *Int. J. of Comput. Applicat.*, vol. 59, no. 13, pp. 1–8, 2012.
- [74] L. Cork, R. Walker, y S. Dunn, “Fault detection, identification and accommodation techniques for unmanned airborne vehicle” sin publicar.
- [75] M. Demetgul, I. N. Tansel, y S. Taskin, “Fault diagnosis of pneumatic systems with artificial neural network algorithms”, *Expert Syst. Applicat.*, vol. 36, no. 7, pp. 10512–10519, 2009.
- [76] J. A. Cadena, J. M. Cadena, y S. M. Pérez, “aplicación de redes neuronales probabilísticas en la detección de fallas incipientes en transformadores”, *Scientia et Technica*, vol. 14, no. 39, pp. 48–53, 2008.
- [77] M. Hajar, A. Raad, y M. Khalil, “Bearing and gear fault detection using artificial neural networks” sin publicar.
- [78] R. Yam, P. W. Tse, L. Li, y P. Tu, “Intelligent predictive decision support system for condition-based maintenance”, *Int. J. Advanced Manufacturing Tech.*, vol. 17, no. 5, pp. 383–391, 2001.
- [79] S. Wu, N. Gebraeel, M. Lawley, y Y. Yih, “A neural network integrated decision support system for condition-based optimal predictive maintenance policy”, *IEEE Trans. Syst. Man Cybern. A., Syst. Humans*, vol. 37, no. 2, pp. 226–236, 2007.
- [80] M. C. Garcia, M. Sanz-Bobi, y J. del Pico, “SIMAP: Intelligent System for Predictive Maintenance”, *Comput. Ind.*, vol. 57, no. 6, pp. 552–568, 2006.
- [81] J. Lee, J. Ni, D. Djurdjanovic, H. Qiu, y H. Liao, “Intelligent prognostics tools and e-maintenance”, *Comput. Ind.*, vol. 57, no. 6, pp. 476–489, 2006.
- [82] S. Su, W. Zhang, and S. Zhao, “Online fault prediction for nonlinear system based on sliding ARMA combined with online LS-SVR”, en *Proc. 33rd Chinese Control Conf.*, Nanjing, 2014.
- [83] X. Li, J. Qian, y G. Wang, “Fault prognostic based on hybrid method of state judgment and regression”, *Advances Mech. Eng.*, vol. 5, pp. 1–10, 2013.
- [84] C. S. Byington, M. Watson, y D. Edwards, “Data-driven neural network methodology to remaining life predictions for aircraft actuator components”, en *IEEE Aerospace Conf. Proc. (IEEE Cat. No.04TH8720)*, Big Sky, 2004.
- [85] K. Mollazade, H. Ahmadi, M. Omid, y R. Alimardani, “An intelligent model based on data mining and fuzzy logic for fault diagnosis of external gear hydraulic pumps”, *Insight*, vol. 51, no. 11, pp. 594–600, 2009.
- [86] C. Lu, N. Ma, y Z. Wang, “Fault detection for hydraulic pump based on chaotic parallel RBF network”, *EURASIP J. Advances in Signal Process.*, vol. 2011, no. 1, 2011.
- [87] I. Moreno, A. Álvares, y L. Alape, “methodology for the building of a fuzzy expert system for predictive maintenance of hydroelectric power plants”, en *ABCM Symp. Series in Mechatronics*, vol. 5, 2012.
- [88] V. T. Tran, B. Yang, y A. Tan, “Multi-step ahead direct prediction for the machine condition prognosis using regression trees and neuro-fuzzy systems”, *Expert Syst. Applicat.*, vol. 36, no. 5, pp. 9378–9387, 2009.
- [89] R. Ziani, A. Felkaoui, y R. Zegadi, “Gear fault detection using supports vector machine (SVM) & genetic algorithms: application to automated vibration diagnosis” sin publicar.
- [90] J. Rafiee, P. W. Tse, A. Harifi, and M. H. Sadeghi, “A novel technique for selecting mother wavelet function using an intelligent fault diagnosis system”, *Expert Syst. Applicat.*, vol. 36, no. 3, pp. 4862–4875, 2009.
- [91] E. Ebrahimi, “Faults detection of gearbox of MF285 tractor based on wavelet packet transform and ANFIS”, *J. of Appl. Sci. Agriculture*, vol. 9, no. 2, pp. 719–727, 2014.
- [92] C. Chen, B. Zhang, G. Vachtsevanos, y M. Orchard, “Machine condition prediction based on adaptive neuro-fuzzy and high-order particle

- filtering”, *IEEE Trans. Ind. Electron.*, vol. 58, no. 9, pp. 4353–4364, 2011.
- [93] R. B. Chinnam y P. Baruah, “A neuro-fuzzy approach for estimating mean residual life in condition-based maintenance systems”, *Int. J. of Materials and Product Technology*, vol. 20, no. 1–3, 2004.
- [94] Z. Li, X. Yan, Z. Guo, Y. Zhang, y C. Yuan, “Condition monitoring and fault diagnosis for marine diesel engines using information fusion techniques”, *Electron. Elect. Eng.*, vol. 7, no. 123, pp. 109–112, 2012.
- [95] Y. Zhang, Z. Zhao, y Z. Wang, “Comprehensive detection and isolation of fault in complicated electrical engineering”, *Electron. Elect. Eng.*, vol. 19, no. 9, pp. 31–34, 2013.
- [96] X. Li y D. Yang, “SVM optimization based on BFA and its application in AE rotor crack fault diagnosis”, *J. of Comput.*, vol. 6, no. 10, pp. 2084–2091, 2011.
- [97] A. Andre, E. Beltrame, y J. Wainer, “A combination of support vector machine and k-nearest neighbors for machine fault detection” sin publicar.
- [98] W. Hu, L. Fu, y H. Zhang, “BP network for diagnosing rotor broken fault based on a new PSO”, *J. Software*, vol. 8, no. 8, pp. 1960–1967, 2013.
- [99] T. Han, B. Yang, W. Choi, y J. Kim, “Fault diagnosis system of induction motors based on neural network and genetic algorithm using stator current signals”, *Int. J. Rotating Machinery*, vol. 2006, pp. 1–13, 2006.
- [100] D. Leite, R. Attux, F. Von Zuben, P. Costa Jr, y F. Gomide, “Evolutionary neural network applied to induction motors stator fault detection”, en *IEEE Int. Electric Machines & Drives Conf.*, Miami, 2009.
- [101] B. Yang, T. Han, y Y. Kim, “Integration of ART-Kohonen neural network and case-based reasoning for intelligent fault diagnosis”, *Expert Syst. Applicat.*, vol. 26, no. 3, pp. 387–395, 2004.
- [102] M. Dong, T. Cheang, y S. Chan, “On-line fast motor fault diagnostics based on fuzzy neural networks”, *Tsinghua Science and Technology*, vol. 14, no. 2, pp. 225–233, 2009.
- [103] D. Dey, P. Duttagupta, y S. Sengupta, “Mechanical fault diagnostics for electromechanical devices using ANFIS”, *Int. J. of Appl. Eng. Research*, vol. 4, no. 8, pp. 1489–1498, 2009.
- [104] E. Ebrahimi y K. Mollazade, “Intelligent fault classification of a tractor starter motor using vibration monitoring and adaptive neuro-fuzzy inference system”, *Insight - Non-Destructive Testing and Condition Monitoring*, vol. 52, no. 10, pp. 561–566, 2010.
- [105] V. T. Tran, B. Yang, M. Oh, y A. Tan, “Fault diagnosis of induction motor based on decision trees and adaptive neuro-fuzzy inference”, *Expert Syst. Applicat.*, vol. 36, no. 2, pp. 1840–1849, 2009.
- [106] S. M. Ahmed, H. Abu-Rub, S. Refaat, y A. Iqbal, “Diagnosis of stator turn-to-turn fault and stator voltage unbalance fault using ANFIS”, *Int. J. of Elect. Comput. Eng. (IJECE)*, vol. 3, no. 1, pp. 129–135, 2012.
- [107] H. Lee, D. Park, B. Ahn, Y. Park, J. Park, y S. S. Venkata, “A fuzzy expert system for the integrated fault diagnosis”, *IEEE Trans. Power Del.*, vol. 15, no. 2, pp. 833–838, 2000.
- [108] A. Aboshosha, “Neurofuzzy computing aided fault diagnosis of nuclear power reactors”, en *7th ICEENG Conference*, Cairo, 2010.
- [109] H. Lee, N. Nguyen, y J. Kwon, “Bearing Fault Diagnosis Using Fuzzy Inference Optimized by Neural Network and Genetic Algorithm”, *J. Elect. Eng. Technology*, vol. 2, no. 3, pp. 353–357, 2007.
- [110] A. Saxena y A. Saad, “Evolving an artificial neural network classifier for condition monitoring of rotating mechanical systems”, *J. Appl. Soft Computing*, vol. 7, no. 1, pp. 441–454, 2007.
- [111] M. Sanz.Bobi, R. Palacios, A. Muñoz, R. García, M. Pérez, y A. Matesanz, “ISPMAT: sistema inteligente de mantenimiento predictivo aplicado a trenes”, *Ingeniería y gestión de mantenimiento*, vol. 30, pp. 41–46, 2003.
- [112] “Device-to-Business (D2B)™ Platform”. [En línea]. Disponible en: www.imscenter.net/front-

page/Resources/D2B.pdf. [Revisado: 05-Ene-2015].