

**UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ
CÂMPUS CORNÉLIO PROCÓPIO
DIRETORIA DE PESQUISA E PÓS-GRADUAÇÃO
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA
MESTRADO EM ENGENHARIA ELÉTRICA**

EDUARDO DE ANDRADE NOGUEIRA

**APLICAÇÃO DA REDE NEURAL CONVOLUCIONAL PARA A EXTRAÇÃO DE
CARACTERÍSTICAS E CLASSIFICAÇÃO DE FALHAS NO MOTOR DE
INDUÇÃO TRIFÁSICO**

DISSERTAÇÃO

**CORNÉLIO PROCÓPIO
2020**

Dados Internacionais de Catalogação na Publicação

N778 Nogueira, Eduardo de Andrade

Aplicação da rede neural convolucional para a extração de características e classificação de falhas no motor de indução trifásico / Eduardo de Andrade Nogueira. – 2020.

103 f. : il. color. ; 31 cm.

Orientador: Alessandro Goedtel.

Coorientador: Marcelo Favoretto Castoldi.

Dissertação (Mestrado) – Universidade Tecnológica Federal do Paraná. Programa de Pós-Graduação em Engenharia Elétrica. Cornélio Procópio, 2020.

Bibliografia: p. 80-84.

1. Motores elétricos de indução. 2. Convoluçãoes (Matemática). 3. Redes neurais (Computação). 4. Localização de falhas (Engenharia). 5. Engenharia Elétrica – Dissertações. I. Goedtel, Alessandro, orient. II. Castoldi, Marcelo Favoretto, coorient. III. Universidade Tecnológica Federal do Paraná. Programa de Pós-Graduação em Engenharia Elétrica. IV. Título.

CDD (22. ed.) 621.3

Biblioteca da UTFPR - Câmpus Cornélio Procópio

Bibliotecário/Documentalista responsável:
Romeu Righetti de Araujo – CRB-9/1676



TERMO DE APROVAÇÃO

Título da Dissertação Nº 060:

“Aplicação da Rede Neural Convolucional para a Extração de Características e Classificação de Falhas no Motor de Indução Trifásico”.

por

Eduardo de Andrade Nogueira

Orientador: Prof. Dr. Alessandro Goedtel

Co-orientador: Prof. Dr. Marcelo Favoretto Castoldi

Esta dissertação foi apresentada como requisito parcial à obtenção do grau de MESTRE EM ENGENHARIA ELÉTRICA – Área de Concentração: Sistemas Eletrônicos Industriais, pelo Programa de Pós-Graduação em Engenharia Elétrica – PPGEE – da Universidade Tecnológica Federal do Paraná – UTFPR – Câmpus Cornélio Procópio, às 14 horas do dia 14 de abril de 2020. O trabalho foi _____ pela Banca Examinadora, composta pelos professores:

Prof. Dr. Alessandro Goedtel
Presidente

Prof. Dr. Paulo Rogério Scalassara
UTFPR-CP

Prof. Dr. Carlos Nascimento Silla Júnior
PUC-PR

Visto da coordenação:

Prof. Dr. Leonardo Poltronieri Sampaio
Coordenador do Programa de Pós-Graduação em Engenharia Elétrica
UTFPR Câmpus Cornélio Procópio

A Folha de Aprovação assinada encontra-se na Coordenação do Programa.

AGRADECIMENTOS

Venho trazer meu sincero agradecimento a todos os que fizeram parte desta etapa da minha vida. Desde já peço desculpas de alguma omissão pois muitos fizeram parte e todos tiveram uma importância enorme para mim.

Em primeiro lugar, gostaria de agradecer o apoio da minha família, Silvia Osório de Andrade Nogueira, Mario Henrique Nogueira e Henrique de Andrade Nogueira, por estarem sempre do meu lado me apoiando nos momentos difíceis.

Agradeço a Bruna Almeida Osti, minha namorada pela paciência que teve durante todo esse processo, e principalmente por sempre me acompanhar.

Agradeço ao meu orientador Prof. Dr. Alessandro Goedtel e coorientador Prof. Dr Marcelo Favoretto Castoldi por ter me guiado no decorrer deste trabalho com toda experiência e sabedoria.

Agradeço aos meus amigos que me acompanharam durante todo o mestrado, o tornando muito mais leve.

Agradeço aos órgãos e agência de fomento a pesquisa que apoiam o Laboratório de Sistema Inteligentes - LSI, Fundação Araucária de Apoio ao Desenvolvimento Científico e Tecnológico do Paraná processo (38406/56093-3) e Conselho Nacional de Desenvolvimento Científico e Tecnológico - CNPq processos (474290/2008-3, 473576/2011-2, 552269/2011-5, 307220/2016-8) e ao uso das facilidades computacionais do CCCT-CP, UTFPR.

Agradeço a CAPES pela bolsa concedida a mim durante todo o mestrado por meio do Programa de Demanda Social (DS), processo número, 88882.432135/2019-01 (Migrado - SACPAIS).

Enfim, obrigado a todos que me apoiaram e estiveram do meu lado ao longo dessa etapa da minha vida.

Do or do not, there is no try
- Mestre Yoda

E ainda que tivesse o dom de profecia, e conhecesse todos os mistérios
e toda a ciência, e ainda que tivesse toda a fé, de maneira tal que
transportasse os montes, e não tivesse amor, nada seria.
- Coríntios 13:2

RESUMO

NOGUEIRA, E. A.. **Aplicação da rede neural convolucional para a extração de características e classificação de falhas no motor de indução trifásico.** 2020. 102 f. Dissertação – Programa de Pós-Graduação em Engenharia Elétrica, Universidade Tecnológica Federal do Paraná. Cornélio Procópio, 2020.

O Motor de Indução Trifásico é o principal elemento de conversão eletromecânica de energia na indústria. Assim devido ao desgaste e a problemas de qualidade de energia este motor pode apresentar falhas e assim levar a parada inesperada nos processos industriais. Este trabalho apresenta uma metodologia alternativa para a extração de características de falhas dos sinais de tensão e corrente das três fases de alimentação do motor de indução trifásico utilizando a rede neural convolucional. Os dados utilizados neste trabalho são provenientes de ensaios experimentais em laboratório, onde as falhas foram introduzidas artificialmente no motor. Estes testes foram realizados com os dados com as taxas amostrais de 15ksps, 7,5ksps, 3ksps e 1,5ksps, utilizando quatro classificadores de padrão, a saber: Perceptron MultiCamadas, Naive Bayes, Máquina de Vetor de Suporte e K-Próximos Vizinhos. Os resultados obtidos demonstram que a estratégia proposta nesta dissertação mostrou-se viável para a classificação de falhas no motor de indução trifásico.

Palavras-chave: Motor de indução trifásico; Rede neural convolucional; Reconhecimento de padrões; Identificação de falha em motores; Redes neurais profundas

ABSTRACT

NOGUEIRA, E. A. Convolutional neural network application for fault extraction and classification in three-phase induction motor. 2020. 102 f. Master Thesis – Electrical Engineering Graduate Program, Federal University of Technology - Paraná. Cornélio Procópio, 2020.

The three-phase induction motor is the main element of electromechanical energy conversion in the industry. Thus, due to wear and power quality problems, this engine may fail and thus lead to an unexpected stop in industrial processes. This work presents an alternative methodology for the extraction of fault characteristics from the voltage and current signals of the three phase phases of the three-phase induction motor using the convolutional neural network. The data used in this work come from experimental tests in the laboratory, where the faults were artificially introduced in the motor. These tests were performed with data with sample rates of 15ksps, 7.5ksps, 3ksps and 1.5ksps, using four standard classifiers, namely: Perceptron Multi-Layer, Naive Bayes, Support Vector Machine and K-Nearest Neighbors. The results obtained demonstrate that the strategy proposed proved to be viable for the classification of failures in the three-phase induction motor.

Keywords: Three phase induction motor; Convolutional neural network; Pattern recognition; Motor failure identification; Deep neural network

LISTA DE FIGURAS

FIGURA 1 – Curto circuito entre espiras.	23
FIGURA 2 – Elementos internos de um rolamento.	25
FIGURA 3 – Aplicação da operação de convolução.	30
FIGURA 4 – Exemplo Pooling.	31
FIGURA 5 – Função de ativação ReLU	33
FIGURA 6 – Exemplo Softmax	34
FIGURA 7 – Exemplo classificador k - Vizinhos mais Próximos	36
FIGURA 8 – Modelo neurônio artificial.	37
FIGURA 9 – Ilustração da rede <i>Perceptron Multicamadas</i> (PMC).	38
FIGURA 10 – Bancada de testes Laboratório de Sistemas Inteligentes (LSI).	42
FIGURA 11 – Formas de onda da base de dados.	44
FIGURA 12 – Motor com falha de estator.	44
FIGURA 13 – Rotor com quatro barras quebradas.	45
FIGURA 14 – Rolamento com desgaste.	47
FIGURA 15 – Etapas da implementação dos testes.	47
FIGURA 16 – Redução da taxa amostral da base de dados.	49
FIGURA 17 – Normalização dos dados.	49
FIGURA 18 – Janelamento dos dados.	50
FIGURA 19 – Técnica de validação <i>K-Folds</i> .	51
FIGURA 20 – Estrutura das camadas de extração de características e do classificador PMC.	52
FIGURA 21 – Fluxograma geral da estrutura dos classificadores.	54
FIGURA 22 – Comparativo - Classificação de falha - Motor de 1cv - Atributos de tensão e corrente.	56
FIGURA 23 – Comparativo - Classificação de falha - Motor de 2cv - Atributos de tensão e corrente.	57
FIGURA 24 – Comparativo - Classificação de falha - Motor de 1cv - Atributos de corrente.	58
FIGURA 25 – Comparativo - Classificação de falha - Motor de 2cv - Atributos de corrente.	59
FIGURA 26 – Comparativo - Classificação de falha - Teste de generalização entre motores - Treinamento com motor de 1cv e Teste com motor de 2cv - Atributos de tensão e corrente.	60
FIGURA 27 – Comparativo - Classificação de falha - Teste de generalização entre motores - Treinamento com motor de 2cv e Teste com motor de 1cv - Atributos de tensão e corrente.	61
FIGURA 28 – Comparativo - Classificação de falha - Teste de generalização entre motores - Treinamento com motor de 1cv e Teste com motor de 2cv - Atributos de corrente.	62
FIGURA 29 – Comparativo - Classificação de falha - Teste de generalização entre motores - Treinamento com motor de 2cv e Teste com motor de 1cv - Atributos de corrente.	63
FIGURA 30 – Comparativa - Classificação de nível de severidade - Falha de estator - Motor de 1cv - Atributos de tensão e corrente.	64
FIGURA 31 – Comparativo - Classificação de nível de severidade - Falha de estator - Motor de 2cv - Atributos de tensão e corrente.	65
FIGURA 32 – Comparativo - Classificação de nível de severidade - Falha de estator - Motor de 1cv - Atributos de corrente.	66

FIGURA 33 – Comparativo - Classificação de nível de severidade - Falha de estator - Motor de 2cv - Atributos de corrente.	67
FIGURA 34 – Comparativo - Classificação de nível de severidade - Falha de rotor - Motor de 1cv - Atributos de tensão e corrente.	68
FIGURA 35 – Comparativo - Classificação de nível de severidade - Falha de rotor - Motor de 2cv - Atributos de tensão e corrente.	69
FIGURA 36 – Comparativo - Classificação de nível de severidade - Falha de rotor - Motor de 1cv - Atributos de corrente.	70
FIGURA 37 – Comparativo - Classificação de nível de severidade - Falha de rotor - Motor de 2cv - Atributos de corrente.	70
FIGURA 38 – Comparativo - Classificação de nível de severidade - Falha de rolamento - Motor de 1cv - Atributos de tensão e corrente.	71
FIGURA 39 – Comparativo - Classificação de nível de severidade - Falha de rolamento - Motor de 2cv - Atributos de tensão e corrente.	72
FIGURA 40 – Comparativo - Classificação de nível de severidade - Falha de rolamento - Motor de 1cv - Atributos de corrente.	73
FIGURA 41 – Comparativo - Classificação de nível de severidade - Falha de rolamento - Motor de 2cv - Atributos de corrente.	74

LISTA DE TABELAS

TABELA 1 – Estatística de falhas no Motor de Indução Trifásico (MIT)	22
TABELA 2 – Interpretação índice <i>Kappa</i>	41
TABELA 3 – Quantidade de ciclos por taxa amostral no janelamento	50
TABELA 4 – Estrutura das topologias de extração de características	52
TABELA 5 – Estrutura das topologias convolucionais	53
TABELA 6 – Melhores topologias - Classificação de Falha - Atributos de tensão e corrente	56
TABELA 7 – Melhores topologias - Classificação de Falha - Atributos de corrente	58
TABELA 8 – Melhores topologias - Classificação de Falha - Teste de generalização - Atributos de tensão e corrente	60
TABELA 9 – Melhores topologias - Classificação de Falha - Teste de generalização - Atributos de corrente	61
TABELA 10 – Melhores topologias - Classificação de nível de severidade - Falha de Estator - Atributos de tensão e corrente - <i>K-Folds</i>	64
TABELA 11 – Melhores topologias - Classificação de nível de severidade - Falha de Estator - Atributos de corrente - <i>K-Folds</i>	66
TABELA 12 – Melhores topologias - Classificação de nível de severidade - Falha de Rotor - Atributos de tensão e corrente - <i>K-Folds</i>	68
TABELA 13 – Melhores topologias - Classificação de nível de severidade - Falha de Rotor - Atributos de corrente - <i>K-Folds</i>	69
TABELA 14 – Melhores topologias - Classificação de nível de severidade - Falha de Rolo-mento - Atributos de tensão e corrente - <i>K-Folds</i>	71
TABELA 15 – Melhores topologias - Classificação de nível de severidade - Falha de Rola-mento - Atributos de corrente - <i>K-Folds</i>	73
TABELA 16 – Comparativo da classificação de falha na literatura	75
TABELA 17 – Métricas de desempenho - Classificação de Falha - 15ksps	85
TABELA 18 – Desvio Padrão - Classificação de Falha - 15ksps	85
TABELA 19 – Métricas de desempenho - Classificação de Falha - 7,5ksps	86
TABELA 20 – Desvio Padrão - Clássificação de Falha - 7,5ksps	86
TABELA 21 – Métricas de desempenho - Classificação de Falha - 3ksps	87
TABELA 22 – Desvio Padrão - Clássificação de Falha - 3ksps	87
TABELA 23 – Métricas de desempenho - Classificação de Falha - 1,5ksps	88
TABELA 24 – Desvio Padrão - Clássificação de Falha - 1,5ksps	88
TABELA 25 – Métrica de desempenho - Classificação de Falha - 15ksps - Validação Cruzada	89
TABELA 26 – Métrica de desempenho - Classificação de Falha - 7,5ksps	89
TABELA 27 – Métrica de desempenho - Classificação de Falha - 3ksps	90
TABELA 28 – Métrica de desempenho - Classificação de Falha - 1,5ksps	90
TABELA 29 – Métrica de desempenho - Classificação de nível de severidade para falha de estator - 15ksps	91
TABELA 30 – Desvio Padrão - Classificação de nível de severidade para falha de estator - 15ksps	91
TABELA 31 – Métrica de desempenho - Classificação de nível de severidade para falha de estator - 7,5ksps	92
TABELA 32 – Desvio Padrão - Classificação de nível de severidade para falha de estator - 7,5ksps	92
TABELA 33 – Métrica de desempenho - Classificação de nível de severidade para falha de estator - 3ksps	93

TABELA 34 – Desvio Padrão - Classificação de nível de severidade para falha de estator - 3ksp	93
TABELA 35 – Métrica de desempenho - Classificação de nível de severidade para falha de estator - 1,5ksp	94
TABELA 36 – Desvio Padrão - Classificação de nível de severidade para falha de estator - 1,5ksp	94
TABELA 37 – Métricas de desempenho - Classificação de nível de severidade da falha de rotor - 15ksp	95
TABELA 38 – Desvio Padrão - Classificação de nível de severidade da falha de rotor - 15ksp	95
TABELA 39 – Métricas de desempenho - Classificação de nível de severidade da falha de rotor - 7,5ksp	96
TABELA 40 – Desvio Padrão - Classificação de nível de severidade da falha de rotor - 7,5ksp	96
TABELA 41 – Métricas de desempenho - Classificação de nível de severidade da falha de rotor - 3ksp	97
TABELA 42 – Desvio Padrão - Classificação de nível de severidade da falha de rotor - 3ksp	97
TABELA 43 – Métricas de desempenho - Classificação de nível de severidade da falha de rotor - 1,5ksp	98
TABELA 44 – Desvio Padrão - Classificação de nível de severidade da falha de rotor - 1,5ksp	98
TABELA 45 – Métricas de desempenho - Classificação de falha de rolamento - 15ksp	99
TABELA 46 – Desvio padrão - Classificação de falha de rolamento - 15ksp	99
TABELA 47 – Métricas de desempenho - Classificação de falha de rolamento - 7,5ksp	100
TABELA 48 – Desvio padrão - Classificação de falha de rolamento - 7,5ksp	100
TABELA 49 – Métricas de desempenho - Classificação de falha de rolamento - 3ksp	101
TABELA 50 – Desvio padrão - Classificação de falha de rolamento - 3ksp	101
TABELA 51 – Métricas de desempenho - Classificação de falha de rolamento - 1,5ksp	102
TABELA 52 – Desvio padrão - Classificação de falha de rolamento - 1,5ksp	102

LISTA DE QUADROS

QUADRO 1 – Distribuição dos atributos das bases de dados de falha no MIT de 1cv e 2cv.	43
QUADRO 2 – Definição das taxas amostrais	48

LISTA DE ABREVIATURAS

AC Acurácia

ECG Eletrocardiograma

EEG Eletroencefalograma

F1 Pontuação F1

GNB *Gaussian Naive Bayes*

KNN *K-Nearest Neighbors*

LDA *Linear Discriminant Analysis*

LSI Laboratório de Sistemas Inteligentes

LSTM *Long Short-Term Memory*

MIT Motor de Indução Trifásico

PCA *Principal Component Analysis*

PMC *Perceptron Multicamadas*

PR Precisão

RE *Recall*

RNA Rede Neural Artificial

ReLU *Rectified Linear Unit*

SNE *Stochastic Neighbor Embedding*

SVM *Support Vector Machine*

t-SNE *t-Distributed Stochastic Neighbor Embedding*

LISTA DE SÍMBOLOS

$V_{ab,bc,ca}$	Tensões de linha de alimentação do motor
$I_{a,b,c}$	Correntes de fase da alimentação do motor
f_{st}	Frequências da falha de estator
f_{bb}	Frequências da falha de rotor
f_{orf}	Frequência da falha de rolamento
f_s	Frequência fundamental de alimentação do motor
m, p, k	Coeficientes
s	Esorregamento do motor
ω_{in}	Velocidade do rolamento
α	Ângulo de contato
d	Diâmetro da esfera do rolamento
D	Diâmetro da fissura no rolamento
N_b	Número de esferas no rolamento
x, ω	Funções
I	Amostra de dados
K_r	Kernel
$A_{i,j}$	Matriz original
$B_{i,j}$	Matriz após pooling
\max, \min	Função de máximo e mínimo
$P(a b)$	Probabilidade de a dado b verdadeiro
$P(a)$	Probabilidade de a ocorrer
$d(x, y)$	Distância euclidiana
x_i, y_i	Pontos de dados
u	Potêncial de ativação
w_i	Matriz de pesos sinápticos
y	Sinal de saída
$g(u)$	Função de ativação
$\Phi(\mathbf{w})$	Custo SVM
AC	Acurácia
PR	Precisão
RE	Recall
$F1$	Pontuação F1
$KAPPA$	Índice kappa
TP	Verdadeiros positivos
TN	Verdadeiros negativos

FP	Falsos positivos
FN	Falsos negativos
p_o	Concordância relativa para o índice kappa
p_e	Probabilidade hipotética para o índice kappa
n_{rd}	Taxa de redução amostral
x_{max}, x_{min}	Valor máximo e mínimo de cada atributo para normalização
F	Numero de filtros
KS	Tamanho do kernel
AF	Função de ativação
OS	Tamanho do pool
NN	Número de neurônios
Conv1D	Camada convolucional
MaxPooling1D	Camada de pooling
Flatten	Camada de achatamento
Dense	Camada neural totalmente conectada
K	Número de folds
\bar{P}	Média das métricas de desempenho
P_i	Métricas de desempenho
d_P	Desvio padrão da métrica de desempenho
p	Número de pares de polos do motor de indução trifásico

SUMÁRIO

1	INTRODUÇÃO	18
1.1	MÁQUINAS ELÉTRICAS	18
1.2	FALHAS EM MÁQUINAS ELÉTRICAS	18
1.3	REDES NEURAIS CONVOLUCIONAIS	19
1.4	MOTIVAÇÃO	20
1.5	OBJETIVOS	20
1.5.1	Objetivos Específicos	21
1.6	ORGANIZAÇÃO DO TEXTO	21
2	FALHA EM MÁQUINAS ELÉTRICAS	22
2.1	MOTOR DE INDUÇÃO TRIFÁSICO	22
2.2	FALHAS NO MOTOR DE INDUÇÃO TRIFÁSICO	22
2.2.1	Falhas de Estator	23
2.2.2	Falhas de Rotor	24
2.2.3	Falhas de Rolamento	25
2.3	CONCLUSÃO DO CAPÍTULO	27
3	ALGORITMOS INTELIGENTES	28
3.1	REDES NEURAIS PROFUNDAS	28
3.1.1	Redes Convolucionais	28
3.1.1.1	Camada Convolucional	29
3.1.1.2	Camada de <i>Pooling</i>	31
3.1.1.3	Funções de ativação	32
3.2	CLASSIFICADORES DE PADRÕES	34
3.2.1	Classificador de Naive Bayes	35
3.2.2	<i>k</i> - Vizinhos mais Próximos	35
3.2.3	Perceptron Multicamadas	36
3.2.4	Máquina de Vetor de Suporte	38
3.3	ANÁLISE DA PERFORMANCE DOS CLASSIFICADORES	39
3.3.1	Métricas de Performance	39
3.4	CONCLUSÃO DO CAPÍTULO	41
4	METODOLOGIA	42
4.1	BASE DE DADOS	42
4.1.1	Falha de estator	43
4.1.2	Falha de rotor	45
4.1.3	Falha de rolamento	46
4.2	IMPLEMENTAÇÃO DOS TESTES	46
4.2.1	Pré-processamento de dados	47
4.2.1.1	Redução da taxa amostral	48
4.2.1.2	Normalização	48
4.2.1.3	Janelamento	49
4.2.1.4	Separação da base de dados	50
4.2.2	Desenvolvimento das topologias de extração de características	51
4.2.3	Desenvolvimento dos classificadores	53
4.3	CONCLUSÃO DO CAPÍTULO	53
5	RESULTADOS E DISCUSSÕES	55
5.1	ANÁLISE GLOBAL DOS RESULTADOS	55

5.1.1	Classificação de falha	55
5.1.1.1	Métricas de teste K-Folds	55
5.1.1.2	Métricas do teste de generalização	59
5.1.2	Classificação de nível de severidade	63
5.1.2.1	Falha de estator	63
5.1.2.2	Falha de rotor	67
5.1.2.3	Falha de rolamento	70
5.2	DISCUSSÕES	74
5.2.1	Taxa amostral e Atributos	74
5.2.2	Topologias e Classificadores	75
5.3	CONCLUSÃO DO CAPÍTULO	75
6	CONCLUSÃO	77
6.1	PERSPECTIVAS DE TRABALHOS FUTUROS	78
	REFERÊNCIAS	79

1 INTRODUÇÃO

1.1 MÁQUINAS ELÉTRICAS

As máquinas elétricas rotativas desempenham um papel fundamental na indústria moderna atuando na conversão eletromecânica de energia. O motor elétrico está presente em diversos equipamentos tais como compressores, esteiras, tornos, dentre outros. Sua importância consiste no fato de consumir de 44% à 46% de toda energia elétrica produzida no âmbito mundial (WAIDE; BRUNNER, 2011).

Dentre os motores elétricos, o Motor de Indução Trifásico (MIT) é amplamente utilizado na indústria devido ao seu baixo custo, robustez e pouca necessidade de manutenção. Ainda, pode-se citar como outra vantagem a possibilidade de controlar sua velocidade quando acionado por um inversor de frequência, possibilitando sua aplicação em uma maior gama de processos (TRZYNADLOWSKI, 2000).

1.2 FALHAS EM MÁQUINAS ELÉTRICAS

O MIT, assim como a maioria dos equipamentos, está sujeito à falhas o que pode ser definido como uma discrepância do funcionamento normal. A parada inesperada de um motor na indústria pode acarretar em acidentes aos funcionários que estão em contato direto com as máquinas e levar a interrupção da linha de produção resultando em prejuízo tanto à empresa quanto a seus acionistas.

Nos últimos anos diversos esforços foram despendidos na predição de falhas nos motores elétricos antes que venham a causar a parada desta máquina em uma linha de produção. Segundo SINGH e KAZZAZ (2003), as falhas no MIT estão distribuídas nas seguintes proporções: rolamento (42%), estator (28%), rotor (8%) e demais falhas¹ (22%). Observa-se que o conjunto das falhas de rolamento, estator e rotor compõem (78%) das falhas apresentados no MIT e, por conta disso, a maioria das técnicas de classificação de falhas focam nestes três defeitos.

Os principais sensores usados no contexto do diagnóstico de falhas no motor de indução trifásico são: i) vibração, ii) temperatura, iii) acústicos, iv) tensão, v) corrente de linha de alimentação do motor, dentre outros. Neste contexto o diagnóstico de falhas a partir da tensão e corrente de alimentação do motor possui a vantagem de detectar todos os tipos de falhas. Já o diagnóstico por meio do sinal de vibração e temperatura apresentam um baixo custo comparado aos sensores de corrente, mas são limitados quanto a quais falhas eles são capazes de classificar e também o mal posicionamento dos sensores pode levar a erros adicionais causados pela vibração de outros equipamentos conectados ao motor (CORNE et al., 2015).

Dentre as diversas estratégias para identificação de falhas propostas, segundo ZHAO et al. (2019), podemos classificá-las em duas categorias, a saber: i) os métodos clássicos que se baseiam na variação dos parâmetros internos do motor para identificar a discrepância no

¹ventilador, caixa de ligação, defeitos estruturais, falhas não determinadas

funcionamento e ii) os métodos inteligentes que se baseiam na análise de dados e no aprendizado de máquina os quais podem ser divididos em clássicos e de aprendizado profundo.

As estratégias de diagnóstico de falhas em máquinas elétricas rotativas baseadas no aprendizado profundo apresentam algumas vantagens quando comparadas aos outros métodos. Na referida metodologia não é necessária a extração manual dos parâmetros internos bem como dos atributos, diferentemente do método de aprendizado clássico. Ainda, pode-se citar que o método dispensa algumas etapas extras como os exigidos pelos métodos de aprendizado clássicos tais como *Principal Component Analysis* (PCA) e *Linear Discriminant Analysis* (LDA) alem de possibilitar seu uso com um grande volume de dados (LIU et al., 2018).

Com os novos conceitos da indústria 4.0 onde todos os processos estarão interligados, trabalhando e produzindo um grande volume de dados e com a interação humana limitada entre estes processos, faz-se necessária a aplicação de novas abordagens para a análise e a operação destas informações. Neste contexto os métodos inteligentes de classificação de falhas baseados no aprendizado profundo começaram a ganhar destaque frente aos métodos clássicos por apresentarem maior robustez (ZABINSKI et al., 2019). Dentre as técnicas de aprendizado profundo pode-se citar as: i) Redes Neurais Convolucionais, ii) Redes *Long Short-Term Memory* (LSTM), iii) Redes Totalmente Conectadas conforme SAINATH et al. (2015).

Assim, este trabalho apresenta uma metodologia alternativa voltada a aplicação prática, buscando estudar a classificação das falhas no MIT e o nível de severidade em que estas falhas se encontram utilizando diferentes taxas amostrais bem como a classificação de padrões de falhas com uma menor quantidade de sensores.

1.3 REDES NEURAIS CONVOLUCIONAIS

Dentro da categoria de redes neurais profundas temos as rede neurais convolucionais as quais são o principal instrumento de estudo deste trabalho. Estas redes são amplamente utilizadas em aplicações de visão computacional e análise de sinais biológicos devido a sua alta capacidade de analisar grandes volumes de dados. Neste sentido, tem-se as seguintes aplicações relatadas na literatura:

- **Classificação de Imagens**

A primeira aplicação de uma rede neural convolucional foi no trabalho de LECUN et al. (2001), onde, por meio da operação matemática da convolução com filtros treinados foi, possível extrair e classificar caracteres escritos a mão. Ainda no trabalho de SIMONYAN e ZISSERMAN (2015), foi desenvolvido uma rede convolucional capaz de classificar mil classes de imagens diferentes.

- **Processamento de Sinal Biológico**

No artigo de KIRANYAZ, INCE e GABBOUJ (2016), os autores apresentaram uma metodologia para a extração de características de um sinal de Eletrocardiograma (ECG), referente

a cinco diferentes classes de batimentos cardíacos. Já no trabalho de MOON, JANG e LEE (2018) por meio do sinal de Eletroencefalograma (EEG) os autores foram capazes de classificar as emoções dos pacientes.

- **Reconhecimento de atividade humana**

No trabalho de IGNATOV (2018), o autor foi capaz de classificar quais atividades estavam sendo realizadas por uma pessoa tais como: caminhada, corrida, sentado, dentre outras classes², por meio de uma rede convolucional e do sinal de um acelerômetro.

- **Identificação de som**

No trabalho de PICZAK (2015), utiliza-se uma rede neural convolucional para extrair as características e classificar dez diferentes sons urbanos.

No contexto deste trabalho a aplicação da rede convolucional tem como objetivo a extração de características da forma de onda de tensão e de corrente de linha do MIT auxiliando os classificadores no diagnóstico de falhas.

1.4 MOTIVAÇÃO

Neste contexto, este trabalho consiste em trazer uma metodologia alternativa para classificação de falhas no MIT buscando viabilizar a implementação da estratégia apresentando quatro estudos que podem ser resumido aos seguintes questionamentos:

- i Com a redução da taxa amostral é possível a classificação de falha e nível de severidade no MIT ?
- ii Com a redução dos sensores é possível a classificação de falha e nível de severidade no MIT ?
- iii Qual a melhor topologia para a classificação de falha e nível de severidade no MIT?
- iv Qual o melhor classificador de padrão para a identificação de falha e nível de severidade no MIT ?

Os questionamentos i e ii tem como objetivo a redução no custo de implementação da metodologia enquanto os questionamentos iii e iv buscam a redução da complexidade de implementação computacional.

1.5 OBJETIVOS

O objetivo geral deste trabalho consiste em estudar e implementar um classificador de padrões por meio de uma rede neural convolucional das falhas mais comuns no Motor de

²Subindo escada, Descendo escada, Levantando e Sentando

Indução Trifásico (MIT), a saber: desgaste de rolamento, barra de rotor quebrada, curto circuito de estator bem como apresentar a classificação do nível de severidade das referidas falhas.

1.5.1 Objetivos Específicos

Com base no objetivo geral deste trabalho foram determinados os objetivos específicos, os quais consistem em:

- Estudar a estrutura de uma rede neural convolucional como classificador e aplicá-la ao processamento de sinais no domínio do tempo;
- Implementar em ambiente computacional uma rede neural convolucional para a classificação de falhas e nível de severidade destas falhas no MIT fazendo o uso de dados reais;
- Analisar a performance da camada convolucional por meio da aplicação de diversos classificadores;
- Analisar qual a melhor configuração de sensores e taxas amostrais, para a classificação de falha e do nível de severidade.

1.6 ORGANIZAÇÃO DO TEXTO

Este trabalho está dividido em cinco capítulos, apresentando uma visão geral sobre o problema e os métodos aplicados para a sua solução, bem como os resultados obtidos com a metodologia e a conclusão.

No Capítulo 1 é apresentada a introdução ao tema, o contexto em que o trabalho está inserido e a motivação da escolha do classificador de padrões. Neste capítulo também são apresentados os objetivos gerais e específicos deste trabalho.

No Capítulo 2 são apresentados os aspectos construtivos do MIT e suas principais falhas buscando descrever as suas causas e consequências.

No Capítulo 3 é apresentada a revisão bibliográfica das redes neurais convolucionais para a extração de características e dos métodos de classificação utilizados, bem como das métricas de desempenho.

No Capítulo 4 é apresentada a metodologia usada nos testes descrevendo como se deu a implementação de cada etapa e uma descrição sobre a base de dados.

No Capítulo 5 são apresentados os resultados obtidos com cada classificador de padrões testado e as diversas topologias descritas. Nesta seção também é realizada a discussão e a análise dos resultados obtidos.

Por fim, no Capítulo 6 é apresentada a conclusão do trabalho e são indicados os novos passos para o desenvolvimento da pesquisa no âmbito de identificação de falhas em máquinas elétricas com as redes neurais convolucionais.

2 FALHA EM MÁQUINAS ELÉTRICAS

O motor elétrico como brevemente descrito no Capítulo 1, é o principal elemento de conversão eletromecânica de energia na indústria devido a sua alta robustez e a possibilidade de controle da sua velocidade.

Dentre os motores elétricos podemos classificá-los em três categorias: Motores assíncronos, os síncronos e os de corrente contínua. O motor utilizado neste trabalho é o Motor de Indução Trifásico (MIT) pois é o mais usado na indústria (TRZYNADLOWSKI, 2000).

2.1 MOTOR DE INDUÇÃO TRIFÁSICO

O MIT também conhecido como motor assíncrono devido a sua característica da velocidade do rotor não estar em sincronismo com a do campo girante. Eles apresentam como vantagem alta robustez e baixa necessidade de manutenção. Ainda, devido aos avanços na eletrônica de potência e dos microcontroladores tornou-se possível o controle preciso de sua velocidade por meio de inversores de frequência.

2.2 FALHAS NO MOTOR DE INDUÇÃO TRIFÁSICO

Nas últimas décadas diversos estudos foram realizados para determinar os dados relativos as falhas nos MITs. Neste contexto pode-se citar as pesquisas de ALBRECHT et al. (1986) e SINGH e KAZZAZ (2003) que relacionaram a frequência das falhas. O resultado destas pesquisas são apresentados na Tabela 1:

Tabela 1 – Estatística de falhas no MIT.

	Rolamento	Estator	Rotor	Outras ¹
IEEE	42%	28%	8%	22%
EPRI	41%	36%	9%	14%

Fonte: Adaptado de KARMAKAR et al. (2016)

Comparando os dois resultados é possível observar que há uma semelhança entre as estatísticas de falhas, onde os defeitos de rolamento apresentam a maior parcela associada à paradas inesperadas de motores elétricos em ambientes industriais. De forma a complementar, o trabalho de KARMAKAR et al. (2016) classifica as falhas no MIT em três categorias: i) elétricas, ii) mecânicas e iii) ambientais.

i Falhas Elétricas - Falhas relacionadas aos elementos elétricos do motor como:

- Desbalanço de tensão e corrente;
- Sobre e subtensão;
- Curto circuito das espiras.

ii Falhas Mecânicas - Falhas físicas relacionadas aos elementos mecânicos do motor como:

- Barra de rotor quebrada;
- Desbalanço de massa do rotor;
- Excentricidade do entreferro;
- Falhas de rolamento.

iii Falhas Ambientais - Falhas relacionadas ao ambiente externo em que o motor está situado como:

- Baixa ou elevada temperatura;
- Elevada umidade;
- Presença de elementos químicos;
- Vibração externa.

2.2.1 Falhas de Estator

As falhas de estator segundo SINGH e KAZZAZ (2003) representam estatisticamente cerca de 36% das falhas no MIT. A falha mais comum no estator consiste no curto circuito entre as espiras conforme ilustrado na Figura 1. Ainda segundo DRIF e CARDOSO (2014), esta falha é causada pela degradação do sistema de isolamento dos enrolamentos das bobinas.

Figura 1 – Curto circuito entre espiras.



Fonte: WEG (2013)

Segundo BONNETT e SOUKUP (1992) as causas das falhas de estator podem ser divididas em três categorias:

- **Deterioração do material:** A deterioração do material ocorre devido ao tempo de uso, onde o isolante dos condutores podem vir a se romper causando o curto entre as bobinas;
- **Térmica:** Este tipo de falha ocorre devido a elevada temperatura do motor. Neste caso o isolante pode vir a deteriorar-se causando o curto nas bobinas;
- **Elétrica:** A falha elétrica é causada por transitórios de tensão como, por exemplo, as descargas atmosféricas, as quais podem romper o dielétrico do isolante das espiras e causar o curto circuito das mesmas;

- **Mecânica:** O defeito mecânico é originado pelo impacto² das bobinas pelo estator resultando no rompimento do isolante e curto circuitando as espiras. Outra causa mecânica da falha de estator é a vibração das bobinas e, consequentemente, a abrasão do isolante;
- **Causas Externas:** São falhas causadas por questões externas ao motor como por exemplo a operação do motor em ambientes hostis com a presença de alta temperatura, elevada umidade e de materiais estranhos ³.

As falhas de estator, possuem uma assinatura característica do sinal de corrente representado na frequência descrito na equação (1) conforme apresentado por GANDHI, CORRIGAN e PARSA (2011).

$$f_{st} = f_s \left[\frac{m}{p} (1 - s) \pm k \right] \quad (1)$$

Onde:

f_{st} : Frequências da falha de estator;

f_s : Frequência fundamental de alimentação do motor;

m : Coeficientes “0, 1, 2”;

k : Coeficientes “0, 1, 3, 5”;

p : Número de pares de polos;

s : Escorregamento.

O estudo da falha no contexto deste trabalho se dá para determinar onde e como a falha se manifesta, viabilizando a extração das características de falha por meio das camadas convolucionais e em seguida sua classificação.

2.2.2 Falhas de Rotor

Neste trabalho o elemento de estudo é o MIT com o rotor gaiola de esquilo o qual é composto por barras condutoras conectadas a um anel condutor. Os rotores, segundo o estudo estatístico das falhas apresentado na Tabela 1, compõe 8% do total. O defeito mais comum nos rotores gaiola de esquilo é a quebra ou trinca de uma ou mais barras. Segundo BONNETT e SOUKUP (1992) pode-se listar como causas das falhas de estator:

- **Falha na produção:** O processo de manufatura das barras e do anel condutor é feita pela fundição do material, uma falha neste processo pode resultar em trincas no material.
- **Stress:** O stress no material pode ser causado por diversos fatores dentre os principais podemos citar:
 - Força centrífuga: Esta força ocorre quando o rotor possui os anéis condutores com uma alta massa e as barras sofrem a ação da força centrífuga resultando em trincas;

²Choque ou colisão de um corpo estranho nas bobinas do estator

³Poeira ou resíduos de usinagem

- Rolamento defeituoso: Quando o rolamento apresenta falha, ele pode acabar forçando as barras resultando em trincas ou a quebra da mesma;
- Elevado número de partidas: Quando o motor parte é exercida uma força de torque elevada no rotor para retirá-lo da inércia. Esta força quando faz-se presente constantemente leva o rotor à falhas.

Segundo MESSAOUDI e LASSAAD (2010) as falhas de barra de rotor quebrada apresentam uma assinatura característica no sinal de corrente conforme apresentado na equação (2).

$$f_{bb} = (1 \pm 2ks)f_s \quad (2)$$

Onde:

f_{bb} : Frequências da falha de rotor;

f_s : Frequência fundamental;

k : Coeficientes “0, 1, 3, 5”;

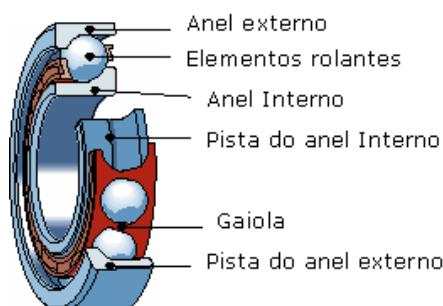
s : Escorregamento.

O estudo da falha de estator mostrou que a assinatura de falha faz-se presente no sinal de corrente, portanto por meio deste sinal é possível sua identificação.

2.2.3 Falhas de Rolamento

Estatisticamente segundo, SINGH e KAZZAZ (2003), o elemento construtivo do MIT que mais apresenta falha é o rolamento, totalizando cerca de 41% de todas as falhas. Isso ocorre devido ao fato deste componente estar sempre sob constante esforço, causado tanto pela rotação do motor quanto pelo contato direto com o ambiente externo. Ainda, conforme a referência citada, o rolamento é um dos principais elementos construtivos de um MIT. Na Figura 2 são ilustradas as principais peças que compõe o dispositivo.

Figura 2 – Elementos internos de um rolamento.



Fonte: SKF (2005) Adaptado.

- **Anéis externo e interno:** Os anéis externo e interno têm a função de fornecer o suporte ao rolamento;
- **Elementos rolantes:** Os elementos rolantes têm como objetivo anular o atrito entre os anéis externo e interno por reduzir a superfície de contato entre eles;
- **Gaiola:** A gaiola tem como objetivo manter a distância constante entre os elementos girantes e o contato com o líquido lubrificante;
- **Pistas dos anéis externo e interno:** As pistas dos anéis externo e interno têm como objetivo fornecer o caminho para os elementos rolantes.

Neste trabalho é levado em consideração apenas o desgaste do rolamento, mas segundo RADU (2010) podemos citar as demais causas de falhas de rolamento como:

- **Excesso de carga:** Quando o motor está operando acima do seu valor nominal de carga, são exercidos nas esferas e nos anéis do rolamento esforços os quais ocasionam a deformação dos mesmos. Ainda devido ao excesso de carga, o motor pode apresentar o aumento na temperatura o que leva a degradação dos rolamentos;
- **Fadiga:** A falha por fadiga é progressiva, ou seja, ela ocorre em um grande espaço de tempo, resultando em fraturas e na remoção do material das esferas e dos anéis, causando o aumento da vibração e do ruído do motor;
- **Corrosão:** A corrosão ocorre quando os elementos do rolamento estão em contato com um contaminante abrasivo ou com a atmosfera por remoção do lubrificante;
- **Contaminação:** A contaminação é causada pela presença de terra, poeira ou qualquer outra partícula estranha no lubrificante aumentando a abrasão e consequentemente o atrito nos elementos móveis;
- **Falha no lubrificante:** A falha no lubrificante é causada pelo fluxo restrito de lubrificante ou aumento na temperatura. Como consequência é impossibilitada a redução do atrito das partes móveis e corroborando para a degradação do rolamento;
- **Desalinhamento:** No desalinhamento é verificado um maior atrito causando o desgaste e aumento de temperatura na peça.

Segundo SINGH, KUMAR e KUMAR (2014) as frequências características da falha de rolamento pode ser matematicamente expressa pela equação (3).

$$f_{orf} = \left| f_s \pm m N_b \omega_{in} \left(\frac{1 - \frac{d}{D} \cos \alpha}{2} \right) \right| \quad (3)$$

Onde:

f_{orf} : Frequências da falha de rolamento;

f_s : Frequência fundamental;

m : Coeficientes “0, 1, 2”;

N_b : Número de esferas no rolamento;

ω_{in} : Velocidade do rolamento;

d : Diâmetro interno do rolamento;

D : Diâmetro externo do rolamento;

α : Angulo de contato das esferas.

A importância de conhecer as frequências características de falhas no MIT se deve ao fato de sua utilização nos métodos tradicionais de classificação de padrão, onde o usuário apresenta ao modelo de classificação de falhas o vetor de frequências. Por outro lado, a rede neural convolucional é capaz de extrair de forma automática estas características de falha.

2.3 CONCLUSÃO DO CAPÍTULO

Este capítulo apresentou a importância do Motor de Indução Trifásico (MIT) contextualizando-o no ambiente industrial atual apresentando suas vantagens e as principais falhas que ocorrem com esta máquina. Este capítulo também trouxe uma análise dos defeitos mais comuns encontrados no MIT apresentando suas causas e também a resultante no sinal de corrente.

Neste contexto o estudo do MIT e das falhas viabilizou a escolha da estratégia de extração de característica e classificação das falhas por meio da rede neural convolucional apresentada no capítulo seguinte.

3 ALGORITMOS INTELIGENTES

Algoritmos de aprendizado de máquina (também conhecidos como algoritmos inteligentes) estão muitas vezes associados com inteligência artificial, em atividades tais como reconhecimento de padrões, planejamento e previsão. Neste trabalho o conceito de aprendizado de máquinas e de redes neurais profundas (do inglês *Deep Neural Networks*) é aplicado na identificação de falhas em MITs. Assim, partir dos conhecimentos adquiridos a metodologia proposta é capaz de reconhecer padrões e auxiliar na sua identificação.

3.1 REDES NEURAIS PROFUNDAS

As redes neurais de aprendizado profundo são métodos de representação e aprendizado com múltiplos níveis (LECUN; BENGIO; HINTON, 2015) e nos últimos anos ganharam um grande destaque. Este grande destaque para as redes de aprendizado profundo segundo GOODFELLOW, BENGIO e COURVILLE (2016) ocorre principalmente por conta de quatro fatores:

- As redes profundas já apresentaram aplicação em diversos campos do conhecimento fundamentando seu funcionamento;
- Com o avanço e evolução do poder computacional e das estruturas de aprendizado profundo tornou-se viável sua implementação com um grande volume de dados e em diversas situações visto que nos últimos anos houve uma tendência do aumento do volume das bases de dados;
- Os métodos de aprendizado profundo apresentam melhores resultados com grandes volumes de dados;
- Os métodos de aprendizado profundo são capazes de resolver problemas complexos elevando sua acurácia ao longo do tempo.

Diante das vantagens apresentadas pelos métodos de aprendizado profundo, este trabalho apresenta uma metodologia alternativa para a análise e extração de característica dos sinais de corrente de linha para auxiliar na identificação de falhas de estator, rotor e rolamento no MIT.

3.1.1 Redes Convolucionais

As redes convolucionais são um instrumento computacional de classificação e extração de características bio-inspiradas no sistema visual dos mamíferos (INCE et al., 2016). Ainda, segundo MENDES (2017), a definição de rede convolucional é uma rede *feedforward* que faz o uso de camadas convolucionais.

As redes neurais convolucionais são compostas por diversas camadas, dentre as principais para a implementação de uma rede convolucional podemos citar: i) camada convolucional e ii) camada de *pooling*. Estas duas camadas juntas compõem a etapa de extração de características.

Após a extração das características pelas camadas convolucionais de *pooling*, apresentam os dados obtidos para os algoritmos classificadores de padrões. Na etapa de classificação podemos citar os seguintes algoritmos: i) *Gaussian Naive Bayes* (GNB), ii) *Perceptron Multicamadas* (PMC), iii) *K-Nearest Neighbors* (KNN), iv) *Support Vector Machine* (SVM).

3.1.1.1 Camada Convolutinal

Segundo GOODFELLOW, BENGIO e COURVILLE (2016), a convolução é uma operação matemática entre duas funções dada pela equação (4) que representa as duas notações para a operação de convolução no tempo contínuo.

$$s(t) = (x * w)(t) = \int x(a)\omega(t - a)da \quad (4)$$

Onde:

x e w : Funções no domínio do tempo.

Em muitos casos o processamento dos sinais e as operações matemáticas são realizadas de maneira digital, onde os dados estão discretizados. Assim, a equação (5) representa a mesma operação de convolução descrita pela equação (4) mas no tempo discreto.

$$s(t) = (x * w)(t) = \sum_{a=-\infty}^{\infty} x(a)\omega(t - a) \quad (5)$$

Em aprendizado de máquinas os dados de entrada e o kernel são matrizes multidimensionais. Portanto, para a aplicação da convolução como uma camada de uma rede neural é preciso uma representação da operação em um espaço multidimensional dado pela equação (6).

$$s(i, j) = (I * K_r)(i, j) = \sum_m \sum_n I(m, n)K_r(i - m, j - n) \quad (6)$$

Onde:

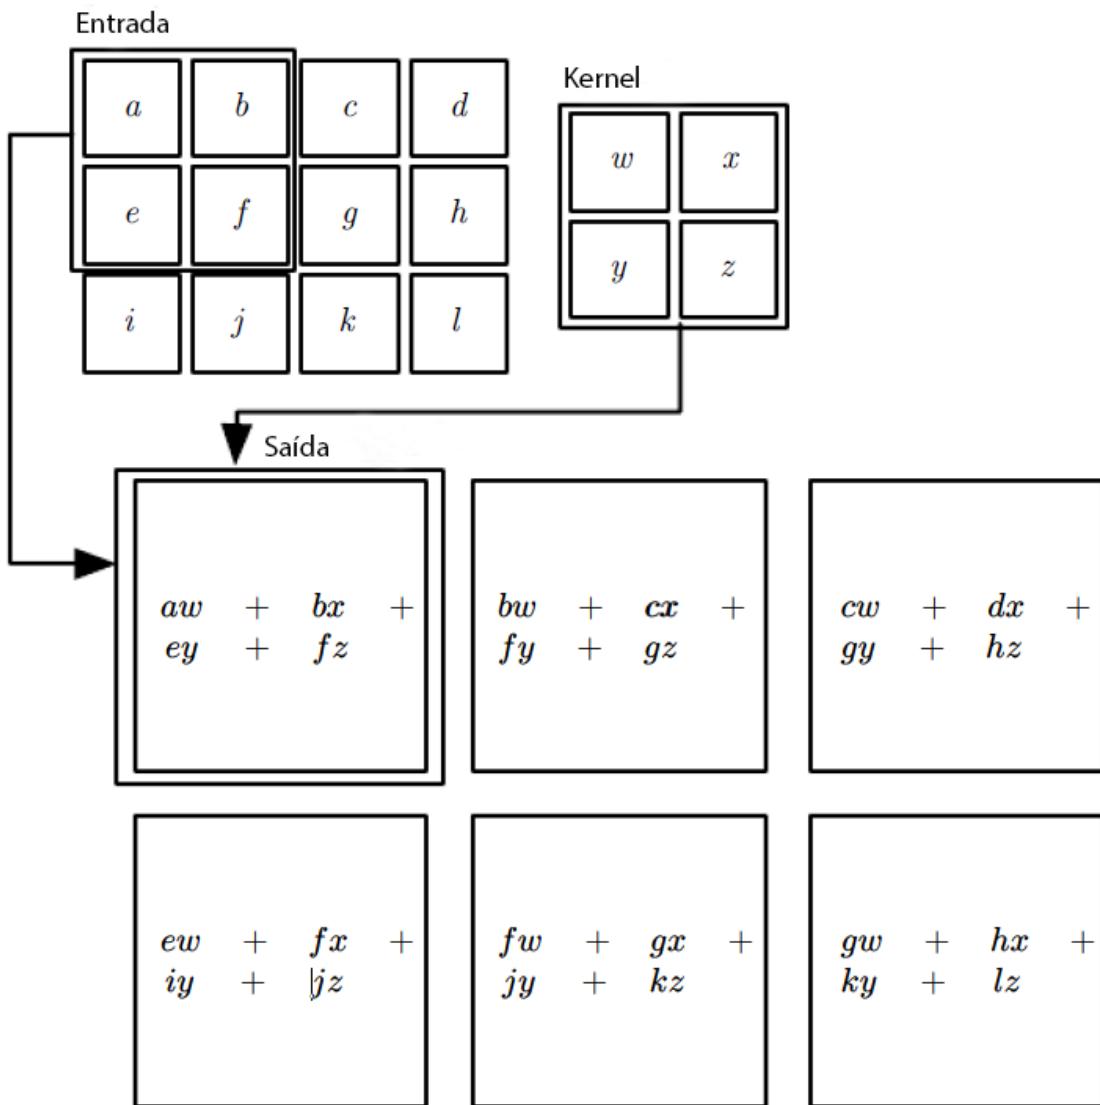
I : Amostra de dados;

K_r : Kernel.

Usando a operação dada pela equação (6) torna-se possível a implementação da convolução como uma camada neural. Um exemplo da operação de convolução aplicada a uma base de dados bidimensional foi apresentada por GOODFELLOW, BENGIO e COURVILLE (2016) e está representada na Figura 3. Nesta representação é aplicado um Kernel com dimensão 2x2 em uma base de dados com dimensão 3x4, resultando em uma saída com as dimensões 2x3. Ainda, na referida figura, é possível observar que o Kernel percorreu todos os dados de entrada,

efetuando a operação de convolução descrita na equação (6) gerando uma nova representação para as amostras de dados.

Figura 3 – Aplicação da operação de convolução.



Fonte: Adaptado de GOODFELLOW, BENGIO e COURVILLE (2016)

Na etapa de treinamento os coeficientes do Kernel inicialmente definidos aleatoriamente são ajustados para a melhor extração das características das classes por meio do algoritmo de retro propagação, também conhecido como algoritmo de *backpropagation* que foi proposto por RUMELHART, HINTON e WILLIAMS (1986).

A operação deste algoritmo tem duas principais operações, a saber: i) A fase de 'Computação para frente' onde são obtidos os valores de saída para a base de teste e calculado o erro desta saída comparando com o valor desejado e ii) A fase de 'Computação para trás' onde a partir do erro calculado na fase de computação para frente são ajustados os coeficientes das demais camadas da rede.

3.1.1.2 Camada de *Pooling*

Segundo SUÁREZ-PANIAGUA e SEGURA-BEDMAR (2018) o principal objetivo da camada de *Pooling* é extrair as características mais significativas da saída da camada convolucional e fornecê-las para as próximas camadas. Assim, a camada de *Pooling* executa operações matemáticas simples e não exige uma alta demanda computacional para o seu funcionamento. Ainda, esta camada pode ser dividida em três tipos: *MinPooling*, *MaxPooling* e *AveragePooling*. Cada uma das topologias tem como objetivo extrair uma característica do problema. Mais especificamente, tem-se as definições de *MaxPooling*, *MinPooling* e *AveragePooling*:

- ***MaxPooling*:** A camada *MaxPooling* tem como objetivo obter o valor máximo de uma região delimitada pelo kernel dado a saída da camada convolucional.

O exemplo de *Pooling* da Figura 4 apresenta uma matriz de características com dimensão 4x4 onde é aplicado um *pool* de dimensão 2x2. A saída da operação *MaxPooling* é determinada por meio da equação (7).

Figura 4 – Exemplo Pooling.

A11	A12	A13	A14		B11	B12
A21	A22	A23	A24		B21	B22
A31	A32	A33	A34			
A41	A42	A43	A44			

Fonte: Autoria Própria.

$$\begin{aligned}
 B_{11} &= \max(A_{11}, A_{12}, A_{21}, A_{22}) \\
 B_{12} &= \max(A_{13}, A_{14}, A_{23}, A_{24}) \\
 B_{21} &= \max(A_{31}, A_{32}, A_{41}, A_{42}) \\
 B_{22} &= \max(A_{33}, A_{34}, A_{43}, A_{44})
 \end{aligned} \tag{7}$$

Onde:

max: função de máximo;

A_{ij} : coeficientes da matriz antes do *pooling*;

B_{ij} : coeficientes da matriz após o *pooling*.

No exemplo apresentado na Figura 4 o tamanho do *pool* escolhido é de 2x2 e a matriz de características possui uma dimensão 4x4 portanto a matriz foi dividida em regiões de dimensão 2x2 e obtido o valor máximo de cada uma destas regiões.

- **MinPooling:** A camada *MinPooling* tem como objetivo obter o valor mínimo de uma região dada a saída da camada convolucional.

Usando a mesma matriz de características e o mesmo *pool* apresentado na Figura 4, tem-se a saída da operação *MinPooling* determinada por meio da equação (8).

$$\begin{aligned} B_{11} &= \min(A_{11}, A_{12}, A_{21}, A_{22}) \\ B_{12} &= \min(A_{13}, A_{14}, A_{23}, A_{24}) \\ B_{21} &= \min(A_{31}, A_{32}, A_{41}, A_{42}) \\ B_{22} &= \min(A_{33}, A_{34}, A_{43}, A_{44}) \end{aligned} \quad (8)$$

Onde:

min: Função de mínimo.

- **AveragePooling:** A camada *AveragePooling* tem como objetivo calcular a média de uma região dada a saída da camada convolucional.

Para ilustrar o *AveragePooling*, utiliza-se a mesma matriz de características e o mesmo *pool* apresentado na Figura 4. Assim, a saída da operação *AveragePooling* é determinada por meio das equações (9).

$$\begin{aligned} B_{11} &= (A_{11} + A_{12} + A_{21} + A_{22})/4 \\ B_{12} &= (A_{13} + A_{14} + A_{23} + A_{24})/4 \\ B_{21} &= (A_{31} + A_{32} + A_{41} + A_{42})/4 \\ B_{22} &= (A_{33} + A_{34} + A_{43} + A_{44})/4 \end{aligned} \quad (9)$$

3.1.1.3 Funções de ativação

As principais funções de ativação no contexto das redes neurais com poucas camadas é a tangente hiperbólica e a função logística. No contexto das redes neurais profundas, com mais de uma camada a função de ativação mais utilizada nas camadas intermediárias é a *Rectified Linear Unit* (ReLU) representada matematicamente na equação (10) e ilustrada na Figura 5.

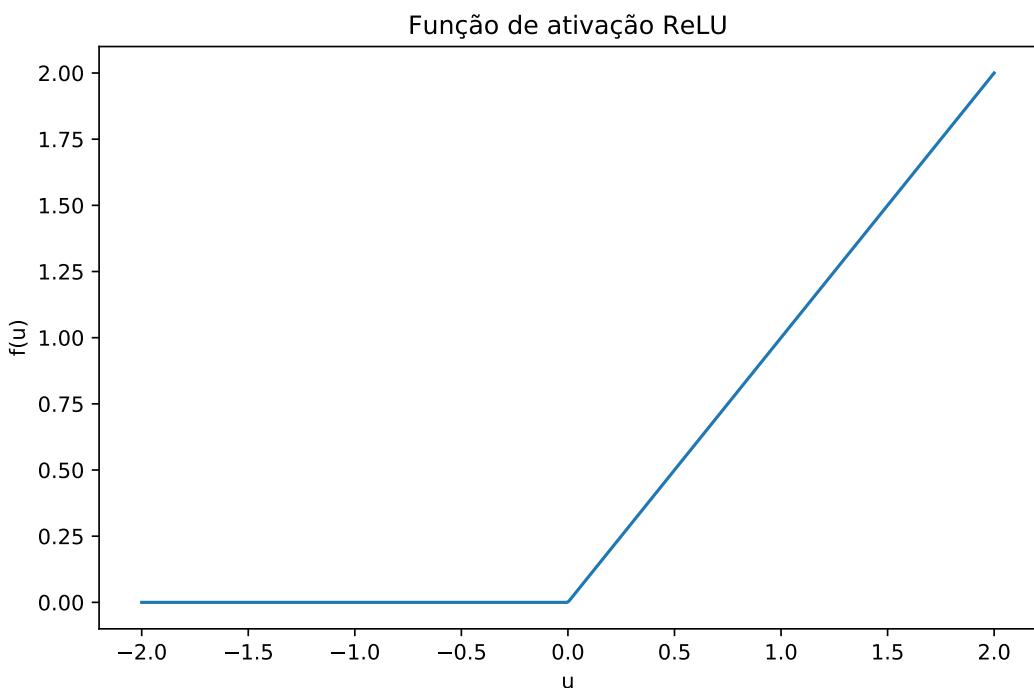
$$f(u) = \begin{cases} f(u) = u & u > 0 \\ f(u) = 0 & u \leq 0 \end{cases} \quad (10)$$

Onde:

$f(u)$: Função de ativação;

u : Limiar de ativação.

Figura 5 – Função de ativação ReLU



Fonte: Autoria Própria

Segundo KRIZHEVSKY, SUTSKEVER e HINTON (2017) a função de ativação ReLU, apresenta um desempenho superior nas redes neurais profundas com relação as funções tangente hiperbólica e logística devido:

- **Simplicidade computacional** - A função de ativação ReLU apresenta uma menor complexidade computacional por não ser necessário o cálculo do valor exponencial;
- **Derivada constante** - Um dos problemas da utilização das funções de ativação tangente hiperbólica e logística é que a sua derivada pode ter um valor muito próximo de zero impossibilitando o treinamento pelo algoritmo de *backpropagation*. A função de ativação ReLU é linear e tem derivada igual a um para valores positivos evitando que isso ocorra.

Na camada de saída para problemas de classificação de padrões, as funções de ativação mais utilizadas são a logística quando faz-se presente apenas duas classes e a *Softmax* para múltiplas classes sendo apresentada matematicamente pela equação (11).

$$f(u_i) = \frac{e^{u_i}}{\sum_j e^{y_j}} \quad (11)$$

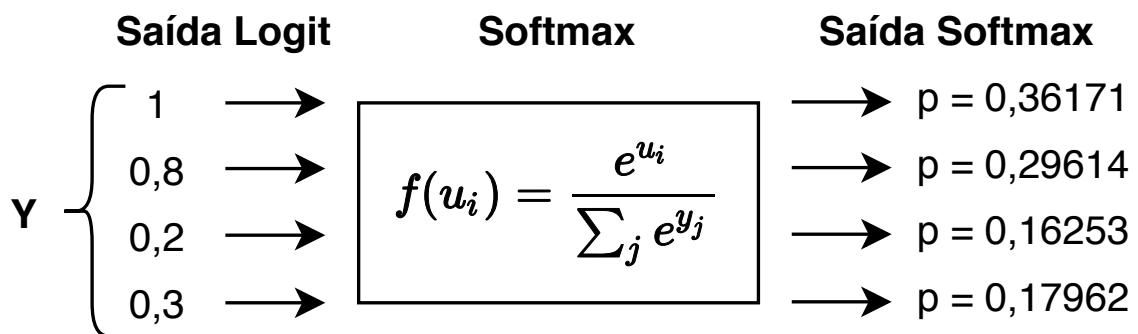
Onde:

- u_i : é a saída individual da camada logit;
- u_j : são as saídas das camadas logit;
- $f(u_i)$: é a saída da camada Softmax.

A função de ativação *Softmax* diferente da logística, pois fornece uma métrica análoga a probabilidade de uma amostra de dados pertencer a uma dada classe com um valor entre zero e um por meio da transformação da saída da camada logit (MARTINS; ASTUDILLO, 2016).

O exemplo apresentado na Figura 6 demonstra atuação da camada Softmax dado quatro saídas neurais.

Figura 6 – Exemplo Softmax



Fonte: Autoria Própria

Observa-se que a saída da camada *Softmax* é a uma analogia da probabilidade de y pertencer a uma das classes, e que a soma de todas as saídas é 1.

3.2 CLASSIFICADORES DE PADRÕES

Segundo KUNCHEVA (2004) classificar um padrão é fornecer um rótulo a algum objeto. Assim, no contexto deste trabalho, os classificadores de padrões são algoritmos que têm como objetivo fornecer um rótulo referente a falha no MIT para uma dada amostra de dado.

Usualmente o classificador utilizado para a classificação de padrões nas redes neurais convolucionais é o PMC. Neste trabalho os testes com os demais classificadores tem como objetivo específico analisar a capacidade de extração de características das camadas convolucionais.

Nesta seção são apresentados os classificadores de padrões utilizados neste trabalho: *Gaussian Naive Bayes* (GNB), *Support Vector Machine* (SVM), *K-Nearest Neighbors* (KNN) e *Perceptron Multicamadas* (PMC).

3.2.1 Classificador de Naive Bayes

O classificadores Bayesianos fazem o uso da teoria de Bayes para a classificação de padrões. Segundo ZHANG (2004), o funcionamento do classificador é fundamentado na atribuição de um rótulo referente a sua classe dada uma amostra de entrada. Para este classificador de padrões utiliza-se o teorema de Bayes apresentado na equação (12) onde é calculada a probabilidade das amostras $E = (x_1, x_2, \dots, x_n)$ pertencer a classe c .

$$P(c|E) = \frac{P(c)P(E|c)}{P(E)} \quad (12)$$

Onde:

$P(c|E)$: Probabilidade de c ocorrer dado E ocorrido;

$P(E|c)$: Probabilidade de E ocorrer dado c ocorrido;

$P(c)$: Probabilidade de c ocorrer;

$P(E)$ é a probabilidade de E ocorrer.

Os classificadores de Naive Bayes partem da suposição que todos os atributos são independentes dado o valor de uma classe. Portanto, a equação (12) no classificador de Naive Bayes é representado pela equação (13)

$$P(E|c) = P(x_1, x_2, \dots, x_n|c) = \prod_{i=1}^n P(x_i|c) \quad (13)$$

Onde:

$P(x_1, x_2, \dots, x_n|c)$: Probabilidade de x_1, x_2, \dots, x_n ocorrer dado c ocorrido.

O classificador Bayesiano vem sendo utilizado em conjunto com algoritmos de extração de características no diagnóstico inteligente de falhas no MIT. Já o classificador de Naive Bayes gaussiano, assume que a probabilidade dos atributos é assumida como uma gaussiana.

Neste contexto, uma aplicação do algoritmo de Naive Bayes na classificação de falhas em máquinas elétricas faz-se presente nos trabalhos de ZHANG et al. (2018) e Asfani, Purnomo e Sawitri (2013). Nestas referências, os classificadores de padrões por meio do pré processamento dos dados e extração das características de falha o classificador foi capaz de identificar e classificar as classes de falha de rolamento e curto circuito no estator.

3.2.2 k - Vizinhos mais Próximos

O algoritmo de aprendizado de máquina k - Vizinhos mais Próximos (KNN) é usado em problemas de classificação de padrões e de regressão. Este algoritmo é considerado relativamente simples na sua implantação, porém demanda maior poder computacional e memória para sua execução (KANKATALA, 2015).

Para a classificação de padrões o algoritmo k - Vizinhos mais Próximos no contexto deste trabalho, opera comparando a distância euclidiana entre dois pontos x e y vizinhos em N

dimensões conforme a equação (14).

$$d(x, y) = \sqrt{\sum_{i=1}^N (x_i - y_i)^2} \quad (14)$$

Onde:

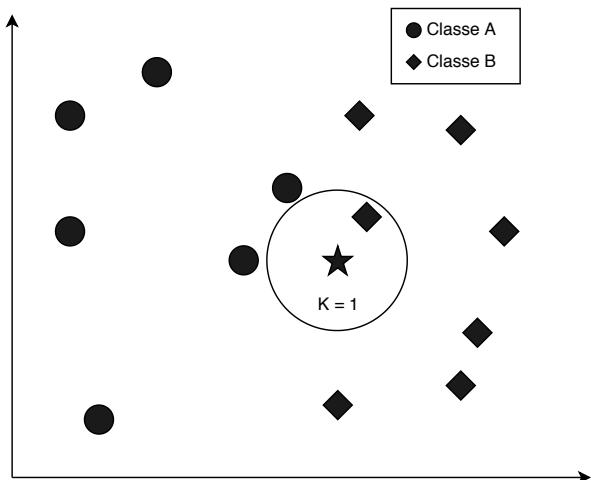
$d(x, y)$: Distância euclidiana;

x_i, y_i : Pontos no espaço.

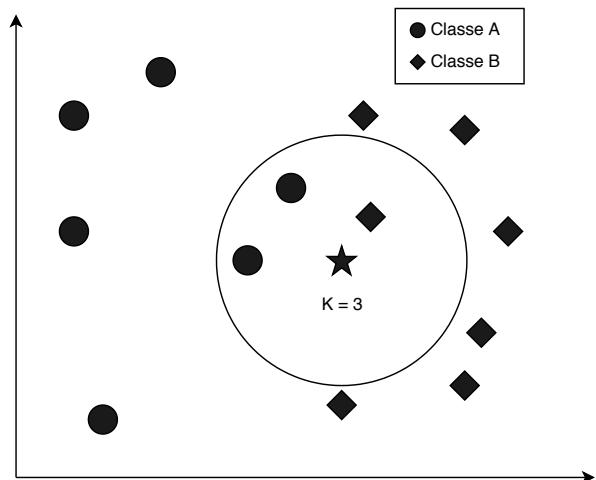
A partir da proximidade com os k-vizinhos é determinada a qual classe aquele ponto pertence. Na Figura 7 é possível analisar um exemplo da classificação do método de k - Vizinhos mais Próximos onde é analisada a proximidade do ponto a ser classificado com seus vizinhos mais próximos obtido pela menor distância euclidiana.

Figura 7 – Exemplo classificador k - Vizinhos mais Próximos

(a) Exemplo considerando $k = 1$ vizinhos



(b) Exemplo considerando $k = 3$ vizinhos



Fonte: Autoria Própria

No exemplo da Figura 7a é possível observar que o ponto a ser classificado está mais próximo do ponto cuja classe é B. Assim, o classificador k - Vizinhos mais Próximos e considerando $k = 1$ vizinho, classifica o ponto em questão como sendo pertencente a classe B. Já no exemplo da Figura 7b e considerando $k = 3$ vizinhos, tem-se o ponto a ser classificado mais próximo dos pontos cuja a classe é A. Portanto, o classificador determina que o ponto em questão pertencente à classe A.

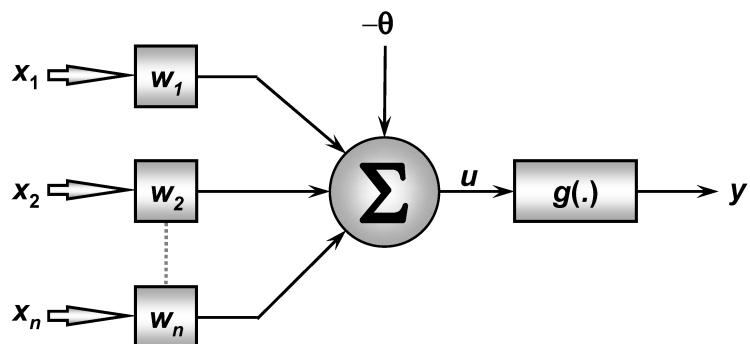
3.2.3 Perceptron Multicamadas

O classificador *Perceptron Multicamadas* (PMC) consiste em uma das redes neurais artificiais que apresenta mais de uma camada. Ainda, as redes PMC possuem uma maior

capacidade de abstração. Devido a isso são capazes de classificar problemas onde as classes não são linearmente separadas.

A unidade básica de processamento das redes perceptron multicamadas é o neurônio artificial representado pela Figura 8. Segundo SILVA, SPATTI e FLAUZINO (2010) ele é composto por sete elementos básicos: Sinais de Entrada (x_1, x_2, \dots, x_n), os Pesos Sinápticos (w_1, w_2, \dots, w_n), o Combinador Linear (\sum), o Limiar de Ativação (θ), o Potencial de ativação (μ), a Função de ativação ($g(\cdot)$) e o sinal de saída (y).

Figura 8 – Modelo neurônio artificial.



Fonte: SILVA, SPATTI e FLAUZINO (2010)

O modelo matemático do neurônio artificial conforme descrito por SILVA, SPATTI e FLAUZINO (2010) é dado pelas equações (15) e (16):

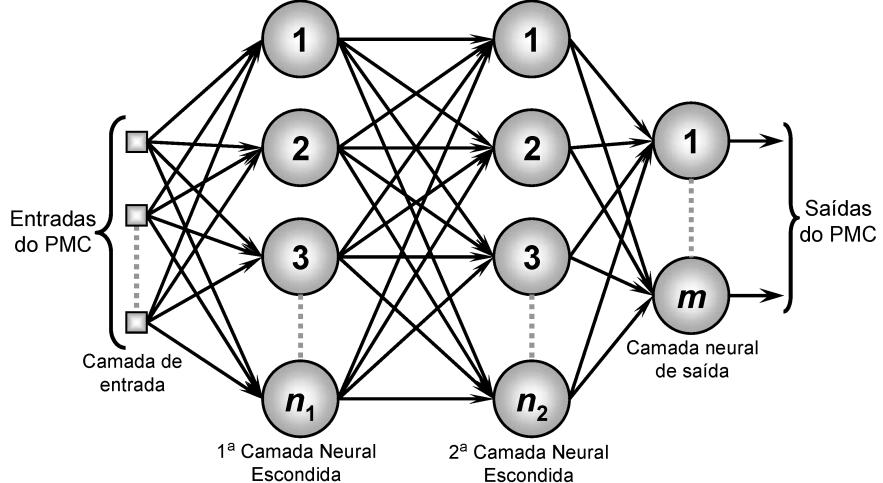
$$u = \sum_{i=1}^n w_i x_i - \theta \quad (15)$$

$$y = g(u) \quad (16)$$

A Figura 9 ilustra uma rede neural *perceptron* multicamadas com duas camadas escondidas. Na referida figura é possível observar sua principal característica, a qual consiste em possuir mais de uma camada escondida. Na PMC as entradas são conectadas aos neurônios das camadas escondidas e as saídas dos mesmos são conectadas às entradas dos neurônios da camada seguinte até a camada de saída neural.

A propagação dos sinais de entrada nas redes *perceptron* multicamadas seguem apenas um sentido, da camada de entrada em direção a camada de saída. Assim, devido a esta característica as redes *perceptron* multicamadas são conhecidas como redes *feedforward*. Ainda, o ajuste dos pesos sinápticos da rede PMC é realizado na etapa de treinamento por meio do algoritmo de retropropagação do erro.

Figura 9 – Ilustração da rede PMC.



Fonte: SILVA, SPATTI e FLAUZINO (2010)

3.2.4 Máquina de Vetor de Suporte

Segundo HAYKIN (2001) o principal objetivo do método de aprendizado de máquina SVM consiste em encontrar um hiperplano separador cuja a margem de separação seja máxima, representado pela equação (17), sendo os pontos $\mathbf{x}_i \in \mathbb{R}$ e a matriz dos coeficientes do hiperplano $\mathbf{w} \in \mathbb{R}$.

$$\mathbf{w}^T \mathbf{x} + b = 0 \quad (17)$$

Onde:

\mathbf{w} : Matriz dos coeficientes do hiperplano.

A classificação no SVM é feita pela equação (18) que representa a tomada de decisão de qual classe está sendo referida, da seguinte forma: quando $\mathbf{w}^T \mathbf{x} + b$ obtém um valor maior ou igual a zero a saída estabelece o valor +1 e quando se obtém um valor menor que zero a saída estabelece o valor -1.

$$\begin{aligned} \mathbf{w}^T \mathbf{x} + b \geq 0 &\rightarrow d_i = +1 \\ \mathbf{w}^T \mathbf{x} + b < 0 &\rightarrow d_i = -1 \end{aligned} \quad (18)$$

Onde:

d_i : Subconjunto que a classe está representado.

Esta expressão de tomada de decisão é chamada de função sinal, portanto a equação (18) pode ser expressa como (19).

$$d_i = \text{sinal}(\mathbf{w}^T \mathbf{x} + b) \quad (19)$$

Para encontrar o plano ótimo considera-se o SVM como um otimizador que tem como

objetivo encontrar os parâmetros w e b . Neste contexto, para que o plano de separação descrito em (17) consiga classificar as saídas desejadas d_i de uma amostra de treinamento dada por meio da função de custo apresentado na equação (20), consideram-se as restrições em (21).

$$\Phi(\mathbf{w}) = \frac{1}{2} \mathbf{w}^T \mathbf{w} \quad (20)$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \rightarrow i = 1, 2, \dots, N \quad (21)$$

A solução do problema de otimização segundo HAYKIN (2001) pode ser obtida usando o *método dos multiplicadores de Lagrange*. Ainda, o método SVM apresenta portanto uma limitação que só é possível classificar classes linearmente separáveis, onde para separar classes não linearmente separáveis é necessário introduzir o método Kernel. Este método consiste em representar as entradas do problema em um espaço amostral de mais dimensões tornando-os assim linearmente separáveis (PATLE; CHOUHAN, 2013).

3.3 ANÁLISE DA PERFORMANCE DOS CLASSIFICADORES

Em problemas de classificação, adotam-se as seguintes métricas de desempenho: Acurácia, Precisão, Pontuação F1 e *Kappa*, onde cada uma das métricas tem como objetivo de fornecer uma informação sobre o desempenho de cada um dos classificadores na classificação de falha e nível de severidade.

3.3.1 Métricas de Performance

A fim de obter uma visão mais específica da classificação tem-se outras formas de avaliar o desempenho em sendo cada uma com uma função específica (POWERS, 2011).

A acurácia é expressa pela equação (22) e tem como objetivo obter uma visão geral de quantos elementos o classificador conseguiu estimar corretamente sem levar em consideração o desbalanço das classes.

$$AC = \frac{TP + TN}{(TP + FP + FN + TN)} \quad (22)$$

Onde:

TP : Verdadeiros positivos;

TN : Verdadeiros negativos;

FP : Falso positivos;

FN : Falso negativos.

A precisão que tem como objetivo obter uma visão mais correta de quantos elementos o classificador conseguiu estimar corretamente levando em conta os desbalanços das classes expressa pela equação (23). Em termos gerais a precisão tem o objetivo de responder a

seguinte questão: Dos dados classificados, quantos realmente pertenciam a classe classificada corretamente ?.

$$PR = \frac{TP}{TP + FP} \quad (23)$$

O *recall* é expresso pela equação (24) e tem como objetivo analisar a capacidade do classificador de estimar corretamente as classes, onde o custo de um falso negativo é alto. Novamente em termos gerais o *recall* tem como objetivo responder a seguinte questão: Dado uma classe arbitrária A, quanto frequente uma amostra é classificada como A ?.

$$RE = \frac{TP}{TP + FN} \quad (24)$$

A pontuação F1 segundo SASAKI (2007), é definida como a média harmônica da precisão (*PR*) e do *recall* (*RE*) expresso pela equação (25). Assim tem-se um parâmetro mais completo da classificação. Neste caso, quanto mais próximo de 1 melhor a classificação e quanto mais próximo de 0 pior a classificação.

$$F1 = 2 \cdot \frac{PR \cdot RE}{PR + RE} \quad (25)$$

O coeficiente *Kappa* descrito na equação (26) foi proposto por COHEN (1960) e é definido como uma proporção das discordâncias esperadas ao acaso que não ocorrem, e é amplamente utilizado para analisar concordância dos classificadores em problemas com muitas classes e em casos em que estas classes estão em desbalanço.

$$KAPPA = \frac{p_0 - p_e}{1 - p_e} \quad (26)$$

Onde:

$$p_0 = \frac{TP + TN}{(TP + FP + FN + TN)} = AC$$

$$p_e = \frac{(TP + FP)(TP + FN) + (FN + TN)(FP + TN)}{(TP + FP + FN + TN)^2}$$

O coeficiente *Kappa* pode estabelecer valores entre -1 e 1, onde os valores próximos de 1 indicam uma melhor concordância na classificação. Com o objetivo de trazer uma maneira padronizada da interpretação do coeficiente LANDIS e KOCH (1977) propôs seis níveis de concordância representados na Tabela 2 sendo cada um com um valor específico de *Kappa*.

Com objetivo de obter uma visão geral da performance dos classificadores de padrões no contexto deste trabalho foram utilizadas as métricas de desempenho da acurácia e do índice *Kappa* pois em conjunto fornecem ao usuário respectivamente a qualidade da classificação e sua confiabilidade.

Tabela 2 – Interpretação índice *Kappa*

Índice <i>Kappa</i>	Concordância
< 0	Nenhum
0 a 0,20	Pobre
0,21 a 0,40	Fraca
0,41 a 0,60	Moderada
0,61 a 0,80	Substancial
0,81 a 1,00	Perfeita

Fonte: (LANDIS; KOCH, 1977)

3.4 CONCLUSÃO DO CAPÍTULO

Este capítulo apresentou a fundamentação teórica dos elementos computacionais utilizados no trabalho para o diagnóstico de falha no MIT, sendo compostos por: i) a rede convolucional utilizada para a extração de característica, os ii) classificadores de falhas *Gaussian Naive Bayes* (GNB) *K-Nearest Neighbors* (KNN), *Support Vector Machine* (SVM) e *Perceptron Multicamadas* (PMC) e iii) Métricas de desempenho que foi composta pela Acurácia (AC), Pontuação F1 (F1), *Recall* (RE), Precisão (PR) e Kappa.

No capítulo seguinte é descrito como foram aplicados os métodos apresentados neste capítulo, descrevendo detalhadamente como foi a obtenção dos resultados.

4 METODOLOGIA

Este capítulo tem como objetivo descrever detalhadamente a base de dados utilizada neste trabalho, explicitar como foram determinados os parâmetros para a criação das topologias convolucionais e dos classificadores, bem como apresentar a metodologia utilizada nos testes de classificação de nível de severidade da falha no MIT.

4.1 BASE DE DADOS

Esta seção apresenta as características das bases de dados de falhas no MIT utilizada neste trabalho. Todas as falhas e medidas realizadas para a criação das bases de dados foram desenvolvidas no Laboratório de Sistemas Inteligentes (LSI) na Universidade Tecnológica Federal do Paraná (UTFPR - CP), com o auxílio da bancada de testes apresentada na Figura 10. Os trabalhos de BAZAN et al. (2019), GUEDES et al. (2018), PALACIOS et al. (2017), LOPES et al. (2016), e GODOY et al. (2016) também utilizaram esta estrutura experimental.

Figura 10 – Bancada de testes Laboratório de Sistemas Inteligentes (LSI).



Fonte: Autoria Própria.

As bases de dados utilizadas possuem para cada um dos dois motores de 1cv e de 2cv 1230 casos de testes distribuídos em quatro condições de operação no MIT i) Curto Circuito no Estator, ii) Desgaste no Rolamento e iii) Barra do Rotor Quebrada, e iv) Motor sem falha. A base de dados de i a iv também apresenta para cada falha quatro níveis de severidade.

Cada caso de teste é determinado pelo tipo de falha, nível de severidade, valor de carga mecânica e desbalanço de tensão, com o objetivo de simular o funcionamento deste motor na maior quantidade de condições possível. O Quadro 1 apresenta a quantidade de casos de teste para cada uma das classes de falha e nível de severidade.

Quadro 1 – Distribuição dos atributos das bases de dados de falha no MIT de 1cv e 2cv.

Falha	Severidade	Casos	Total de Casos
Falha de Estator	1% de Curto	60	240
	3% de Curto	60	
	5% de Curto	60	
	10% de Curto	60	
Falha de Rolamento	15 Min de Desgaste	110	440
	30 Min de Desgaste	110	
	60 Min de Desgaste	110	
	90 Min de Desgaste	110	
Falha de Rotor	1 Barra Quebrada	110	440
	2 Barras Quebradas	110	
	2 2 Barras Quebradas	110	
	4 Barras Quebradas	110	
Motor Saudável	Motor Saudável	110	110

Fonte: Autoria Própria.

As variáveis coletadas em cada caso de teste foram as tensões de linha (V_{ab} , V_{bc} e V_{ca}), correntes de linha (I_a , I_b e I_c), torque e a velocidade no eixo do motor em avaliação, sendo que os valores de torque e velocidade no eixo não foram usados na classificação.

A Figura 11 apresenta o sinal de um dos casos de testes, onde observam-se as formas de onda de tensão e corrente de linha, bem como a velocidade e o torque no eixo do motor. Na referida figura também pode-se observar que a tensão aplicada no motor é senoidal e com frequência de 60Hz, sendo esta configuração utilizada em todos os testes.

Os sinais de tensão, corrente, torque e velocidade foram condicionados por meio de um circuito analógico e aquisitados com uma taxa amostral de 15 ksps (*k samples per second*) por meio de um conversor analógico digital por um tempo de 10 segundos.

4.1.1 Falha de estator

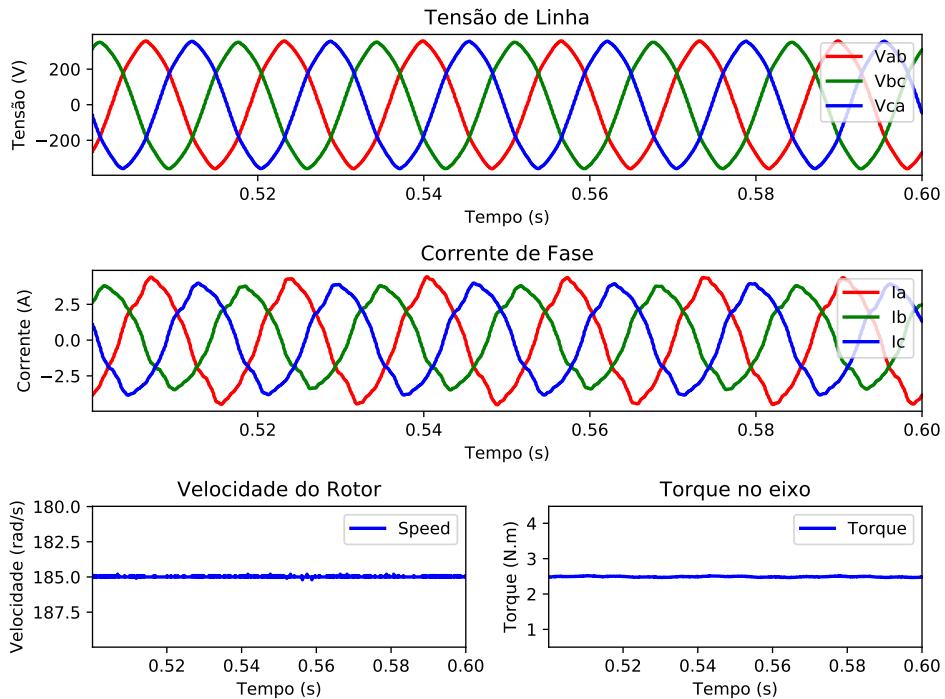
A falha de estator tratada neste trabalho é o curto circuito entre as espiras. Esta falha conforme descrito na Seção 2.2.1, é causada pelo rompimento ou desgaste do isolamento das bobinas do estator.

A reprodução deste defeito foi utilizada por PALACIOS et al. (2017), SUETAKE (2012) e BRONIERA (2014) onde por meio do rebobinamento do motor, tem-se vários taps no enrolamento possibilitando a introdução artificial da falha de curto circuito entre espiras.

A Figura 12 ilustra o motor de 2cv rebobinado. Nele observa-se que foram introduzidos seis níveis de severidade para a falha de curto circuito i) 1% de Curto Circuito entre espiras ii) 3%, iii) 5%, iv) 10%, v) 15% e vi) 20%. Por meio de contatos elétricos é possível selecionar qual nível de falha aplicar.

Na construção da base de dados os níveis de severidade utilizados não ultrapassaram

Figura 11 – Formas de onda da base de dados.



Fonte: Autoria Própria.

Figura 12 – Motor com falha de estator.



Fonte: Autoria Própria.

o valor de 10% para evitar o *stress* excessivo no motor. Os sessenta casos de teste para cada nível de severidade foram definidos pela aplicação de dez níveis de desbalanço de tensão: i) sem desbalanço, ii) 2%, iii) 4%, iv) 6%, v) 8% e vi) 10% para apenas a fase A, e vii) 2%, viii) 4%,

iv) 6% e x) 8% para as fases B e C. Ainda são utilizados diferentes níveis de carga que foram definidos a vazio ao valor nominal para ambos os motores resultando em 6 níveis de torque:

- Motor de 1cv: i) Vazio, ii) 1N.m, iii) 2N.m, iv) 3N.m, v) 4N.m e vi) 5N.m.
- Motor de 2cv: i) Vazio, ii) 2N.m, iii) 4N.m, iv) 6N.m, v) 8N.m e vi) 9N.m.

4.1.2 Falha de rotor

A falha de rotor estudada neste trabalho foi a de barras quebradas. Neste contexto os aspectos metodológicos para sua reprodução em laboratório foi descrita por SUETAKE (2012) e GODOY (2016). O método proposto consiste em furar o rotor com uma broca de diâmetro superior a largura da barra. A Figura 13 apresenta um rotor no qual foi introduzida a falha de barras do rotor com um total de 4 barras quebradas.

Figura 13 – Rotor com quatro barras quebradas.



Fonte: Autoria Própria.

As falhas de rotor não levam a parada total do motor, porém levam a um maior esforço mecânico e consequentemente, o surgimento de novas falhas advindas desta falha primária. Neste trabalho quatro níveis de severidade foram estudados: i) 1 Barra, ii) 2 Barras, iii) 4 Barras e iv) 2|2 Barras contrapostas quebradas.

Da mesma forma que para a falha de estator, foram definidos dez níveis de desbalanço de tensão: i) Sem Desbalanço, ii) 2%, iii) 4%, iv) 6%, v) 8%, vi) 10%, apenas para as fases A, e vii) 2%, viii) 4%, ix) 6% x) 8% e 10% para a fase B e C. Estas condições de alimentação emulam as variações na rede elétrica que podem vir a ocorrer durante a operação deste motor. Em termos de carga mecânica tem-se os seguintes dados:

- Motor de 1cv: i) Vazio, ii) 1 N.m, iii) 1.5 N.m, iv) 2 N.m, v) 2.5 N.m, vi) 3 N.m, vii) 3.5 N.m, viii) 4 N.m, ix) 4.5 N.m, x) 5 N.m.
- Motor de 2cv: i) Vazio, ii) 1 N.m, iii) 2 N.m, iv) 3 N.m, v) 4 N.m, vi) 5 N.m, vii) 6 N.m, viii) 7 N.m, ix) 8 N.m, x) 9 N.m.

Para cada um dos níveis de severidade foram aplicados os diferentes níveis de desbalanço e de carga resultando nos 110 casos para cada nível de severidade da falha de rotor apresentado no Quadro 1.

4.1.3 Falha de rolamento

A falha de rolamento estudada neste trabalho foi o desgaste excessivo. A metodologia utilizada para a inserção de falha foi apresentada por BAZAN et al. (2019), LOPES et al. (2016), SCHMITT et al. (2015) e GONGORA (2013) e é causada principalmente por três causas: i) Falta de lubrificante, ii) Excesso de carga no eixo e iii) Longo tempo de operação do motor.

Para introduzir este defeito nos rolamentos o lubrificante foi substituída por uma pasta abrasiva, e o rolamento posto em funcionamento sem carga continuamente por períodos diferentes de tempo a fim de simular os quatro níveis de severidade: i) 15 min, ii) 30 min, iii) 60 min e iv) 90 min de desgaste. Após os referidos tempos de degradação a pasta abrasiva foi removida e os rolamentos foram novamente lubrificados. Durante todo o processo de degradação a tensão, a corrente e a temperatura foram monitorados assegurando que o motor estava operando corretamente. A Figura 14 apresenta um dos rolamentos degradados para os testes utilizados neste trabalho.

A fim de obter diferentes casos de teste, os motores foram submetidos a diversas condições de operação. Neste contexto, os motores foram submetidos a dez situações de desbalanço de tensão e de diferentes conjugados de carga os mesmos que as falhas de rotor.

Para cada um dos níveis de severidade foram aplicados diferentes níveis de desbalanço de tensão e de carga resultando em 110 casos para cada nível de severidade de falha de rolamento apresentado no Quadro 1.

4.2 IMPLEMENTAÇÃO DOS TESTES

Esta seção tem como objetivo apresentar de forma detalhada as quatro etapas utilizadas na implementação dos testes: i) Pré-Processamento dos dados, ii) Extração das características,

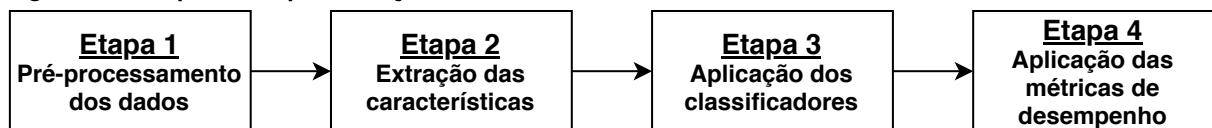
Figura 14 – Rolamento com desgaste.



Fonte: Autoria Própria.

iii) Aplicação dos classificadores e iv) Aplicação das métricas de desempenho. A relação entre as etapas está apresentada no fluxograma da Figura 15.

Figura 15 – Etapas da implementação dos testes.



Fonte: Autoria Própria.

4.2.1 Pré-processamento de dados

O pré-processamento da base de dados tem como objetivo adequar as amostras de dados descrita na Seção 4.1 para a realização dos testes, o qual é composto por quatro etapas:

- i) **Redução da taxa amostral:** A redução da taxa amostral tem como objetivo viabilizar o estudo da classificação de falha e nível de severidade com diversas taxas amostrais e assim analisar sua aplicação com equipamentos de mais baixo custo.
- ii) **Normalização:** A normalização neste trabalho é utilizada para padronizar os níveis de tensão e corrente para se adequar às funções de ativação.

- iii) **Janelamento:** O janelamento foi utilizado para reduzir o sinal aquisitado por um tempo de 10 segundos para um nível que seria possível trabalhar com a rede neural convolucional.
- iv) **Separação da base de dados:** A separação da base de dados foi feita com o objetivo de fornecer as bases de treinamento, teste e validação para a obtenção das métricas de desempenho.

4.2.1.1 Redução da taxa amostral

Este trabalho teve como um dos deus objetivos a análise do método proposto com diferentes taxas amostrais. A taxa amostral original das bases de dados é de 15ksps, e a frequência da rede elétrica que alimentou os motores de 60Hz. Portanto para cada ciclo da rede elétrica era o equivalente a 250 amostras.

Com o objetivo de manter a quantidade de amostras por ciclo em um valor inteiro foram definidas outras quatro taxas amostrais e a taxa de redução (n_{rd}) conforme apresentado no Quadro 2.

Quadro 2 – Definição das taxas amostrais

Taxa amostral	Amostras por ciclo	n_{rd}
15ksps	250	1
7,5ksps	125	2
3ksps	50	5
1,5ksps	25	10

Fonte: Autoria Própria.

A Figura 16 ilustra como foi o procedimento da redução da taxa amostral utilizada neste trabalho, a partir da taxa de redução n_{rd} . Assim, para cada vetor foi salvo o primeiro valor e os próximos $n_{rd} - 1$ foram descartados.

4.2.1.2 Normalização

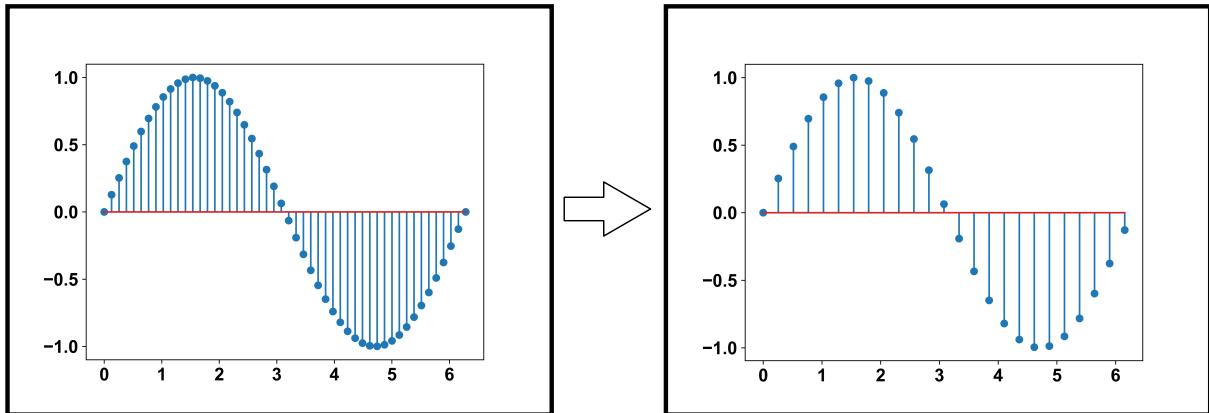
A normalização dos dados neste trabalho teve como objetivo evitar a saturação dos neurônios e adequar a base dados dos motores de 1cv e de 2cv dentro de limites similares. Desta forma, busca-se a generalização da solução para os dois motores.

A técnica utilizada para a normalização foi apresentada por SILVA, SPATTI e FLAUZINO (2010) e consiste em obter o valor máximo e mínimo das amostras de dados e aplicar a técnica de escalonamento baseada no princípio dos segmentos proporcionais dada pela equação (27)

$$z = \frac{x - x^{\min}}{x^{\max} - x^{\min}} \quad (27)$$

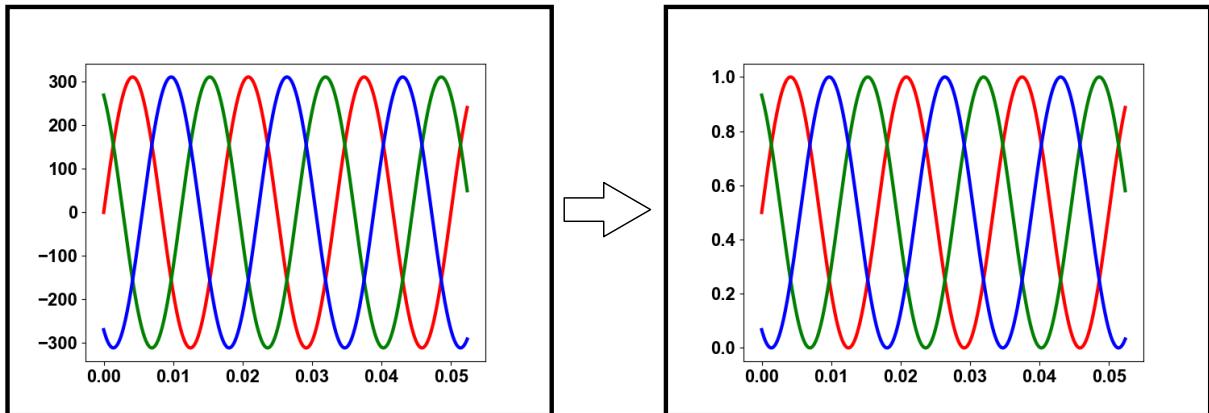
A Figura 17 ilustra o resultado desta transformação, onde o sinal que possui uma variação entre -311 e 311 foi normalizado entre 0 e 1.

Figura 16 – Redução da taxa amostral da base de dados.



Fonte: Autoria Própria.

Figura 17 – Normalização dos dados.



Fonte: Autoria Própria.

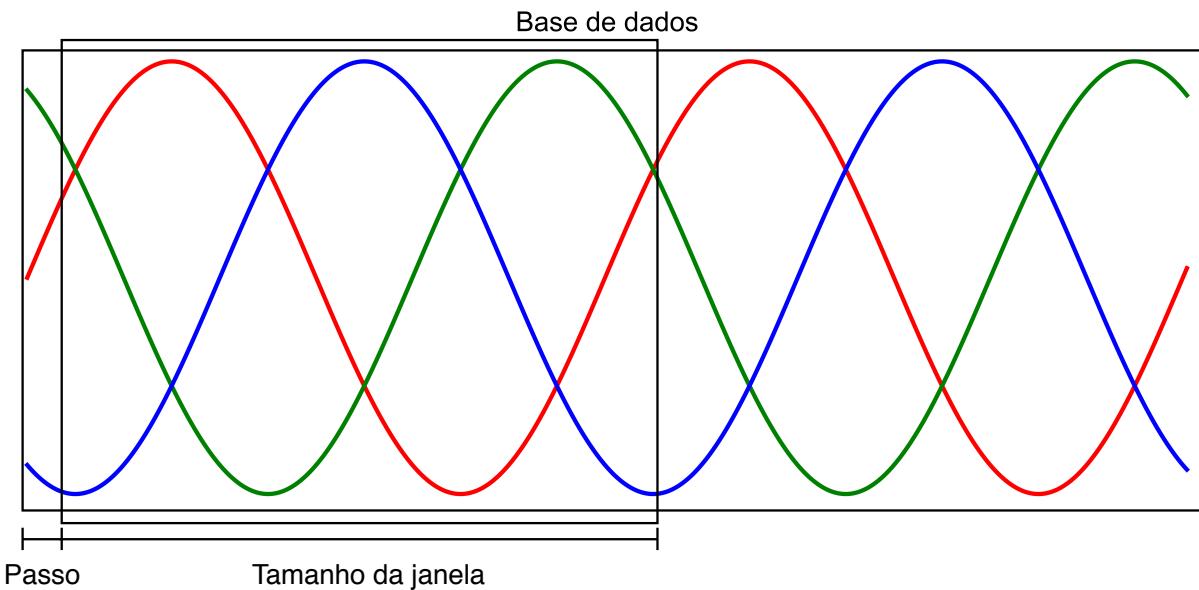
Para aplicação do método todos os sinais de tensão e corrente foram normalizados a partir de seus valores máximo e mínimo para valores entre 0 e 1.

4.2.1.3 Janelamento

A técnica de janelamento utilizada neste trabalho foi a da janela deslizante ilustrada na Figura 18 e teve como objetivo a expansão da base de dados. A sua implementação foi realizada obtendo primeiramente 500 pontos de cada um dos atributos e de cada amostra de dados e, em seguida, foi determinada uma janela de 250 amostras (Quantidade de amostras de um período de uma onda senoidal com 60Hz com 15ksps). Este passo da janela que foi determinado como 1 amostra.

O janelamento descrito, foi aplicado às diferentes taxas amostrais estudadas neste trabalho: i) 15ksps, ii) 7,5ksps, iii) 3ksps e iv) 1,5ksps. Em todos os casos foram utilizadas 250 amostras. Assim, a quantidade de ciclos da forma de onda senoidal foi diferente para cada taxa

Figura 18 – Janelamento dos dados.



Fonte: Autoria Própria.

amostral e esta quantidade de ciclos está apresentada na Tabela 3.

Tabela 3 – Quantidade de ciclos por taxa amostral no janelamento

Taxa Amostral	Ciclos de onda
15ksps	1
7,5ksps	2
3ksps	5
1,5ksps	10

Fonte: Autoria Própria.

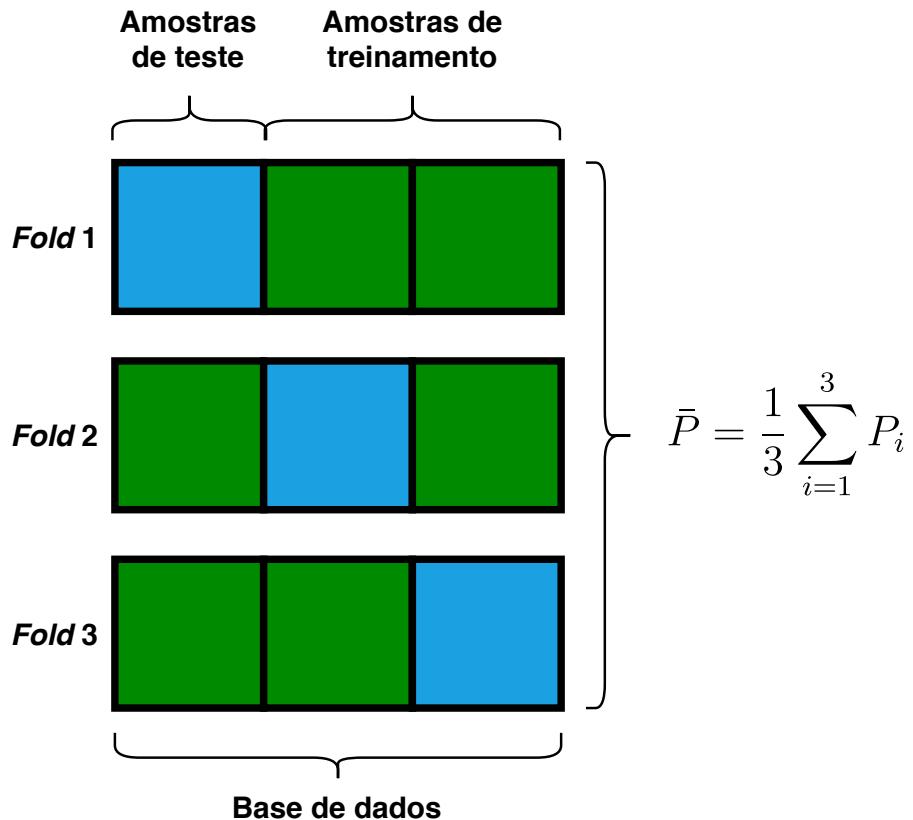
4.2.1.4 Separação da base de dados

A separação da base de dados teve como objetivo aumentar a confiabilidade dos resultados obtidos. A técnica utilizada foi a *K-Folds* descrita por SILVA, SPATTI e FLAUZINO (2010) e está ilustrada na Figura 19.

Na técnica de validação *K-Folds* o teste é realizado com toda a base de dados por meio de múltiplos treinamentos e validações. Neste trabalho o número de *Folds* determinado foi de $K = 3$. Neste caso a base de dados foi dividida em 3 partes e foram realizados 3 testes onde em cada teste era apresentado 2/3 da base de dados no treinamento e 1/3 no teste.

Por fim foi calculada a média das três métricas obtidas em cada treinamento e teste bem como o desvio padrão, fornecendo uma maior confiabilidade para o resultado, pois os testes foram realizados com toda a base de dados.

Figura 19 – Técnica de validação *K-Folds*.



Fonte: Autoria Própria.

4.2.2 Desenvolvimento das topologias de extração de características

Esta seção tem como objetivo apresentar como as topologias de extração de características foram desenvolvidas e quais foram os critérios utilizados para a seleção de cada um dos parâmetros.

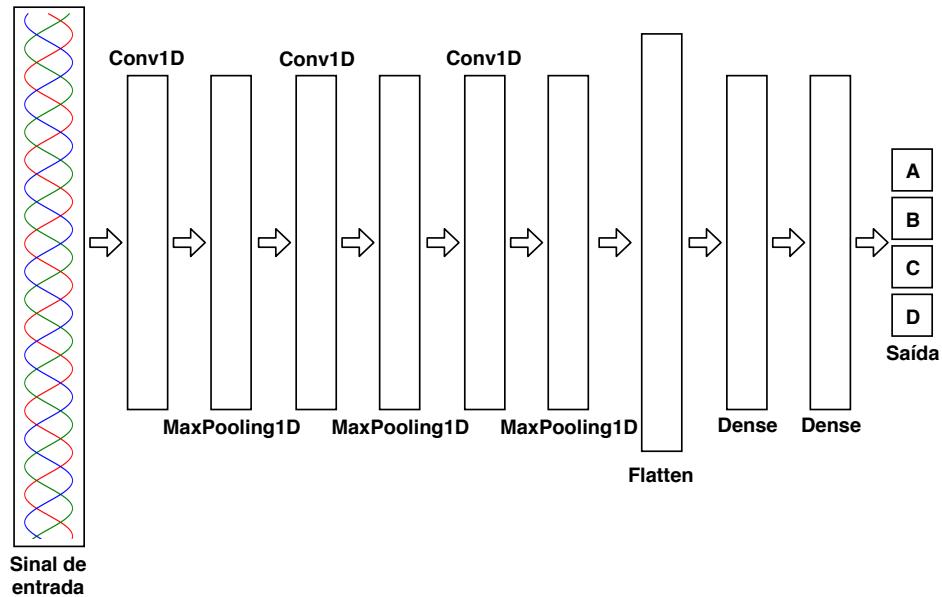
A topologia de extração de características é composta por diversas camadas. Neste trabalho utilizam-se sete camadas, sendo três camadas convolucionais, três camadas de Pooling e uma camada de Achatamento (*Flatten*). A estrutura completa das camadas convolucionais e do classificador PMC está representada na Figura 20 que também apresenta as camadas Dense¹ para auxiliar no seu treinamento.

A quantidade de filtros de cada uma das camadas foi estipulado a fim de obter na camada de achatamento um número pré estabelecido de amostras sendo elas: i) Topologia A - 128 Amostras, ii) Topologia B - 64 Amostras, ii) Topologia C - 32 Amostras, iv) Topologia D - 16 Amostras.

A Tabela 4 apresenta a quantidade de filtros, tamanho do kernel e a função de ativação de cada uma das camadas convolucionais bem como o tamanho do *pool* de cada uma das camadas de MaxPooling.

¹Camada com os neurônios totalmente conectados

Figura 20 – Estrutura das camadas de extração de características e do classificador PMC.



Fonte: Autoria Própria.

Tabela 4 – Estrutura das topologias de extração de características

Topologia	A	B
Camada 1	Conv1D($F = 64$, $KS = 3$, $AF = \text{'relu'}$)	Conv1D($F = 32$, $KS = 3$, $AF = \text{'relu'}$)
Camada 2	MaxPooling1D($PS = 3$)	MaxPooling1D($PS = 3$)
Camada 3	Conv1D($F = 32$, $KS = 3$, $AF = \text{'relu'}$)	Conv1D($F = 16$, $KS = 3$, $AF = \text{'relu'}$)
Camada 4	MaxPooling1D($PS = 3$)	MaxPooling1D($PS = 3$)
Camada 5	Conv1D($F = 16$, $KS = 3$, $AF = \text{'relu'}$)	Conv1D($F = 8$, $KS = 3$, $AF = \text{'relu'}$)
Camada 6	MaxPooling1D($PS = 3$)	MaxPooling1D($PS = 3$)
Camada 7	<i>Flatten</i>	<i>Flatten</i>
Topologia	C	D
Camada 1	Conv1D($F = 16$, $KS = 3$, $AF = \text{'relu'}$)	Conv1D($F = 8$, $KS = 3$, $AF = \text{'relu'}$)
Camada 2	MaxPooling1D($PS = 3$)	MaxPooling1D($PS = 3$)
Camada 3	Conv1D($F = 8$, $KS = 3$, $AF = \text{'relu'}$)	Conv1D($F = 4$, $KS = 3$, $AF = \text{'relu'}$)
Camada 4	MaxPooling1D($PS = 3$)	MaxPooling1D($PS = 3$)
Camada 5	Conv1D($F = 4$, $KS = 3$, $AF = \text{'relu'}$)	Conv1D($F = 2$, $KS = 3$, $AF = \text{'relu'}$)
Camada 6	MaxPooling1D($PS = 3$)	MaxPooling1D($PS = 3$)
Camada 7	<i>Flatten</i>	<i>Flatten</i>

Fonte: Autoria Própria.

Onde:

F: Número de Filtros;

KS: Tamanho do Kernel;

AF: Função de Ativação;

Conv1D: Camada de Convolução 1D;

MaxPooling1D: Camada de Pooling 1D.

4.2.3 Desenvolvimento dos classificadores

Esta seção tem como objetivo apresentar como foi o desenvolvimento de cada um dos quatro classificadores utilizados neste trabalho, a saber: i) Perceptron MultiCamadas, ii) Naive Bayes, iii) Máquina de Vetor de Suporte e iv) K-Próximos Vizinhos, sendo que em todos os testes a configuração dos classificadores foi igual.

O classificador PMC desenvolvido neste trabalho foi usado na classificação e ajuste das camadas convolucionais e possui três camadas. A primeira camada é composta por 256 neurônios totalmente conectados com função de ativação ReLU, a segunda camada é composta por 128 neurônios também totalmente conectados e com função de ativação ReLU, já a última camada é composta por apenas 4 neurônios e a função de ativação softmax.

Tabela 5 – Estrutura das topologias convolucionais

Camada	Número de Neurônios	Função de ativação
Camada 1	256	relu
Camada 2	128	relu
Camada 3	4	softmax

Fonte: Autoria Própria.

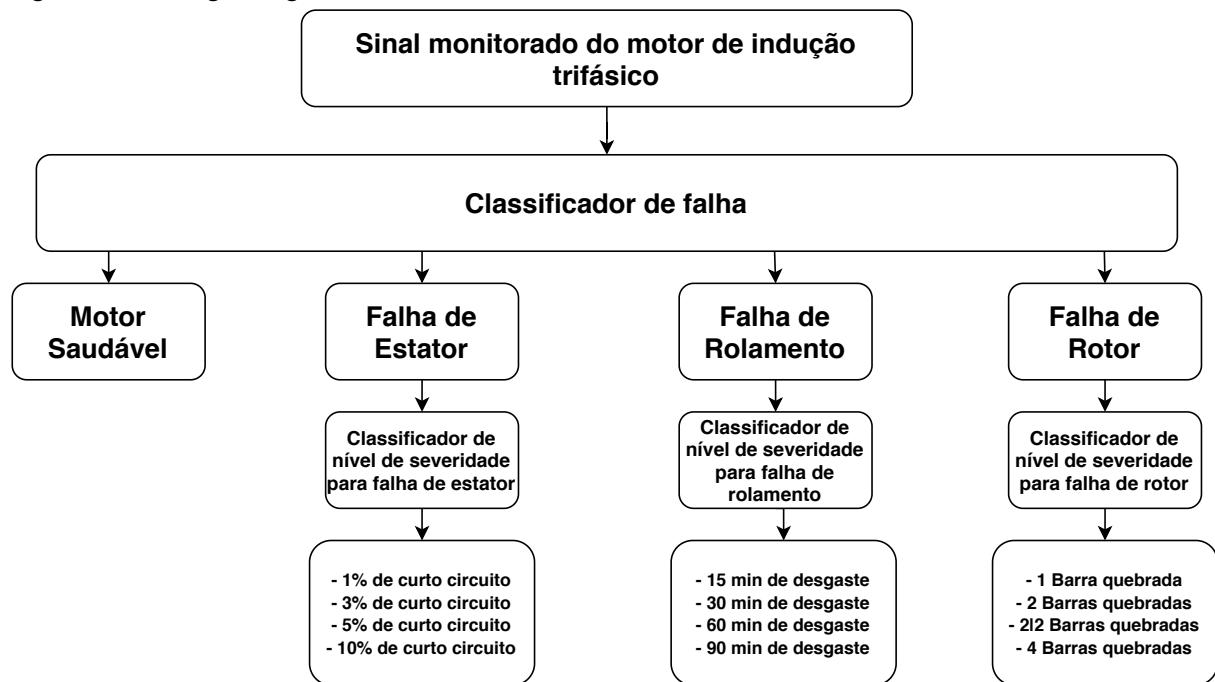
A implementação do classificador SVM se deu com o kernel Linear e a taxa de arredondamento foi estabelecida com o valor de 10^{-2} . O classificador KNN foi implementado com $K = 3$ vizinhos e a métrica utilizada foi a distância euclidiana.

4.3 CONCLUSÃO DO CAPÍTULO

Este capítulo teve como objetivo descrever a base de dados, os atributos que a compõe e os casos de teste que ela aborda. Neste capítulo também foram apresentadas as quatro etapas realizadas no teste: i) Pré-processamento dos dados, ii) Extração das características, iii) Aplicação dos classificadores e iv) Aplicação das métricas de desempenho.

Neste trabalho tem-se dois tipos de classificação: i) falha, ii) nível de severidade. O segundo classificador é dependente da primeira classificação e a análise de nível de severidade foi realizada utilizando uma estrutura hierárquica conforme apresentado na Figura 21.

Figura 21 – Fluxograma geral da estrutura dos classificadores.



Fonte: Autoria Própria.

5 RESULTADOS E DISCUSSÕES

Este capítulo tem como objetivo apresentar as métricas obtidas na classificação de falha e de nível de severidade no MIT. Ainda, são estudados os atributos de tensão e corrente e apenas corrente.

Nos testes tem-se diferentes topologias, classificadores e taxas amostrais aplicadas para identificar qual é a melhor configuração para a resolução do problema. A metodologia utilizada nos testes para a obtenção dos resultados e as métricas de desempenho, bem como o detalhamento das bases de dados são descritos no Capítulo 4. O Apêndice deste trabalho apresenta o desvio padrão de todos os resultados.

5.1 ANÁLISE GLOBAL DOS RESULTADOS

Esta seção tem o objetivo de fornecer uma visão geral sobre os resultados obtidos nos experimentos realizados. Em seguida é apresentada uma discussão sobre os questionamentos contidos na Seção 1.4 viabilizando a implementação da metodologia proposta.

5.1.1 Classificação de falha

Esta seção apresenta as métricas obtidas pelos classificadores com as diferentes topologias convolucionais e taxas amostrais, considerando duas técnicas de validação: i) K-Folds e com o ii) Teste de generalização entre motores. Em todos os testes é apresentado um gráfico comparando a acurácia obtida em todas as configurações.

Primeiramente as métricas foram obtidas utilizando a técnica de validação K-Folds. Com objetivo de validar a estratégia e aumentar a confiabilidade do resultado é aplicado o método de classificação em duas bases de dados: i) Motor de 1cv e ii) Motor de 2cv.

Em seguida a fim de validar a capacidade de generalização do modelo, as métricas foram obtidas por meio do teste de generalização entre motores que consiste em:

- i) Treinamento e validação com a base de dados do motor de 1cv e teste com a base de dados do motor de 2cv
- ii) Treinamento e validação com a base de dados do motor de 2cv e teste com a base de dados do motor de 1cv

5.1.1.1 Métricas de teste K-Folds

Primeiramente as métricas foram obtidas com o teste de validação K-Folds para os motores de 1cv e 2cv. A definição da melhor topologia em todos os testes ocorreu primeiramente pela maior acurácia e em seguida, caso houvesse dois classificadores com a mesma acurácia, pelo índice Kappa e a pontuação F1.

A Tabela 6 apresenta as métricas de desempenho das topologias convolucionais que obtiveram o melhor resultado para todos os classificadores e taxas amostrais analisados, considerando os atributos de tensão e corrente.

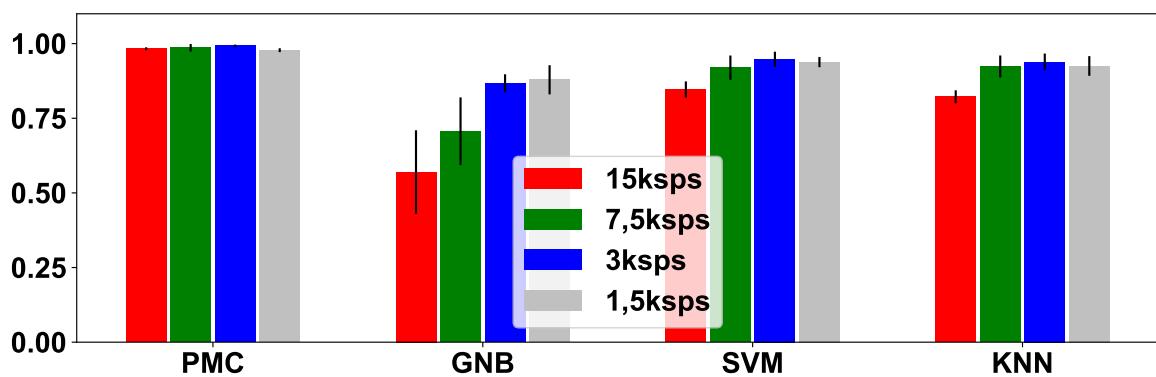
Tabela 6 – Melhores topologias - Classificação de Falha - Atributos de tensão e corrente

Melhores topologias - Classificação de Falha - Motor de 1cv - Atributos de tensão e corrente																
Classificador	15ksp				7,5ksp				3ksp				1,5ksp			
	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN
Topologia	A	C	A	A	A	B	A	B	B	B	A	B	A	A	A	A
Acurácia	0,983	0,570	0,846	0,822	0,986	0,707	0,920	0,924	0,993	0,867	0,948	0,939	0,978	0,879	0,938	0,925
Precisão	0,979	0,555	0,769	0,768	0,979	0,669	0,892	0,900	0,991	0,845	0,944	0,920	0,977	0,865	0,930	0,912
Recall	0,983	0,497	0,726	0,751	0,983	0,681	0,844	0,879	0,990	0,842	0,902	0,935	0,964	0,855	0,877	0,903
F1	0,981	0,521	0,746	0,759	0,981	0,675	0,867	0,890	0,991	0,843	0,923	0,927	0,971	0,859	0,902	0,908
Kappa	0,975	0,366	0,774	0,742	0,980	0,587	0,883	0,890	0,989	0,810	0,924	0,913	0,968	0,827	0,910	0,892

Melhores topologias - Classificação de Falha - Motor de 2cv - Atributos de tensão e corrente																
Classificador	15ksp				7,5ksp				3ksp				1,5ksp			
	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN
Topologia	B	A	A	D	A	A	A	A	A	B	A	B	A	B	A	A
Acurácia	0,984	0,532	0,863	0,871	0,994	0,721	0,928	0,955	0,994	0,775	0,957	0,975	0,953	0,707	0,874	0,822
Precisão	0,978	0,526	0,883	0,870	0,995	0,739	0,945	0,963	0,996	0,782	0,967	0,977	0,955	0,711	0,899	0,825
Recall	0,974	0,551	0,785	0,831	0,986	0,717	0,878	0,944	0,985	0,742	0,938	0,962	0,933	0,689	0,825	0,755
F1	0,976	0,538	0,831	0,850	0,991	0,727	0,909	0,953	0,990	0,760	0,952	0,970	0,944	0,699	0,860	0,788
Kappa	0,977	0,369	0,800	0,813	0,992	0,600	0,895	0,935	0,992	0,676	0,938	0,964	0,932	0,590	0,816	0,740

A Figura 22 ilustra os dados apresentados na Tabela 6 para o motor de 1cv. Nesta figura é possível observar que o melhor classificador em todas as condições de teste é o PMC, obtendo acurácia de 0,993 com a topologia B com a taxa amostral de 3 ksp. Ainda, neste caso é obtido um índice Kappa elevado de 0,989 indicando um grau de concordância perfeito segundo a escala apresentada na Seção 3.3.1.

Figura 22 – Comparativo - Classificação de falha - Motor de 1cv - Atributos de tensão e corrente.



Fonte: Autoria Própria

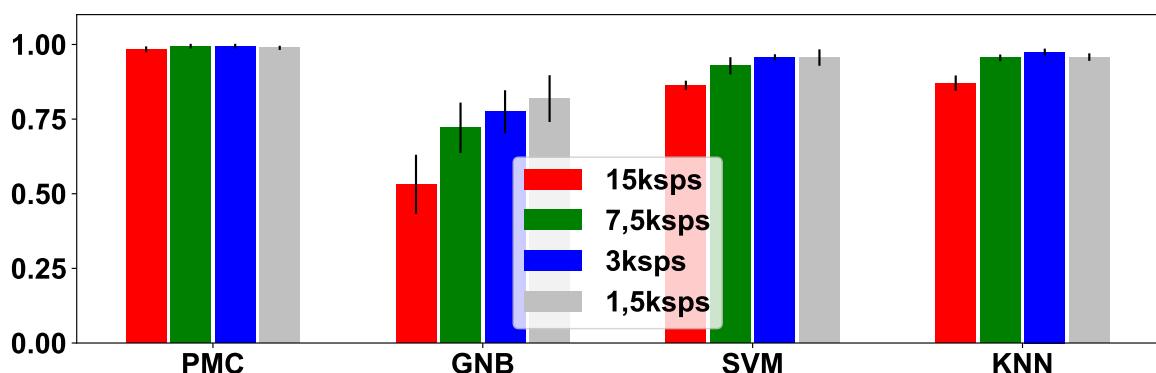
Os demais classificadores para as taxas amostrais de 15 ksp e 7,5 ksp, no teste com o motor de 1cv foram capazes de classificar as falhas no MIT com uma acurácia superior a 0,840

e mantiveram o índice Kappa superior a 0,700, com excessão do GNB.

O mesmo comportamento visto na análise da classificação de falha no motor de 1cv também observado na análise do motor de 2cv. Na Figura 23 são ilustrados os dados apresentados na Tabela 6 para o referido motor. Assim, o melhor classificador é o PMC atingindo a maior acurácia 0,994 com a topologia A para as taxas amostrais de 7,5 ksps e 3 ksps com um resultado muito semelhante. Em ambos os casos o índice Kappa é de 0,992 indicando também um grau de concordância perfeito como na análise do motor de 1cv.

A pior performance novamente está associada ao classificador GNB mantendo uma acurácia inferior aos outros classificadores em todos os testes e um índice Kappa com o grau de concordância moderado e fraco.

Figura 23 – Comparativo - Classificação de falha - Motor de 2cv - Atributos de tensão e corrente.



Fonte: Autoria Própria

Na análise de classificação de falha é possível observar que a metodologia de extração de característica de falha e classificação proposta atingiu o objetivo sendo capaz de classificar corretamente as três classes de falhas e a classe de motor saudável com um alto nível de confiabilidade indicado pela alta acurácia e índice Kappa.

Com o objetivo de analisar a capacidade de classificação de falha no MIT com a menor quantidade de sensores possível, é realizada a análise da classificação de falha apenas com os atributos de corrente, onde as métricas de desempenho das melhores topologias para cada classificador e taxa amostral dos dois motores testados são apresentados na Tabela 7.

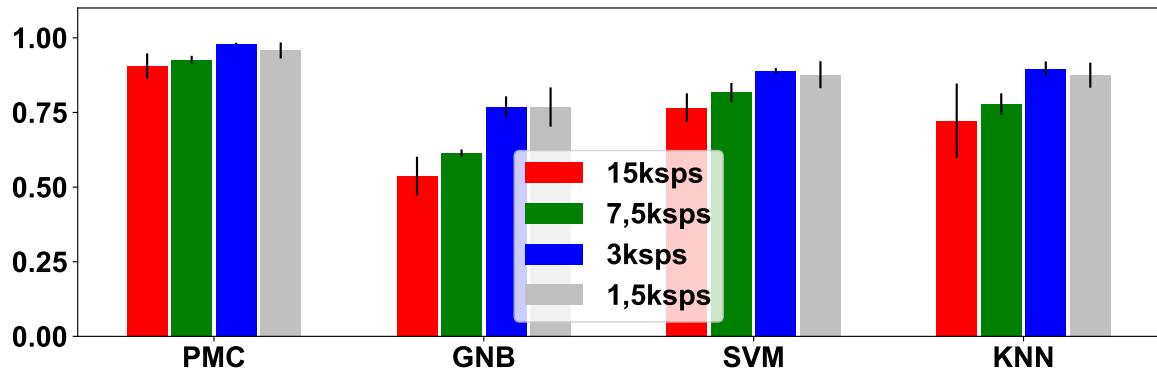
Analizando a Figura 24 observa-se que o melhor classificador é o PMC com a acurácia de 0,980 e índice Kappa de 0,971 para a topologia A com a taxa amostral de 3 ksps. De forma comparativa, tem-se a redução pouco significativa na performance frente ao resultado com os atributos de tensão e corrente que é de 0,993 para a acurácia e de 0,989 para o índice Kappa.

A pior performance obtida com o motor de 1cv utiliza o classificador GNB. Neste caso, as análises com a taxa amostral de 15 ksps e 7,5 ksps obtiveram uma acurácia inferior a 0,650 e o índice Kappa inferior a 0,500 com o grau de concordância abaixo de moderada.

Tabela 7 – Melhores topologias - Classificação de Falha - Atributos de corrente

Melhores topologias - Classificação de Falha - Motor de 1cv - Atributos de corrente																
Classificador	15ksps				7,5ksps				3ksps				1,5ksps			
	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN
Topologia	A	A	A	A	A	A	A	B	A	A	A	A	A	A	A	A
Acurácia	0,905	0,537	0,766	0,722	0,927	0,614	0,817	0,778	0,980	0,767	0,889	0,897	0,958	0,768	0,876	0,875
Precisão	0,885	0,508	0,701	0,683	0,907	0,584	0,682	0,734	0,978	0,739	0,876	0,880	0,959	0,753	0,851	0,858
Recall	0,871	0,482	0,662	0,662	0,896	0,614	0,678	0,732	0,971	0,777	0,825	0,871	0,950	0,752	0,809	0,842
F1	0,878	0,495	0,680	0,672	0,901	0,598	0,679	0,733	0,974	0,758	0,850	0,875	0,954	0,752	0,829	0,850
Kappa	0,863	0,336	0,654	0,598	0,895	0,467	0,729	0,681	0,971	0,673	0,839	0,851	0,939	0,669	0,819	0,819

Melhores topologias - Classificação de Falha - Motor de 2cv - Atributos de corrente																
Classificador	15ksps				7,5ksps				3ksps				1,5ksps			
	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN
Topologia	A	A	A	A	A	A	A	A	A	A	A	A	A	B	A	B
Acurácia	0,900	0,448	0,650	0,699	0,938	0,420	0,729	0,726	0,971	0,649	0,923	0,886	0,953	0,707	0,874	0,851
Precisão	0,899	0,468	0,638	0,727	0,941	0,459	0,713	0,707	0,968	0,692	0,915	0,894	0,955	0,711	0,899	0,848
Recall	0,875	0,404	0,570	0,646	0,926	0,431	0,650	0,657	0,955	0,638	0,889	0,850	0,933	0,689	0,825	0,802
F1	0,887	0,432	0,602	0,684	0,934	0,444	0,680	0,681	0,962	0,664	0,902	0,871	0,944	0,699	0,860	0,824
Kappa	0,855	0,200	0,487	0,558	0,911	0,233	0,602	0,600	0,958	0,521	0,888	0,835	0,932	0,590	0,816	0,784

Figura 24 – Comparativo - Classificação de falha - Motor de 1cv - Atributos de corrente.

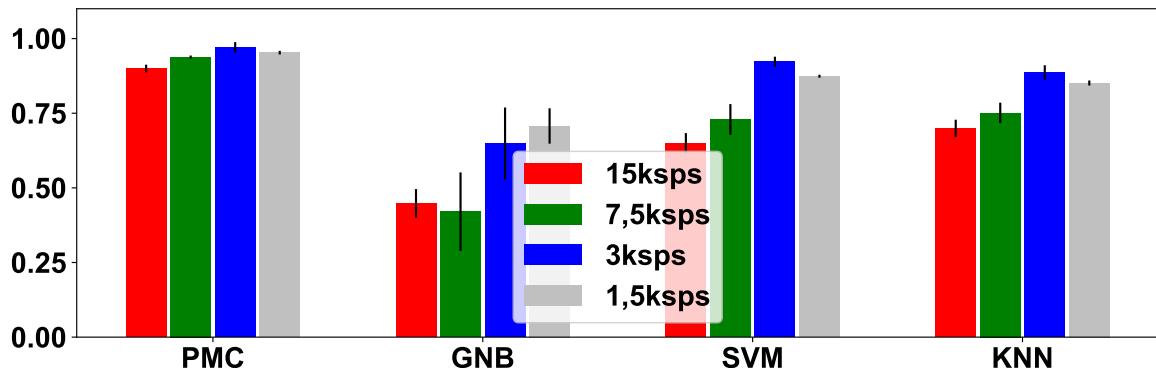
Fonte: Autoria Própria

A Figura 25 apresenta a métrica de acurácia para o teste de classificação de falha com os atributos de corrente para o motor de 2cv. Nela observa-se que o melhor classificador é o PMC com acuráncias superiores a 0,900 para todas as configurações, sendo que a melhor performance foi obtida com a taxa amostral de 3 ksps com a topologia convolucional A onde o classificador obteve a acurácia de 0,971 e o índice Kappa de 0,958 indicando um grau de concordância perfeito.

Na análise de classificação de falha com os atributos de corrente novamente a pior performance ocorre com o classificador GNB onde o índice Kappa em todos os testes indicou o grau de concordância inferior ao moderada.

Conclui-se por meio da análise dos resultados obtidos na classificação de falha no MIT e considerando a estratégia proposta com os atributos de tensão e corrente e apenas os

Figura 25 – Comparativo - Classificação de falha - Motor de 2cv - Atributos de corrente.



Fonte: Autoria Própria

atributos de corrente é possível observar que há uma perda de performance relativamente pouco significativa, indicando que a classificação de falha pode ser realizada apenas com os atributos de corrente.

5.1.1.2 Métricas do teste de generalização

Nesta seção é apresentado o resultado da performance dos classificadores considerando o teste de generalização entre motores, a fim de testar a robustez do método frente a informações de um motor com parâmetros completamente diferentes.

Neste caso são realizadas duas análises i) As topologias convolucionais e os classificadores foram treinados e validados com a base de dados do motor de 1cv e o teste é realizado com a base de dados do motor de 2cv e ii) As topologias convolucionais e os classificadores foram treinados e validados com a base de dados do motor de 2cv e o teste é realizado com a base de dados do motor de 1cv.

Da mesma forma que na análise de falha por meio da técnica de validação *K-Folds*, a melhor topologia é definida primeiramente pela maior acurácia e em seguida caso fosse igual em dois casos, seria definido pelo índice *Kappa* e pela pontuação *F1*.

A Tabela 8 apresenta as métricas de desempenho para as topologias, classificadores e taxas amostrais que obtiveram os melhores resultados considerando os atributos de tensão e corrente no teste de generalização entre motores.

Na Figura 26 observa-se a métrica de acurácia para a análise de identificação de falha no MIT com o treinamento utilizando o motor de 1cv e teste com motor de 2cv. Na referida figura é possível constatar que o melhor classificador em todos os casos de teste é o PMC visto que obteve a maior acurácia. A melhor performance é alcançada com a taxa amostral de 1,5 ksp com o classificador PMC e com a topologia D. Neste caso, a acurácia é de 0,839 com índice *Kappa* de 0,768 indicando uma concordância substancial.

O classificador que obteve a pior performance é o GNB onde as taxas amostrais de 15

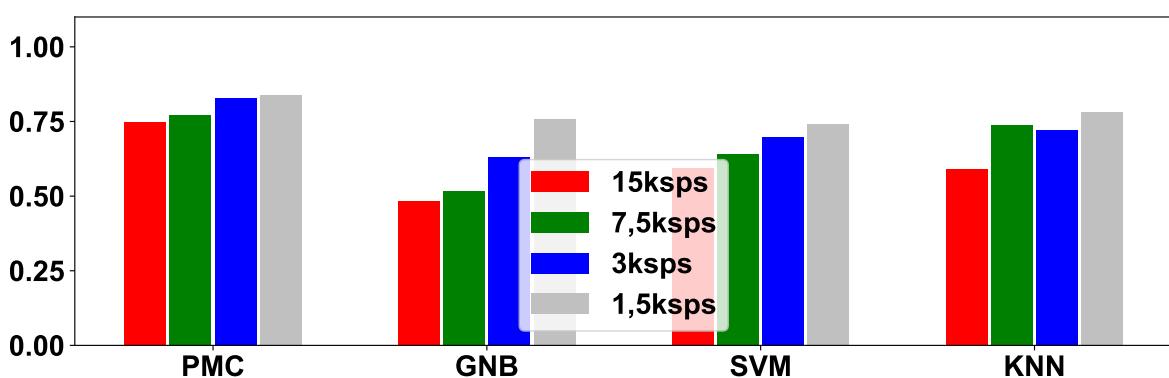
Tabela 8 – Melhores topologias - Classificação de Falha - Teste de generalização - Atributos de tensão e corrente

Melhores topologias - Classificação de Falha - Teste de generalização - Treinamento Motor 1cv, Teste 2cv - Atributos de tensão e corrente																
Classificador	15ksps				7,5ksps				3ksps				1,5ksps			
	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN
Topologia	A	C	B	C	A	C	A	C	B	A	A	B	D	D	D	D
Acurácia	0,748	0,485	0,594	0,589	0,772	0,517	0,640	0,737	0,829	0,630	0,698	0,722	0,839	0,759	0,741	0,780
Precisão	0,736	0,395	0,486	0,580	0,763	0,497	0,649	0,731	0,852	0,648	0,679	0,744	0,822	0,843	0,570	0,782
Recall	0,733	0,412	0,507	0,567	0,796	0,395	0,555	0,730	0,848	0,632	0,646	0,716	0,791	0,650	0,603	0,734
F1	0,734	0,403	0,496	0,573	0,779	0,440	0,598	0,731	0,850	0,640	0,662	0,730	0,806	0,734	0,586	0,757
Kappa	0,639	0,232	0,396	0,417	0,676	0,259	0,467	0,624	0,755	0,483	0,563	0,598	0,768	0,641	0,614	0,681

Melhores topologias - Classificação de Falha - Teste de generalização - Treinamento Motor 2cv, Teste 1cv - Atributos de tensão e corrente																
Classificador	15ksps				7,5ksps				3ksps				1,5ksps			
	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN
Topologia	B	D	B	D	B	B	A	A	C	C	C	A	A	B	A	A
Acurácia	0,655	0,469	0,590	0,573	0,817	0,544	0,691	0,733	0,781	0,613	0,708	0,689	0,714	0,612	0,701	0,627
Precisão	0,621	0,361	0,453	0,552	0,787	0,510	0,663	0,719	0,733	0,575	0,709	0,678	0,588	0,609	0,584	0,609
Recall	0,652	0,412	0,514	0,553	0,822	0,479	0,674	0,744	0,737	0,526	0,615	0,710	0,583	0,529	0,579	0,578
F1	0,636	0,385	0,482	0,552	0,804	0,494	0,668	0,731	0,735	0,549	0,659	0,693	0,585	0,566	0,581	0,593
Kappa	0,520	0,225	0,400	0,401	0,742	0,335	0,570	0,624	0,688	0,431	0,572	0,575	0,571	0,438	0,554	0,472

ksps e 7,5 ksps obtiveram a concordância fraca e acurácia respectivamente de 0,485 e 0,517. Para o GNB, tem-se a melhor performance do classificador com a taxa amostral de 1,5 ksps onde ele obteve a acurácia de 0,759 com um índice de concordância moderada.

Figura 26 – Comparativo - Classificação de falha - Teste de generalização entre motores - Treinamento com motor de 1cv e Teste com motor de 2cv - Atributos de tensão e corrente.



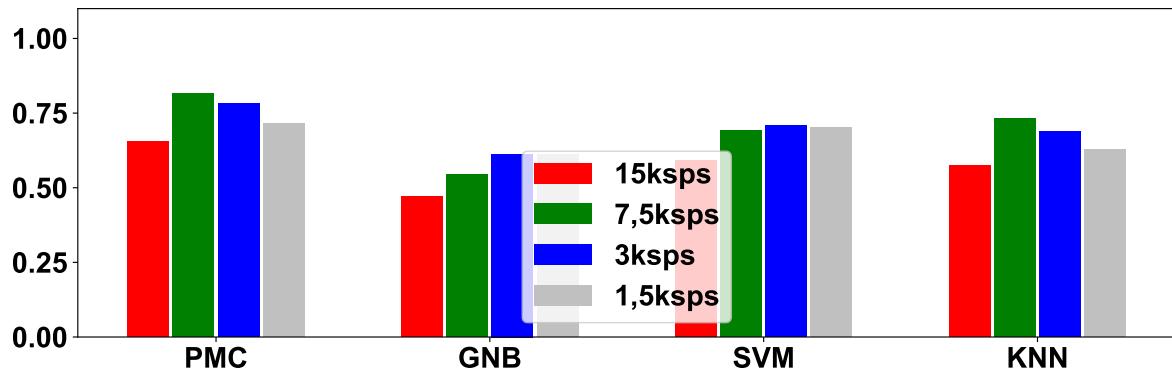
Fonte: Autoria Própria

A Figura 27 ilustra os dados de acurácia referentes ao teste de classificação de falha por meio do teste de generalização entre motores onde o treinamento utilizou o motor de 2cv e o teste com motor de 1cv. Neste caso, observa-se que a maior acurácia 0,817 ocorreu com o classificador PMC e taxa amostral de 7,5 ksps. O índice Kappa neste caso indicou uma concordância substancial, onde o método proposto é capaz de generalizar o problema.

A pior performance dentre os classificadores novamente é a do GNB obtendo uma

assertividade fraca na classificação com as taxas amostrais de 15 ksps e 7,5 ksps e uma concordância moderada com as taxas amostrais de 3 ksps e 1,5 ksps.

Figura 27 – Comparativo - Classificação de falha - Teste de generalização entre motores - Treinamento com motor de 2cv e Teste com motor de 1cv - Atributos de tensão e corrente.



Fonte: Autoria Própria

Comparando os resultados obtidos com a técnica de validação *K-Folds* e o teste de generalização entre motores, observa-se que o desempenho do teste de generalização é inferior. Entretanto, ainda é capaz de classificar corretamente com uma alta confiabilidade as falhas no MIT. Isso ocorre devido ao fato de que os parâmetros elétricos e mecânicos do motor de teste são completamente diferentes, e ter sido apresentado apenas um motor na etapa de treinamento, dificultando a extração de características globais de falhas e a generalização do modelo.

Na Tabela 9 são apresentadas as métricas referente aos teste de generalização com os atributos de corrente podem ser observados.

Tabela 9 – Melhores topologias - Classificação de Falha - Teste de generalização - Atributos de corrente

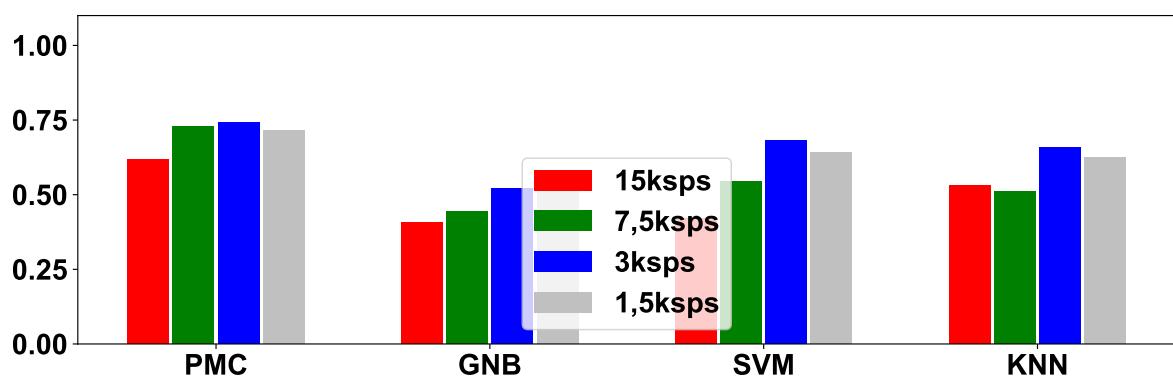
Melhores topologias - Classificação de Falha - Teste de generalização - Treinamento Motor 1cv, Teste 2cv - Atributos de corrente																
Classificador	15ksps				7,5ksps				3ksps				1,5ksps			
	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN
Topologia	A	B	B	C	A	A	A	A	A	C	A	A	A	C	A	B
Acurácia	0,618	0,407	0,421	0,531	0,730	0,443	0,544	0,611	0,741	0,520	0,681	0,659	0,715	0,543	0,643	0,626
Precisão	0,602	0,299	0,345	0,521	0,742	0,509	0,516	0,604	0,776	0,569	0,643	0,670	0,704	0,505	0,629	0,616
Recall	0,590	0,329	0,318	0,507	0,702	0,449	0,482	0,606	0,731	0,448	0,580	0,669	0,707	0,469	0,621	0,622
F1	0,596	0,313	0,331	0,514	0,721	0,477	0,499	0,605	0,753	0,501	0,610	0,670	0,706	0,486	0,625	0,619
Kappa	0,455	0,124	0,114	0,330	0,609	0,221	0,328	0,444	0,624	0,284	0,527	0,514	0,592	0,328	0,488	0,468

Melhores topologias - Classificação de Falha - Teste de generalização - Treinamento Motor 2cv, Teste 1cv - Atributos de corrente																
Classificador	15ksps				7,5ksps				3ksps				1,5ksps			
	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN
Topologia	C	C	A	C	A	C	C	B	A	C	A	A	A	D	A	A
Acurácia	0,566	0,383	0,462	0,493	0,611	0,422	0,541	0,533	0,663	0,519	0,570	0,553	0,700	0,493	0,573	0,607
Precisão	0,520	0,279	0,350	0,469	0,596	0,313	0,435	0,506	0,669	0,456	0,579	0,571	0,681	0,410	0,593	0,621
Recall	0,508	0,297	0,379	0,488	0,610	0,343	0,464	0,539	0,628	0,434	0,540	0,560	0,712	0,430	0,601	0,627
F1	0,514	0,288	0,364	0,478	0,603	0,327	0,449	0,522	0,648	0,445	0,559	0,565	0,696	0,420	0,597	0,624
Kappa	0,369	0,077	0,217	0,291	0,451	0,145	0,319	0,357	0,514	0,276	0,390	0,376	0,582	0,246	0,416	0,462

Na Figura 28 observa-se que a melhor performance novamente ocorreu com o classificador PMC para o teste de generalização com o treinamento com a base de dados referente ao motor de 1cv e treinamento com o motor de 2cv. A maior acurácia obtida é de 0,741 no teste com a taxa amostral de 3 ksps com a topologia A, e nesta mesma configuração, o índice Kappa indicou uma concordância substancial.

O classificador que apresentou a pior performance é o GNB onde todos os casos apresentaram uma concordância fraca. Os classificadores SVM e KNN obtiveram uma performance inferior ao PMC com concordância moderada nas taxas amostrais de 3 ksps e 1,5 ksps.

Figura 28 – Comparativo - Classificação de falha - Teste de generalização entre motores - Treinamento com motor de 1cv e Teste com motor de 2cv - Atributos de corrente.



Fonte: Autoria Própria

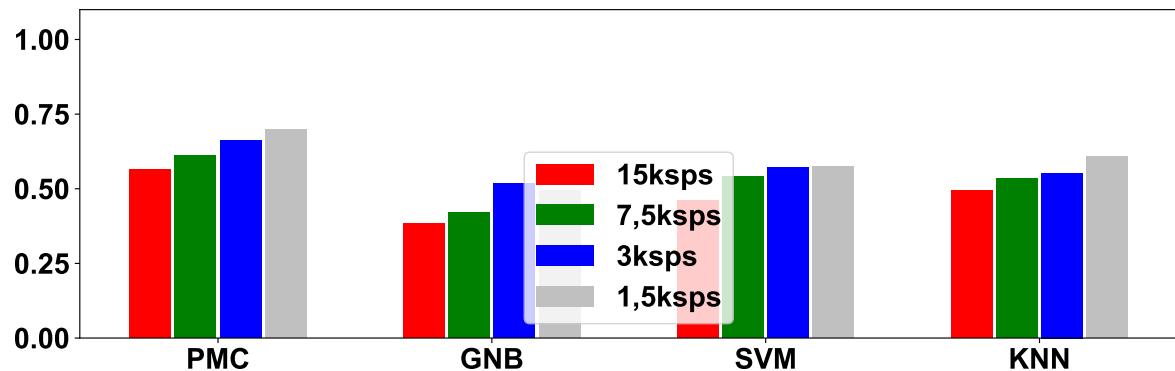
As acuráncias para o teste de generalização com o treinamento utilizando os dados do motor de 2cv e teste com o motor de 1cv são apresentados na Figura 29. Neste teste, a melhor performance é obtida com o classificador PMC com acurácia 0,700 e índice Kappa de 0,592 indicando uma concordância moderada.

O classificador GNB obteve assertividades igual ou abaixo de fraca, sendo o pior classificador aferido neste teste. Ainda, os classificadores SVM e KNN obtiveram performance também inferior quando comparados ao treinamento com o motor de 1cv e teste com o motor de 2cv. Os classificadores SVM e KNN também obtiveram com uma concordância fraca na maioria dos testes.

Analizando os resultados obtidos no teste de generalização entre motores e pelo método de *K-Folds* considerando os atributos de corrente, observa-se que no teste de generalização a performance dos classificadores é muito inferior. Isso indica que devido aos parâmetros do motor ser diferente o método de extração de características e de classificação não é capaz de generalizar o problema com precisão.

Em média a performance dos classificadores com o método de generalização entre motores é inferior ao da técnica *K-Folds*. Isto ocorre devido ao fato da extração de características ser automática, portanto não é possível garantir com apenas um indivíduo (no caso um motor)

Figura 29 – Comparativo - Classificação de falha - Teste de generalização entre motores - Treinamento com motor de 2cv e Teste com motor de 1cv - Atributos de corrente.



Fonte: Autoria Própria

que as camadas convolucionais encontrem características globais de falha, comprometendo assim a performance da classificação.

5.1.2 Classificação de nível de severidade

Esta seção tem como objetivo apresentar os melhores resultados dos testes de classificação de nível de severidade para cada uma das três falhas estudadas neste trabalho: i) Falha de estator, ii) Falha de rotor, e iii) Falha de rolamento. Nesta seção também é apresentado o estudo comparativo da classificação com os atributos de tensão e corrente e apenas os atributos de corrente.

A técnica de validação utilizada em todos os testes de classificação de nível de severidade é a *K-Folds* com $K = 3$.

5.1.2.1 Falha de estator

A Tabela 10 apresenta as métricas de desempenho para os classificadores e topologias que atingiram o melhor desempenho considerando os atributos de tensão e corrente. Em parte dos casos analisados os classificadores obtiveram uma ótima performance, indicado pelo índice Kappa que apresentou uma concordância superior de resultados.

Por meio da acurácia das melhores topologias para a classificação de nível de severidade da falha de estator considerando os atributos de tensão e corrente no motor de 1cv apresentado na Figura 30 o melhor classificador é o PMC. A Rede Neural Artificial (RNA) obteve uma acurácia de 0,971 com a taxa amostral de 3 ksp e topologia A e nesta mesma configuração o índice Kappa é de 0,961 indicando uma concordância perfeita.

Os classificadores SVM e KNN também foram capazes de classificar o nível de severidade para a falha de estator, com acurácia superior a 0,800 e concordância igual ou superior a

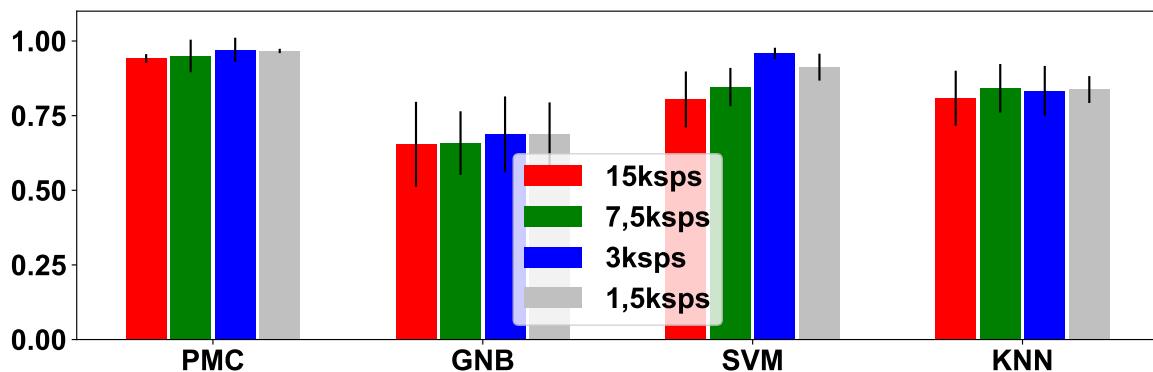
Tabela 10 – Melhores topologias - Classificação de nível de severidade - Falha de Estator - Atributos de tensão e corrente - K-Folds

Melhores topologias - Classificação de nível de severidade - Falha de Estator - Motor de 1cv - Atributos de tensão e corrente																
Classificador	15ksps				7,5ksps				3ksps				1,5ksps			
	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN
Topologia	A	C	A	B	A	A	A	D	A	A	A	A	A	A	A	A
Acurácia	0,942	0,654	0,804	0,808	0,950	0,658	0,846	0,842	0,971	0,688	0,958	0,833	0,967	0,688	0,913	0,838
Precisão	0,937	0,637	0,799	0,821	0,958	0,713	0,853	0,846	0,971	0,714	0,960	0,845	0,966	0,698	0,909	0,842
Recall	0,940	0,638	0,803	0,811	0,952	0,661	0,851	0,843	0,973	0,692	0,959	0,837	0,968	0,670	0,909	0,837
F1	0,938	0,637	0,801	0,816	0,955	0,686	0,852	0,844	0,972	0,702	0,960	0,841	0,967	0,684	0,909	0,840
Kappa	0,921	0,533	0,737	0,742	0,932	0,540	0,792	0,786	0,961	0,577	0,944	0,775	0,955	0,575	0,882	0,781

Melhores topologias - Classificação de nível de severidade - Falha de Estator - Motor de 2cv - Atributos de tensão e corrente																
Classificador	15ksps				7,5ksps				3ksps				1,5ksps			
	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN
Topologia	A	A	A	A	C	A	A	C	A	A	A	B	A	D	A	A
Acurácia	0,808	0,763	0,875	0,838	0,967	0,763	0,942	0,896	0,967	0,779	0,938	0,867	0,979	0,779	0,963	0,896
Precisão	0,821	0,766	0,873	0,854	0,968	0,771	0,946	0,904	0,969	0,811	0,941	0,875	0,983	0,792	0,971	0,911
Recall	0,811	0,756	0,877	0,836	0,967	0,745	0,937	0,896	0,969	0,779	0,939	0,866	0,981	0,779	0,964	0,898
F1	0,816	0,761	0,875	0,845	0,967	0,758	0,941	0,900	0,969	0,794	0,940	0,870	0,982	0,785	0,967	0,905
Kappa	0,742	0,678	0,831	0,780	0,955	0,679	0,921	0,859	0,955	0,702	0,916	0,820	0,972	0,703	0,949	0,859

substancial. O classificador GNB é o que obteve o pior desempenho, onde a melhor acurácia é de 0,688 para as taxas amostrais de 1,5ksps e 3ksps porem com concordância moderada.

Figura 30 – Comparativa - Classificação de nível de severidade - Falha de estator - Motor de 1cv - Atributos de tensão e corrente.



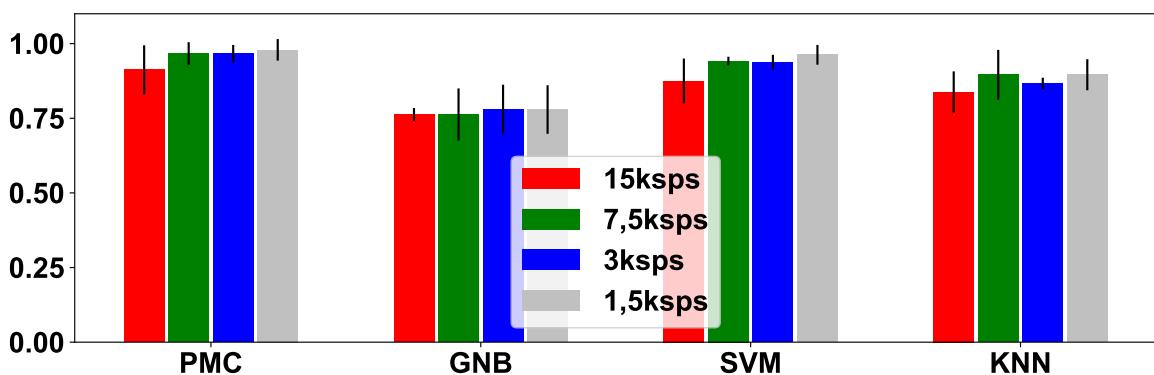
Fonte: Autoria Própria

A Figura 31 que apresenta os resultados da classificação de nível de severidade de falha de estator considerando os atributos de tensão e corrente para o motor de 2cv. Pode-se observar o mesmo comportamento obtido com o teste com o motor de 1cv, onde o classificador que obteve a melhor performance é o PMC mantendo o nível de concordância perfeita, com acuráncias maiores que 0,967. Entretanto, a análise com a taxa amostral de 15ksps, que obteve uma concordância substancial.

Os classificadores SVM e KNN obtiveram uma acurácia superior a 0,838 em todos

os testes e um nível de assertividade superior a substancial. O classificador GNB obteve uma concordância substancial em todos os testes com uma acurácia superior a 0,763.

Figura 31 – Comparativo - Classificação de nível de severidade - Falha de estator - Motor de 2cv - Atributos de tensão e corrente.



Fonte: Autoria Própria

Os classificadores de padrão, em todos os testes, foram capazes de classificar os níveis de severidade para a falha de estator em ambos os motores com resultados semelhantes, indicando uma alta confiabilidade do método considerando a técnica de validação *K-Folds*.

Com o objetivo de avaliar a capacidade dos classificadores de identificar o nível de severidade da falha de estator com um menor número de sensores no motor é proposto o teste apenas com os atributos de corrente. As métricas de desempenho para a combinação de topologia e classificador que obtiveram os melhores resultados são apresentados na Tabela 11.

Observa-se que a estratégia proposta é capaz de classificar os níveis de severidade no MIT para a falha de estator apenas com os atributos de corrente sem muitas perdas em sua performance frente ao teste com os atributos de tensão e corrente.

O comportamento da classificação em ambos os motores é semelhante, com resultados semelhantes. Na maioria dos casos de teste a concordância é superior a substancial, indicando uma alta confiabilidade no método, exceto o GNB

A Figura 32 apresenta a acurácia das melhores topologias e classificadores para o motor de 1cv. Nesta falha observa-se que o comportamento dos classificadores SVM e KNN foram muito semelhantes onde obtiveram a acurácia de 0,933 e 0,958 respectivamente com taxa amostral de 1,5ksps e topologia A com o método *K-Folds* de validação.

O pior classificador dentre os estudados neste caso é o GNB onde na sua melhor performance obteve uma acurácia de 0,729 e concordância substancial. O melhor classificador é o PMC que obteve uma acurácia de 0,996 com índice Kappa de 0,994 indicando uma concordância perfeita.

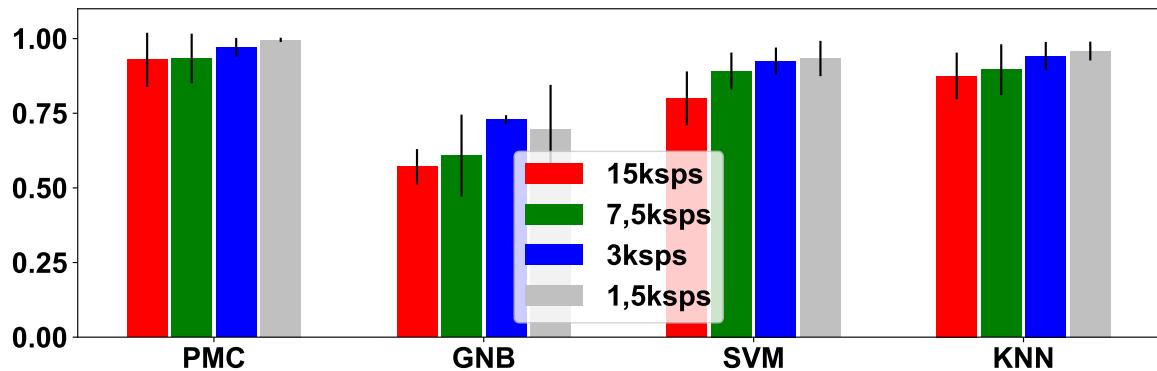
Por meio da Figura 33 observa-se que a classificação de nível de severidade com os atributos de corrente, , onde o comportamento do motor de 2cv é muito semelhante ao de 1cv.

Tabela 11 – Melhores topologias - Classificação de nível de severidade - Falha de Estator - Atributos de corrente - K-Folds

Melhores topologias - Classificação de nível de severidade - Falha de Estator - Motor de 1cv - Atributos de corrente																
Classificador	15ksps				7,5ksps				3ksps				1,5ksps			
	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN
Topologia	A	A	A	A	A	D	A	A	A	A	A	A	A	D	A	A
Acurácia	0,929	0,571	0,800	0,875	0,933	0,629	0,892	0,896	0,971	0,729	0,925	0,942	0,996	0,696	0,933	0,958
Precisão	0,945	0,547	0,802	0,883	0,952	0,623	0,899	0,906	0,976	0,768	0,936	0,953	0,996	0,715	0,933	0,959
Recall	0,933	0,555	0,800	0,870	0,939	0,619	0,897	0,902	0,974	0,735	0,930	0,945	0,996	0,693	0,938	0,961
F1	0,939	0,551	0,801	0,876	0,945	0,621	0,898	0,904	0,975	0,751	0,933	0,949	0,996	0,704	0,936	0,960
Kappa	0,904	0,416	0,732	0,831	0,910	0,499	0,854	0,859	0,961	0,635	0,899	0,921	0,994	0,589	0,910	0,944

Melhores topologias - Classificação de nível de severidade - Falha de Estator - Motor de 2cv - Atributos de corrente																
Classificador	15ksps				7,5ksps				3ksps				1,5ksps			
	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN
Topologia	A	A	A	D	A	A	A	A	A	A	A	A	A	A	A	A
Acurácia	0,917	0,663	0,800	0,813	0,954	0,738	0,883	0,896	0,983	0,750	0,925	0,913	0,925	0,742	0,913	0,908
Precisão	0,918	0,682	0,819	0,813	0,960	0,762	0,898	0,905	0,984	0,770	0,941	0,918	0,931	0,758	0,920	0,928
Recall	0,920	0,660	0,800	0,808	0,959	0,738	0,887	0,902	0,985	0,747	0,931	0,918	0,932	0,742	0,919	0,917
F1	0,919	0,671	0,809	0,810	0,960	0,749	0,892	0,904	0,985	0,758	0,936	0,918	0,932	0,749	0,920	0,922
Kappa	0,888	0,542	0,730	0,747	0,938	0,645	0,842	0,860	0,977	0,661	0,899	0,882	0,899	0,650	0,882	0,876

Figura 32 – Comparativo - Classificação de nível de severidade - Falha de estator - Motor de 1cv - Atributos de corrente.



Fonte: Autoria Própria

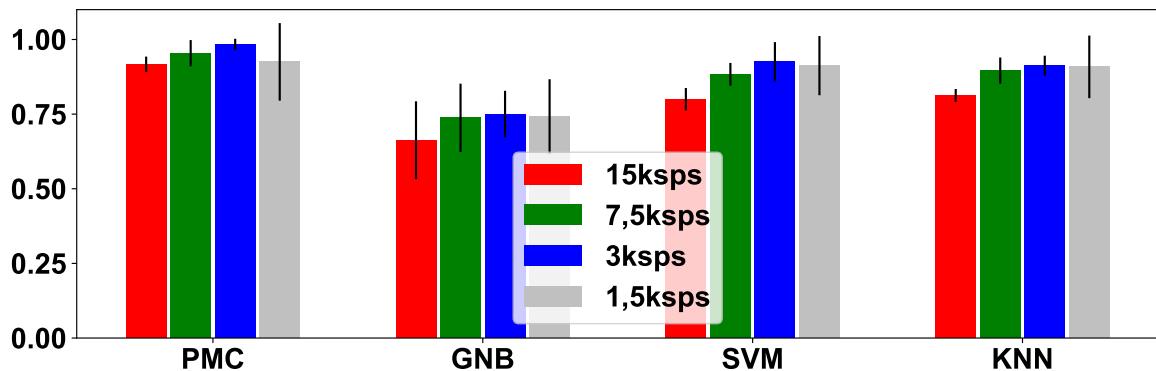
Os classificadores SVM e KNN tiveram uma performance elevada com acurácia e índice Kappa respectivamente superior a 0,800 e 0,730, indicando concordância substancial.

Novamente o classificador que obteve a melhor performance é o PMC com uma acurácia de 0,983 e Kappa de 0,977 resultando em concordância perfeita e a pior performance foi obtida com o GNB onde na sua melhor configuração obteve acurácia de 0,742 com Kappa 0,650.

Em ambos os casos testados para a classificação de nível de severidade da falha de estator com os i) atributos de tensão e corrente e ii) atributos de corrente, os classificadores obtiveram nas melhores classificações um desempenho com acurácia superior a 95%.

Assim, pode-se concluir que a classificação de nível de severidade para a falha de estator não é comprometida quando é apresentado ao sistema apenas os atributos de corrente.

Figura 33 – Comparativo - Classificação de nível de severidade - Falha de estator - Motor de 2cv - Atributos de corrente.



Fonte: Autoria Própria

5.1.2.2 Falha de rotor

Esta seção tem como objetivo apresentar os melhores resultados da classificação do nível de severidade para a falha de rotor e trazer um comparativo da performance dos classificadores nas situações onde são apresentados os atributos de tensão e corrente e apenas os atributos de corrente. Os melhores resultados foram estabelecidos primeiramente pelo critério de maior acurácia e o índice Kappa.

A Tabela 12 apresenta as melhores métricas de desempenho para a classificação de nível de severidade da falha de barras de rotor quebrada considerando as bases de dados dos motores de 1cv e 2cv com os atributos de tensão e corrente.

Observa-se na referida tabela que para o motor de 1cv a melhor performance para todos os classificadores é obtida com a taxa amostral de 3ksps e para o motor de 2cv a melhor performance com 1,5ksps. Ainda, na Tabela 12 observa-se que o classificador que obteve a melhor performance é o PMC e a pior com o GNB.

A Figura 34 apresenta a acurácia da classificação de nível de severidade para a falha de rotor, considerando o motor de 1cv com os atributos de tensão e corrente. Neste caso a melhor performance é alcançada com o classificador PMC com a taxa amostral de 3ksps com acurácia de 0,920 e índice Kappa de 0,893. O classificador com o pior resultado é o GNB com a taxa amostral de 15ksps o qual obteve acurácia 0,434 e concordância fraca com Kappa 0,251.

Na Figura 35 que representa a acurácia da classificação de nível de severidade para a falha de rotor, considerando o motor de 2cv com os atributos de tensão e corrente. Novamente, o melhor classificador é o PMC com taxa amostral de 1,5 ksps obteve acurácia de 0,889 e índice Kappa 0,851.

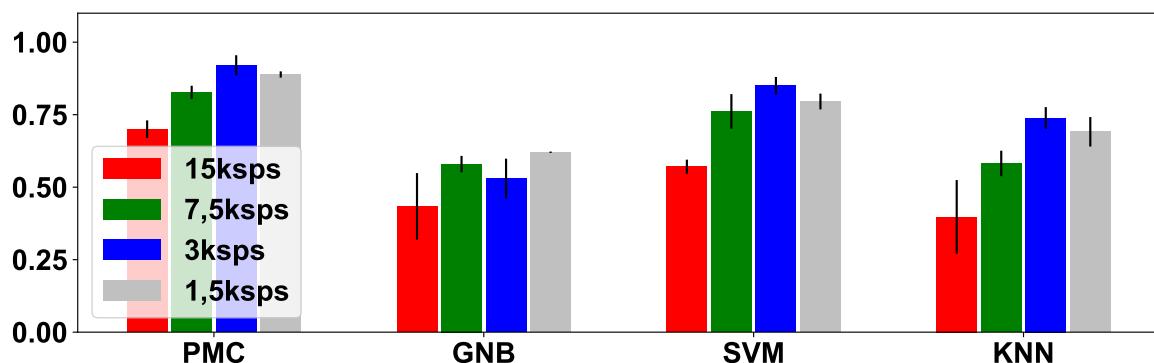
A Tabela 13 apresenta as métricas de desempenho para os testes de classificação de nível de severidade para a falha no rotor nos motores de 1cv e 2cv, apenas com os atributos de corrente. Comparando os resultados obtidos com atributos de tensão e corrente, os quais

Tabela 12 – Melhores topologias - Classificação de nível de severidade - Falha de Rotor - Atributos de tensão e corrente - K-Folds

Melhores topologias - Classificação de nível de severidade - Falha de Rotor - Motor de 1cv - Atributos de tensão e corrente																
Classificador	15ksps				7,5ksps				3ksps				1,5ksps			
	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN
Topologia	A	D	A	D	A	A	A	A	A	A	A	A	A	C	B	B
Acurácia	0,700	0,434	0,570	0,398	0,827	0,580	0,761	0,582	0,920	0,709	0,850	0,739	0,889	0,620	0,795	0,691
Precisão	0,700	0,398	0,573	0,420	0,827	0,604	0,761	0,582	0,929	0,737	0,849	0,745	0,889	0,632	0,801	0,697
Recall	0,694	0,442	0,573	0,402	0,826	0,576	0,763	0,582	0,922	0,707	0,852	0,743	0,888	0,624	0,798	0,693
F1	0,697	0,417	0,573	0,411	0,827	0,589	0,762	0,582	0,925	0,722	0,851	0,744	0,889	0,628	0,800	0,695
Kappa	0,598	0,251	0,428	0,196	0,769	0,438	0,681	0,442	0,893	0,611	0,800	0,652	0,851	0,495	0,728	0,589

Melhores topologias - Classificação de nível de severidade - Falha de Rotor - Motor de 2cv - Atributos de tensão e corrente																
Classificador	15ksps				7,5ksps				3ksps				1,5ksps			
	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN	PMC	GNB	SVM	KNN
Topologia	A	B	A	C	A	C	A	C	A	A	A	D	A	B	A	C
Acurácia	0,573	0,236	0,514	0,241	0,639	0,280	0,589	0,280	0,655	0,377	0,655	0,345	0,889	0,620	0,795	0,691
Precisão	0,588	0,256	0,474	0,272	0,667	0,240	0,583	0,329	0,661	0,359	0,656	0,351	0,889	0,632	0,801	0,697
Recall	0,573	0,233	0,520	0,241	0,629	0,282	0,590	0,283	0,656	0,376	0,658	0,340	0,888	0,624	0,798	0,693
F1	0,580	0,243	0,496	0,254	0,647	0,259	0,586	0,304	0,659	0,365	0,657	0,346	0,889	0,628	0,800	0,695
Kappa	0,431	-0,022	0,355	-0,007	0,514	0,040	0,453	0,044	0,541	0,168	0,541	0,127	0,851	0,495	0,728	0,589

Figura 34 – Comparativo - Classificação de nível de severidade - Falha de rotor - Motor de 1cv - Atributos de tensão e corrente.



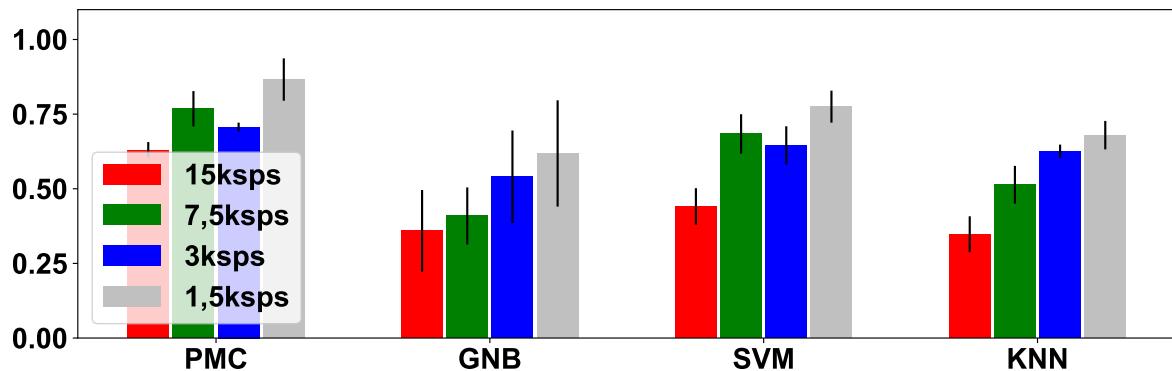
Fonte: Autoria Própria

foram apresentados na Tabela 12 percebe-se a redução pouco significativa na performance dos classificadores. Assim, tem-se a possibilidade de aplicação desta metodologia com um número menor de sensores.

A Figura 36 apresenta as acurárias no teste de classificação de nível de severidade para a falha de rotor no motor de 1cv. Na referida figura observa-se que o melhor classificador neste teste é o PMC com acurácia 0,866 e índice Kappa de 0,821 indicando, segundo a escala de LANDIS e KOCH (1977), uma concordância perfeita. Por outro lado o pior classificador é o GNB onde na sua melhor performance obteve uma concordância moderada com acurácia de 0,618.

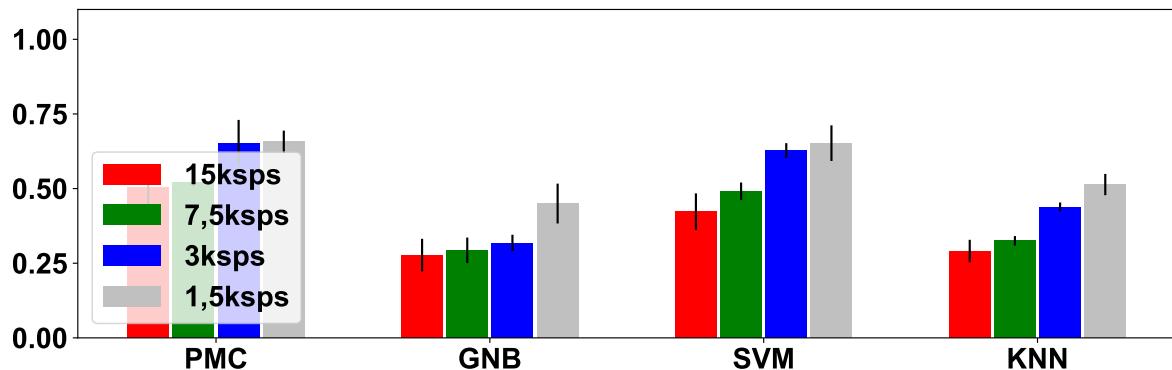
A Figura 37 apresenta as acuráncias no teste de classificação de nível de severidade

Figura 36 – Comparativo - Classificação de nível de severidade - Falha de rotor - Motor de 1cv - Atributos de corrente.



Fonte: Autoria Própria

Figura 37 – Comparativo - Classificação de nível de severidade - Falha de rotor - Motor de 2cv - Atributos de corrente.



Fonte: Autoria Própria

corrente, observou-se a redução na performance dos classificadores nos testes com o motor de 1cv e 2cv quando comparados aos resultados com os atributos de tensão e corrente. Entretanto, conclui-se que para as falhas de rotor é possível a classificação apenas com os atributos de corrente.

5.1.2.3 Falha de rolamento

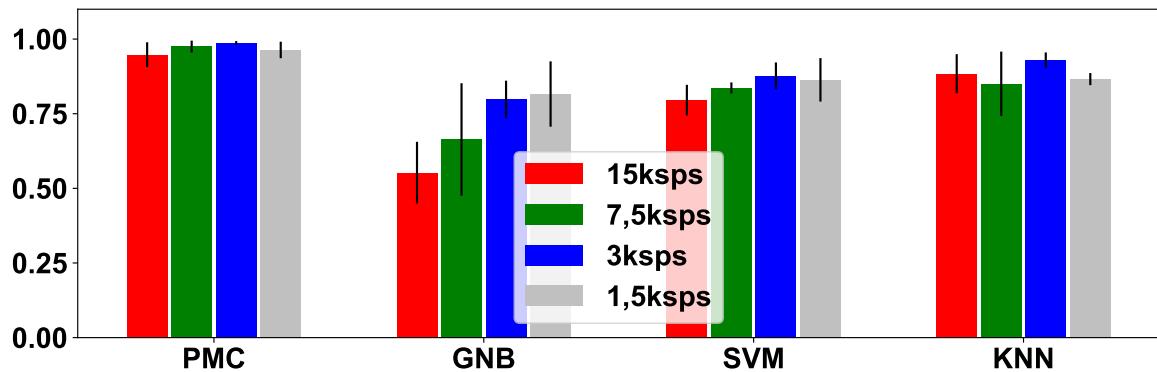
Esta seção apresenta as métricas de desempenho dos testes que obtiveram o melhor resultado na classificação de nível de severidade para a falha de desgaste de rolamentos do MIT. A primeira análise considera os atributos de tensão e corrente. A seguir são avaliados apenas os atributos de corrente na mesma falha.

A Tabela 14 apresenta as métricas de desempenho para os testes de classificação de nível de severidade para a falha de rolamento, considerando os atributos de tensão e corrente.

A Figura 39 apresenta as métricas de acurácia para todos os testes de classificação de nível de severidade da falha de rolamento com os atributos de tensão e corrente para o motor de 2cv. Assim, o melhor classificador para a solução do problema é o PMC também com taxa amostral de 3 ksp, onde sua acurácia é de 0,986 e Kappa 0,986 com uma concordância idêntica ao teste realizados com o motor de 1cv.

O pior classificador no teste é o GNB que obteve a taxa amostral de 3ksp sua melhor performance onde a acurácia é de 0,798 e Kappa 0,731 indicando uma concordância substancial. Os classificadores SVM e KNN obtiveram sua melhor performance também com a taxa amostral de 3ksp e suas acuráncias foram respectivamente 0,877 e 0,863 com Kappa 0,836 e 0,906 indicando uma concordância perfeita em ambos os casos.

Figura 39 – Comparativo - Classificação de nível de severidade - Falha de rolamento - Motor de 2cv - Atributos de tensão e corrente.



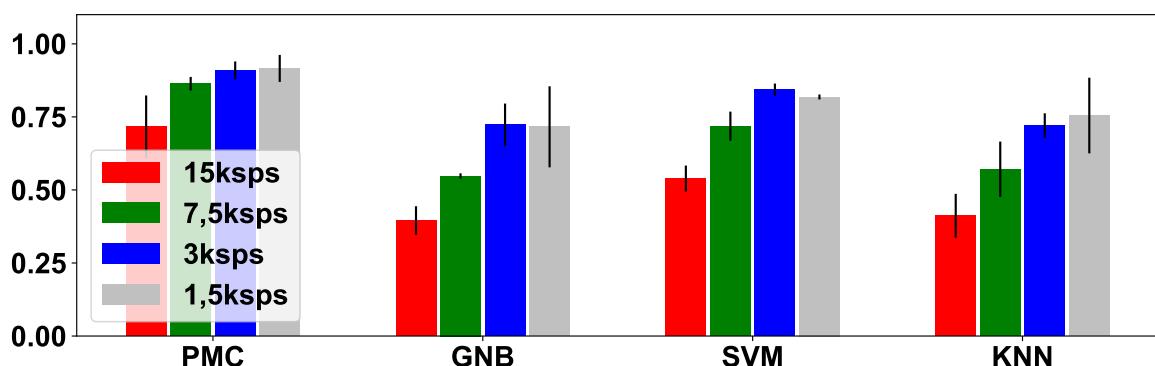
Fonte: Autoria Própria

As métricas de desempenho para a classificação do nível de severidade apenas com os atributos de corrente para a falha de rotor são apresentados na Tabela 15. Na Figura 40 são apresentadas as métricas de acurácia no teste de classificação de nível de severidade para a falha de rolamento com os atributos de corrente para o motor de 1cv. Na referida figura tem-se a melhor performance com o PMC no teste com 3ksp, acurácia de 0,952 e Kappa 0,936. O pior classificador no teste é o GNB o qual obteve seu melhor resultado com a taxa amostral de 1,5ksp, acurácia de 0,711 e Kappa de 0,616 indicando uma concordância substancial.

A Figura 41 apresenta as métricas de acurácia no teste de classificação de nível de severidade para a falha de rolamento com os atributos de corrente para o motor de 2cv. Neste caso o melhor classificador é o PMC com acurácia 0,916 e Kappa 0,888 indicando uma concordância novamente perfeita. O pior classificador novamente é o GNB com acurácia de 0,723 e Kappa 0,630 na sua melhor configuração.

O classificador SVM obteve a melhor performance com a taxa amostral de 3ksp com acurácia de 0,843 e índice Kappa de 0,791 indicando uma concordância substancial. Já o classificador KNN obteve a melhor performance com uma acurácia de 0,755 e Kappa 0,673

Figura 41 – Comparativo - Classificação de nível de severidade - Falha de rolamento - Motor de 2cv - Atributos de corrente.



Fonte: Autoria Própria

5.2 DISCUSSÕES

Esta seção tem como objetivo apresentar o resultado das discussões apresentadas na Seção 1.4 sendo elas i) Com a redução da taxa amostral é possível a classificação de falhas ?, ii) Com a redução dos sensores é possível a classificação de falha ?, iii) Qual a melhor topologia para a classificação de falha e nível de severidade no MIT ? e iv) Qual o melhor classificador de padrão para a identificação de falha e nível de severidade no MIT ?, com uma abordagem destinada a redução do custo e complexidade de implementação.

5.2.1 Taxa amostral e Atributos

Os questionamentos com a redução da taxa amostral e dos sensores é possível a classificação de falha e nível de severidade no MIT, com a redução de custos de implementação da metodologia proposta neste trabalho.

Nesta dissertação quatro taxas amostrais foram testadas, a citar: i) 1,5 ksp, ii) 3 ksp, iii) 7,5 ksp e iv) 15 ksp. De forma complementar, também são testadas duas configurações de sensores, a citar: i) tensão e corrente e apenas ii) corrente.

Para determinar a melhor taxa amostral utilizou-se o valor com maior acurácia. Na análise de falha temos que em 65,5% dos casos o melhor resultado é obtido com a taxa amostral de 3 ksp. Ainda, nos testes de nível de severidade 50% dos melhores resultados foram obtidos com a taxa amostral de 3 ksp e os outros 50% foram obtidos com a taxa amostral de 1,5 ksp. Assim, a classificação de falha e nível de severidade, o melhor resultado foi obtido com a taxa de 3 ksp.

No tocante aos atributos conforme descrito na Seção 5.1, a utilização apenas dos atributos de corrente não acarretaram em uma redução significativa da acurácia do modelo. Portanto justifica-se a utilização apenas dos sensores de corrente resultando assim em uma classificação

de falha ainda com uma alta acurácia, porém com a redução no custo de implementação da metodologia proposta neste trabalho.

5.2.2 Topologias e Classificadores

Os questionamentos relativos a melhor topologia e classificador para a identificação de falha e nível de severidade no MIT estão relacionados ao modelo computacional para a implementação da metodologia de classificação de falha no MIT.

Nesta dissertação quatro classificadores foram testados a citar: PMC, GNB, SVM e KNN, também é testado quatro topologias conforme descrito na Seção 4.2.2.

Neste contexto, o melhor classificador é definido por meio da análise dos resultados de acurácia e índice Kappa obtidos em cada caso. Nos casos de classificação de falhas e severidade tem-se em 100% dos casos o classificador PMC alcançando os melhores resultados.

Com relação as topologias convolucionais, 61,72% dos melhores resultados para a classificação de falha e 76,04% para a classificação de nível de severidade foram obtidos com a topologia A.

5.3 CONCLUSÃO DO CAPÍTULO

Esta seção tem como objetivo apresentar a conclusão da análise dos resultados deste capítulo e o comparativo dos resultados obtidos neste trabalho na classificação de falha no motor de indução trifásico com outros métodos propostos na literatura conforme a Tabela 16.

Tabela 16 – Comparativo da classificação de falha na literatura

	Este trabalho	1	2	3	4
Motores	1cv e 2cv	1cv e 2cv	1cv e 2cv	1/4cv	1cv
Extração de características	Rede neural convolucional	-	-	-	-
Dados	Tensão e Corrente / Corrente	Corrente	Corrente	Corrente	Corrente
Método de Classificação	PMC / GNB KNN / SVM	PMC / RIPPER / NB KNN / SVM / C4.5	PMC	PMC	FUZZY
Desequilíbrio	Sim	Sim	Sim	Não	Sim
Variação de carga	Sim	Sim	Sim	Não	Sim
Falha de estator	Sim	Sim	Sim	Sim	Sim
Falha de rotor	Sim	Sim	Sim	Não	Sim
Falha de rolamento	Sim	Sim	Sim	Não	Sim
Acurácia	≤ 99,4%	≈ 90%	≈ 88,9%	≤ 87%	≤ 95%
Multiclassificador	Sim	Sim	Sim	Não	Sim

Fonte: Autoria Própria.

- 1 - PALACIOS (2016)
- 2 - PALACIOS (2016), reproduzido.
- 3 - Asfani et al. (2012)
- 4 - Seera et al. (2013)
- T - Domínio do tempo
- F - Domínio da frequência

Observa-se que o trabalho proposto com a extração de características do sinal de

alimentação do MIT por meio da rede neural convolucional, apresentou resultados compatíveis quando comparados aos resultados obtidos na literatura.

Em todos os casos de classificação do nível de severidade, os classificadores foram capazes de obter uma elevada acurácia e ótimos índices de concordância Kappa, indicando que a estratégia proposta também é capaz de classificar o nível de severidade das falhas estudadas no MIT.

A análise da classificação com os atributos de tensão e corrente e apenas com os atributos de corrente, indicou que apesar de haver uma pequena perda na performance do classificador, é possível realizar a classificação de falha e do nível de severidade sem os atributos de tensão, reduzindo os custos de implementação da estratégia.

Quanto a análise da taxa amostral, é observada a relação entre a quantidade de ciclos apresentados a rede e a acurácia. Tem-se assim um ponto ótimo da classificação na taxa amostral de 3 ksps.

6 CONCLUSÃO

O principal objetivo deste trabalho foi o estudo e implementação de um classificador de padrões por meio de uma rede neural convolucional para a identificação de três classes de falhas no MIT: i) Falha de Rolamento, ii) Falha de Rotor e iii) Falha de Estator, bem como a iv) Classe de Motor Saudável.

Com o objetivo de determinar a confiabilidade da estratégia, duas técnicas de validação foram aplicadas: i) *K-Folds* realizando os testes nos motores de 1cv e 2cv e o ii) Teste de generalização entre motores. Em ambos os casos foram obtidos resultados de acurácia superior a 90%, sendo que o teste com o teste de generalização apresentou resultado inferior ao teste com *K-Folds* de 15,5% considerando os melhores casos.

Os testes com os diferentes atributos: i) tensão e corrente e ii) corrente, bem como os testes com as diferentes taxas amostrais: i) 15 ksps, ii) 7,5 ksps, iii) 3 ksps e iv) 1,5 ksps, tiveram como objetivo o estudo da classificação de falha e nível de severidade com menor custo em termos de sensores e de processamento de sinais. Os resultados desta análise também se mostraram satisfatórios visto que não houve uma redução significativa na acurácia quando apresentado à rede apenas os atributos de corrente e a taxa amostral que apresentou os melhores resultados foi a de 3 ksps.

Quatro classificadores foram analisados, após a extração de características por meio das camadas convolucionais: i) PMC, ii) GNB, iii) SVM e iv) KNN. O classificador que obteve a melhor performance em todos os testes foi o PMC. No mesmo contexto, a topologia que apresentou o melhor resultado foi a A.

Nos testes de classificação de falha com a técnica *K-Folds*, o comportamento de todos os classificadores foi muito semelhante com as duas bases de dados. Na classificação com os atributos de tensão e corrente o classificador PMC para o motor de 1cv obteve uma acurácia de 0,993 e para o motor de 2cv de 0,994. Já o resultado para a classificação apenas com os atributos de corrente a acurácia com o classificador PMC para o motor de 1cv e 2cv foi de 0,980 e 0,971. Portanto, conclui-se que os resultados foram satisfatórios e devido a baixa redução das acurárias a classificação de falhas no MIT pode ser realizada apenas com os atributos de corrente.

No teste de classificação de falha com a técnica de generalização entre motores, novamente os testes com os motores de 1cv e 2cv foram semelhantes. O melhor resultado é associado ao PMC com os atributos de tensão e corrente no treinamento com o motor de 1cv e teste com o motor de 2cv com acurácia de 0,839. No treinamento com o motor de 2cv e teste com o motor de 1cv obteve uma acurácia de 0,817.

No teste de classificação de nível de severidade para as três falhas estudadas foram obtidos resultados de acurácia superior a 92% considerando os atributos de tensão e corrente e superior a 86% utilizando apenas corrente utilizando a técnica de validação *K-Folds*.

6.1 PERSPECTIVAS DE TRABALHOS FUTUROS

A estratégia proposta de extração de características de falhas por meio de uma rede neural convolucional mostrou-se como uma metodologia alternativa para a solução do problema. Assim, uma possível continuação deste trabalho seria a análise de classificação de falhas no motor de indução trifásico alimentado por inversor de frequência.

Ainda, com o desenvolvimento da industria 4.0 associado com a computação em nuvem tem-se como perspectiva a implementação desta metodologia na nuvem (*Cloud Computing*) alimentado por dados obtidos de motores na industria

Outra possibilidade de implantação da estratégia proposta consiste na utilização de sensores de vibração empregando a mesma estratégia de extração de características utilizada neste trabalho.

REFERÊNCIAS

- ALBRECHT, P. F. et al. Assessment of the reliability of motors in utility applications - updated. **IEEE Transactions on Energy Conversion**, Institute of Electrical and Electronics Engineers (IEEE), EC-1, n. 1, p. 39–46, March 1986. ISSN 0885-8969. Citado na página 22.
- ASFANI, D.A. et al. Temporary short circuit detection in induction motor winding using combination of wavelet transform and neural network. **Expert Systems with Applications**, Elsevier BV, ., v. 39, n. 5, p. 5367–5375, apr 2012. Citado na página 75.
- ASFANI, D. A.; PURNOMO, M. H.; SAWITRI, D. R. Naive bayes classifier for temporary short circuit fault detection in stator winding. In: **2013 9th IEEE International Symposium on Diagnostics for Electric Machines, Power Electronics and Drives (SDEMPED)**. [S.I.]: IEEE, 2013. Citado na página 35.
- BAZAN, G. H. et al. Information theoretical measurements from induction motors under several load and voltage conditions for bearing faults classification. **IEEE Transactions on Industrial Informatics**, Institute of Electrical and Electronics Engineers (IEEE), p. 1–1, 2019. Citado 2 vezes nas páginas 42 e 46.
- BONNETT, A. H.; SOUKUP, G. C. Cause and analysis of stator and rotor failures in three-phase squirrel-cage induction motors. **IEEE Transactions on Industry Applications**, Institute of Electrical and Electronics Engineers (IEEE), v. 28, n. 4, p. 921–937, July 1992. ISSN 0093-9994. Citado 2 vezes nas páginas 23 e 24.
- BRONIERA, P. J. **DIAGNÓSTICO DE CURTO-CIRCUITO NO ENROLAMENTO DE ESTATOR EM MÁQUINAS DE INDUÇÃO TRIFÁSICAS UTILIZANDO REDES NEURAIS ARTIFICIAIS**. 2014. Dissertação (Mestrado) — Universidade Tecnológica Federal do Paraná - UTFPR, 2014. Citado na página 43.
- COHEN, J. A coefficient of agreement for nominal scales. **Educational and Psychological Measurement**, SAGE Publications, v. 20, n. 1, p. 37–46, apr 1960. Citado na página 40.
- CORNE, BRAM et al. Comparing MCSA with vibration analysis in order to detect bearing faults — a case study. In: **2015 IEEE International Electric Machines & Drives Conference (IEMDC)**. IEEE, 2015. Disponível em: <<https://doi.org/10.1109/iemdc.2015.7409240>>. Citado na página 18.
- DRIF, M.; CARDOSO, A. J. M. Stator fault diagnostics in squirrel cage three-phase induction motor drives using the instantaneous active and reactive power signature analyses. **IEEE Transactions on Industrial Informatics**, v. 10, n. 2, p. 1348–1360, May 2014. ISSN 1551-3203. Citado na página 23.
- GANDHI, ARUN; CORRIGAN, TIMOTHY; PARSA, LEILA. Recent advances in modeling and online detection of stator interturn faults in electrical motors. **IEEE Transactions on Industrial Electronics**, Institute of Electrical and Electronics Engineers (IEEE), v. 58, n. 5, p. 1564–1575, may 2011. Citado na página 24.
- GODOY, W. F. **Multiclassificador inteligente de falhas no domínio do tempo em motores de indução trifásicos alimentados por inversores de frequência**. 2016. Tese (phdthesis) — Escola de Engenharia de São Carlos - USP, 2016. Citado na página 45.

GODOY, W. F. et al. Application of intelligent tools to detect and classify broken rotor bars in three-phase induction motors fed by an inverter. **IET Electric Power Applications**, Institution of Engineering and Technology (IET), v. 10, n. 5, p. 430–439, may 2016. Citado na página 42.

GONGORA, W. S. **Uma abordagem neural no diagnóstico de falhas em rolamentos de motores de indução trifásicos**. fev. 2013. Dissertação (mathesis) — Universidade Tecnológica Federal do Paraná, fev. 2013. Disponível em: <<http://repositorio.utfpr.edu.br/jspui/handle/1/782>>. Citado na página 46.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. : MIT Press, 2016. <<http://www.deeplearningbook.org>>. Citado 3 vezes nas páginas 28, 29 e 30.

GUEDES, J. J. et al. Parameters estimation of three-phase induction motors using differential evolution. **Electric Power Systems Research**, Elsevier BV, v. 154, p. 204–212, jan 2018. Citado na página 42.

HAYKIN, S. **Redes Neurais: Princípios e práticas**. Porto Alegre, Brasil: Bookman, 2001. ISBN 978-85-7307-718-6. Citado 2 vezes nas páginas 38 e 39.

IGNATOV, A. Real-time human activity recognition from accelerometer data using convolutional neural networks. **Applied Soft Computing**, v. 62, p. 915 – 922, 2018. ISSN 1568-4946. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S1568494617305665>>. Citado na página 20.

INCE, T. et al. Real-time motor fault detection by 1-d convolutional neural networks. **IEEE Transactions on Industrial Electronics**, v. 63, n. 11, p. 7067–7075, Nov 2016. ISSN 0278-0046. Citado na página 28.

KANKATALA, S. **Performance Analysis of kNN on large datasets using CUDA & Pthreads comparing between CPU & GPU**. set. 2015. Dissertação (mathesis) — Blekinge Institute of Technology, SE371 79 Karlskrona, Sweden, set. 2015. Disponível em: <<https://www.diva-portal.org/smash/get/diva2:861804/FULLTEXT01.pdf>>. Citado na página 35.

KARMAKAR, S. et al. **Induction Motor Fault Diagnosis Approach through Current Signature Analysis**. : Springer Singapore, 2016. ISBN 978-981-10-0623-4. Citado na página 22.

KIRANYAZ, S.; INCE, T.; GABBOUJ, M. Real-time patient-specific ecg classification by 1-d convolutional neural networks. **IEEE Transactions on Biomedical Engineering**, v. 63, n. 3, p. 664–675, March 2016. ISSN 0018-9294. Citado na página 19.

KRIZHEVSKY, A.; SUTSKEVER, I; HINTON, G. E. ImageNet classification with deep convolutional neural networks. **Communications of the ACM**, Association for Computing Machinery (ACM), v. 60, n. 6, p. 84–90, may 2017. Citado na página 33.

KUNCHEVA, L. I. **Combining Pattern Classifiers: Methods and Algorithms**. Wiley-Interscience, 2004. ISBN 0-471-21078-1. Disponível em: <<https://www.amazon.com/Combining-Pattern-Classifiers-Methods-Algorithms/dp/0471210781?SubscriptionId=AKIAIOBINVZYXQZ2U3A&tag=chimbori05-20&linkCode=xm2&camp=2025&creative=165953&creativeASIN=0471210781>>. Citado na página 34.

LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. **Biometrics**, JSTOR, v. 33, n. 1, p. 159, mar 1977. Citado 4 vezes nas páginas 40, 41, 68 e 71.

- LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, Springer Science and Business Media LLC, v. 521, n. 7553, p. 436–444, maio 2015. Disponível em: <<https://doi.org/10.1038/nature14539>>. Citado na página 28.
- LECUN, Y. et al. Gradient-based learning applied to document recognition. In: **Intelligent Signal Processing**. : IEEE Press, 2001. p. 306–351. Citado na página 19.
- LIU, R. et al. Artificial intelligence for fault diagnosis of rotating machinery: A review. **Mechanical Systems and Signal Processing**, v. 108, p. 33 – 47, 2018. ISSN 0888-3270. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0888327018300748>>. Citado na página 19.
- LOPES, T. D. et al. Bearing fault identification of three-phase induction motors bases on two current sensor strategy. **Soft Computing**, Springer Science and Business Media LLC, v. 21, n. 22, p. 6673–6685, jun 2016. Citado 2 vezes nas páginas 42 e 46.
- MARTINS, A. F. T.; ASTUDILLO, R. F. From softmax to sparsemax: A sparse model of attention and multi-label classification. **CoRR**, abs/1602.02068, 2016. Disponível em: <<http://arxiv.org/abs/1602.02068>>. Citado na página 34.
- MENDES, C. C. T. **Estimação de navegabilidade para veículos autônomos usando aprendizado de máquinas**. 2017. Dissertação (Mestrado) — Universidade de São Paulo, 2017. Citado na página 28.
- MESSAOUDI, M.; LASSAAD, S. Multiple faults diagnosis in induction motor using the mcsa method. **International Journal of signal and Image processing**, v. 1, p. 190–195, 05 2010. Citado na página 25.
- MOON, S.; JANG, S.; LEE, J. Convolutional neural network approach for eeg-based emotion recognition using brain connectivity and its spatial information. **CoRR**, abs/1809.04208, 2018. Disponível em: <<http://arxiv.org/abs/1809.04208>>. Citado na página 20.
- PALACIOS, R. H. C. **Aplicação de técnicas inteligentes com análise no domínio do tempo para reconhecimento de defeitos em motores de indução trifásicos**. 2016. Tese (phdthesis) — Escola de Engenharia de São Carlos - USP, 2016. Citado na página 75.
- PALACIOS, R. H. C. et al. Diagnosis of stator faults severity in induction motors using two intelligent approaches. **IEEE Transactions on Industrial Informatics**, Institute of Electrical and Electronics Engineers (IEEE), v. 13, n. 4, p. 1681–1691, aug 2017. Citado 2 vezes nas páginas 42 e 43.
- PATLE, A.; CHOUHAN, D. S. SVM kernel functions for classification. In: **2013 International Conference on Advances in Technology and Engineering (ICATE)**. [S.I.]: IEEE, 2013. Citado na página 39.
- PICZAK, K. J. Environmental sound classification with convolutional neural networks. In: **2015 IEEE 25th International Workshop on Machine Learning for Signal Processing (MLSP)**. [S.I.: s.n.], 2015. p. 1–6. ISSN 1551-2541. Citado na página 20.
- POWERS, D.M.W. Evaluation: From precision, recall and f-measure to roc, informedness, markedness & correlation. **Journal of Machine Learning Technologies**, v. 2, n. 1, p. 37–63, Feb 2011. ISSN 2229-3981 & 2229-399X. Citado na página 39.

- RADU, C. The most common causes of bearing failure and the importance of bearing lubrication. **RKB TECHNICAL REVIEW**, fev. 2010. Citado na página 26.
- RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **Nature**, Nature Publishing Group, v. 323, p. 533–, out. 1986. Disponível em: <<http://dx.doi.org/10.1038/323533a0>>. Citado na página 30.
- SAINATH, T. N. et al. Convolutional, long short-term memory, fully connected deep neural networks. p. 4580–4584, April 2015. ISSN 1520-6149. Citado na página 19.
- SASAKI, Y. The truth of the f-measure. **School of Computer Science, University of Manchester**, p. 1–5, Oct 2007. Disponível em: <<https://www.cs.odu.edu/~mukka/cs795sum09dm/LectureNotes/Day3/F-measure-YS-26Oct07.pdf>>. Citado na página 40.
- SCHMITT, HELDER LUIZ et al. Detecting bearing faults in line-connected induction motors using information theory measures and neural networks. **Journal of Control, Automation and Electrical Systems**, Springer Science and Business Media LLC, v. 26, n. 5, p. 535–544, aug 2015. Citado na página 46.
- SEERA, M. et al. Application of the fuzzy min–max neural network to fault detection and diagnosis of induction motors. **Neural Computing and Applications**, v. 23, n. 1, p. 191–200, Dec 2013. ISSN 1433-3058. Disponível em: <<https://doi.org/10.1007/s00521-012-1310-x>>. Citado na página 75.
- SILVA, I. N.; SPATTI, D. H.; FLAUZINO, R. A. **Redes Neurais Artificiais para engenharia e ciências aplicadas**. São Paulo, Brasil: Artliber, 2010. ISBN 978-85-88098-53-4. Citado 4 vezes nas páginas 37, 38, 48 e 50.
- SIMONYAN, K.; ZISSERMAN, A. Very deep convolutional networks for large-scale image recognition. 2015. Disponível em: <<http://arxiv.org/abs/1409.1556>>. Citado na página 19.
- SINGH, G.K; KAZZAZ, S. A. S. A. Induction machine drive condition monitoring and diagnostic research—a survey. **Electric Power Systems Research**, Elsevier BV, v. 64, n. 2, p. 145–158, fev. 2003. Citado 4 vezes nas páginas 18, 22, 23 e 25.
- SINGH, S.; KUMAR, A.; KUMAR, N. Motor current signature analysis for bearing fault detection in mechanical systems. **Procedia Materials Science**, v. 6, p. 171–177, 12 2014. Citado na página 26.
- SKF. **Rolamentos de esferas**. 2005. Grupo SKF 2015. Citado na página 25.
- SUÁREZ-PANIAGUA, V.; SEGURA-BEDMAR, I. Evaluation of pooling operations in convolutional architectures for drug-drug interaction extraction. **BMC Bioinformatics**, Springer Nature, v. 19, n. S8, jun. 2018. Disponível em: <<https://doi.org/10.1186/s12859-018-2195-1>>. Citado na página 31.
- SUETAKE, M. **Sistemas inteligentes para monitoramento e diagnósticos de falhas em motores de indução trifásicos**. 2012. Tese (phdthesis) — Escola de Engenharia de São Carlos - USP, 2012. Citado 2 vezes nas páginas 43 e 45.
- TRZYNADLOWSKI, A. **Control of Induction Motors**. : University of Nevada, Reno, USA, Academic Press, 2000. Citado 2 vezes nas páginas 18 e 22.

WAIDE, P.; BRUNNER, C. U. **Energy-Efficiency Policy Opportunities for Electric Motor-Driven Systems**. 9 rue de la Fédération, 75739 Paris Cedex 15, France, 2011. Citado na página 18.

WEG, Motores Elétricos. **Windings: Three-Phase Motors**. 2013. Citado na página 23.

ZABINSKI, T. et al. Condition monitoring in industry 4.0 production systems - the idea of computational intelligence methods application. **Procedia CIRP**, v. 79, p. 63 – 67, 2019. ISSN 2212-8271. 12th CIRP Conference on Intelligent Computation in Manufacturing Engineering, 18-20 July 2018, Gulf of Naples, Italy. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S221282711930126X>>. Citado na página 19.

ZHANG, H. The optimality of naive bayes. AAAI Press, 2004. Citado na página 35.

ZHANG, N. et al. Naive bayes bearing fault diagnosis based on enhanced independence of data. **Sensors**, MDPI AG, v. 18, n. 2, p. 463, feb 2018. Citado na página 35.

ZHAO, R. et al. Deep learning and its applications to machine health monitoring. **Mechanical Systems and Signal Processing**, v. 115, p. 213 – 237, 2019. ISSN 0888-3270. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0888327018303108>>. Citado na página 18.

Apêndices

